

Fundamentos Matemáticos del Aprendizaje Automático

Teoría, demostraciones y formulación rigurosa de los métodos de regresión, clasificación y análisis de datos

MI Jesús Gilberto Rodríguez Escobedo

2026-07-27

Tabla de contenidos

1 Fundamentos Matemáticos del Aprendizaje Automático	16
Bienvenida	17
Objetivos generales	17
2 Presentación	18
3 Introducción	19
4 Notación general	20
 I I. Fundamentos matemáticos	 21
5 Lenguaje matemático, conjuntos y funciones	22
5.1 Introducción	22
5.2 Objetivos	22
5.3 Conjuntos numéricos	22
5.4 Concepto de conjunto	23
5.5 Formas de especificar conjuntos	24
5.5.1 Por extensión	24
5.5.2 Por comprensión	24
5.6 Igualdad de conjuntos	24
5.7 Subconjuntos	25
5.8 Conjunto vacío	25
5.9 Operaciones entre conjuntos	26
5.9.1 Unión	26
5.9.2 Intersección	26
5.9.3 Diferencia	26
5.9.4 Complemento	26
5.10 Propiedades fundamentales	27
5.10.1 Conmutatividad	27
5.10.2 Asociatividad	27
5.10.3 Distributividad	27
5.10.4 Leyes de De Morgan	28
5.11 Producto cartesiano	28
5.12 Relaciones	28
5.13 Funciones	29
5.14 Dominio, codominio e imagen	29
5.15 Imagen e imagen inversa de conjuntos	30

5.16	Funciones inyectivas, suprayectivas y biyectivas	30
5.16.1	Función inyectiva	30
5.16.2	Función suprayectiva	30
5.16.3	Función biyectiva	31
5.17	Composición de funciones	31
5.18	Función indicadora	32
5.19	Sumatorias y productorias	32
5.20	Representación formal de datos	33
5.21	Regresión y clasificación	34
5.21.1	Regresión	34
5.21.2	Clasificación binaria	34
5.21.3	Clasificación multiclase	35
5.22	Función objetivo desconocida	35
5.23	Ejemplo integrado	35
5.24	Conexión con R	36
5.25	Errores frecuentes	37
5.26	Ejercicios	37
5.26.1	Ejercicios conceptuales	37
5.26.2	Ejercicios de conjuntos	37
5.26.3	Ejercicios de funciones	38
5.26.4	Ejercicio de clasificación	38
5.27	Resumen	39
6	Álgebra lineal para aprendizaje automático	40
6.1	Introducción	40
6.2	Objetivos	40
6.3	Escalares	41
6.4	Vectores	41
6.5	Igualdad de vectores	42
6.6	Suma de vectores	42
6.7	Multiplicación por un escalar	43
6.8	Combinaciones lineales	43
6.9	Combinación convexa	43
6.10	Independencia lineal	44
6.11	Espacios vectoriales	45
6.12	Subespacios	45
6.13	Espacio generado	45
6.14	Base y dimensión	46
6.15	Matrices	46
6.16	Filas y columnas	47
6.17	Matrices especiales	47
6.17.1	Matriz cero	47
6.17.2	Matriz identidad	48
6.17.3	Matriz diagonal	48
6.17.4	Matriz simétrica	48
6.18	Suma de matrices	48
6.19	Multiplicación de una matriz por un escalar	49
6.20	Producto matricial	49

6.21	Matriz transpuesta	50
6.22	Producto interno	50
6.23	Norma	51
6.24	Distancia euclidiana	51
6.25	Desigualdad de Cauchy-Schwarz	51
6.26	Ángulo entre vectores	52
6.27	Ortogonalidad	52
6.28	Vectores ortonormales	52
6.29	Proyección ortogonal	53
6.30	Sistemas de ecuaciones lineales	53
6.31	Matriz inversa	53
6.32	Determinante	54
6.33	Rango	54
6.34	Espacio columna	55
6.35	Espacio nulo	55
6.36	Transformaciones lineales	55
6.37	Formas cuadráticas	56
6.38	Matrices definidas positivas	56
6.39	Valores y vectores propios	56
6.40	Interpretación geométrica	57
6.41	Descomposición espectral	58
6.42	Matriz de covarianza	58
6.43	Descomposición en valores singulares	58
6.44	Aproximación de rango bajo	59
6.45	Pseudoinversa	60
6.46	Relación con regresión lineal	60
6.47	Relación con PCA	61
6.48	Relación con redes neuronales	61
6.49	Conexión con R	61
6.50	Ejemplo numérico integrado	62
6.51	Errores frecuentes	63
6.52	Ejercicios conceptuales	63
6.53	Ejercicios de cálculo	63
6.54	Ejercicios de matrices	64
6.55	Ejercicio de independencia lineal	64
6.56	Ejercicio de valores propios	64
6.57	Ejercicio aplicado	65
6.58	Resumen	65
7	Probabilidad y estadística para aprendizaje automático	66
7.1	Introducción	66
7.2	Objetivos	66
7.3	Experimentos aleatorios	67
7.4	Espacio muestral	67
7.5	Eventos	67
7.6	Sigma-álgebra	68
7.7	Espacio de probabilidad	68
7.8	Axiomas de probabilidad	68

7.9	Propiedades fundamentales	69
7.10	Probabilidad condicional	69
7.11	Regla del producto	70
7.12	Independencia	70
7.13	Partición del espacio muestral	70
7.14	Teorema de probabilidad total	71
7.15	Teorema de Bayes	71
7.16	Ejemplo de diagnóstico	71
7.17	Variables aleatorias	72
7.18	Variables aleatorias discretas	72
7.19	Distribución Bernoulli	73
7.20	Distribución binomial	73
7.21	Variables aleatorias continuas	74
7.22	Función de distribución acumulada	74
7.23	Distribución normal	75
7.24	Esperanza matemática	75
7.25	Esperanza de una función	75
7.26	Linealidad de la esperanza	76
7.27	Varianza	76
7.28	Propiedades de la varianza	76
7.29	Covarianza	77
7.30	Correlación	77
7.31	Variables aleatorias conjuntas	77
7.32	Distribuciones marginales	78
7.33	Distribuciones condicionales	78
7.34	Independencia de variables aleatorias	78
7.35	Vectores aleatorios	79
7.36	Matriz de covarianza	79
7.37	Distribución normal multivariada	79
7.38	Muestra aleatoria	80
7.39	Media muestral	80
7.40	Varianza muestral	81
7.41	Ley de los grandes números	81
7.42	Teorema central del límite	81
7.43	Estadísticos y parámetros	82
7.44	Estimación puntual	82
7.45	Sesgo	82
7.46	Error cuadrático medio	83
7.47	Consistencia	83
7.48	Función de verosimilitud	83
7.49	Log-verosimilitud	84
7.50	Estimación por máxima verosimilitud	84
7.51	Ejemplo Bernoulli	84
7.52	Estimación bayesiana	85
7.53	Intervalos de confianza	86
7.54	Pruebas de hipótesis	86
7.55	Relación con clasificación	87
7.56	Relación con regresión logística	87

7.57	Relación con árboles de decisión	87
7.58	Relación con PCA	87
7.59	Conexión con R	88
7.60	Ejemplo integrado de clasificación	88
7.61	Errores frecuentes	89
7.62	Ejercicios conceptuales	90
7.63	Ejercicios de probabilidad	90
7.64	Ejercicio de Bayes	90
7.65	Ejercicio de esperanza y varianza	91
7.66	Ejercicio de máxima verosimilitud	91
7.67	Ejercicio aplicado	91
7.68	Resumen	92
8	Cálculo multivariable y optimización	93
8.1	Introducción	93
8.2	Objetivos	93
8.3	Funciones de varias variables	94
8.4	Superficies de nivel	94
8.5	Derivadas parciales	95
8.6	Derivadas parciales de orden superior	95
8.7	Gradiente	96
8.8	Derivada direccional	96
8.9	Funciones vectoriales	97
8.10	Matriz Jacobiana	97
8.11	Matriz Hessiana	97
8.12	Diferenciales	98
8.13	Regla de la cadena	98
8.14	Ejemplo de regla de la cadena	99
8.15	Derivación matricial básica	99
8.16	Expansión de Taylor de primer orden	100
8.17	Expansión de Taylor de segundo orden	101
8.18	Puntos críticos	101
8.19	Clasificación mediante la Hessiana	101
8.20	Ejemplo de mínimo	102
8.21	Optimización sin restricciones	102
8.22	Funciones convexas	103
8.23	Convexidad estricta	103
8.24	Caracterización mediante el gradiente	103
8.25	Caracterización mediante la Hessiana	104
8.26	Teorema del mínimo global	104
8.27	Funciones cóncavas	104
8.28	Descenso por gradiente	104
8.29	Elección de la tasa de aprendizaje	105
8.30	Criterios de parada	105
8.31	Descenso por gradiente para una función cuadrática	105
8.32	Descenso por gradiente por lotes	106
8.33	Descenso por gradiente estocástico	106
8.34	Mini-lotes	106

8.35	Método de Newton	107
8.36	Método de Newton-Raphson	107
8.37	Problemas con restricciones	107
8.38	Multiplicadores de Lagrange	108
8.39	Ejemplo de Lagrange	108
8.40	Relación con PCA	109
8.41	Restricciones de desigualdad y condiciones KKT	110
8.42	Funciones de pérdida	110
8.42.1	Pérdida cuadrática	111
8.42.2	Pérdida absoluta	111
8.42.3	Pérdida logística	111
8.42.4	Pérdida hinge	111
8.43	Riesgo empírico	111
8.44	Regularización	112
8.45	Relación con regresión lineal	112
8.46	Relación con regresión logística	112
8.47	Relación con redes neuronales	113
8.48	Conexión con R	113
8.49	Ejemplo integrado	114
8.50	Errores frecuentes	114
8.51	Ejercicios conceptuales	115
8.52	Ejercicios de derivación	115
8.53	Ejercicio de regla de la cadena	115
8.54	Ejercicio de descenso por gradiente	116
8.55	Ejercicio de Lagrange	116
8.56	Ejercicio aplicado a regresión	117
8.57	Resumen	117
II	II. Fundamentos del aprendizaje automático	118
9	Formulación matemática del aprendizaje supervisado	119
9.1	Introducción	119
9.2	Objetivos	119
9.3	Espacio de entrada	120
9.4	Espacio de salida	120
9.5	Variable aleatoria conjunta	121
9.6	Muestra de entrenamiento	122
9.7	Función objetivo desconocida	122
9.8	Hipótesis	123
9.9	Espacio de hipótesis	123
9.9.1	Modelos lineales	123
9.9.2	Árboles de decisión	123
9.9.3	Redes neuronales	124
9.10	Parámetros e hiperparámetros	124
9.11	Función de pérdida	124
9.12	Pérdida cuadrática	125
9.13	Pérdida absoluta	125

9.14	Pérdida 0-1	125
9.15	Pérdida logística	125
9.16	Pérdida hinge	126
9.17	Riesgo esperado	126
9.18	Riesgo de Bayes	126
9.19	Riesgo empírico	127
9.20	Minimización del riesgo empírico	127
9.20.1	Regresión lineal	127
9.20.2	Clasificación	127
9.21	Error de entrenamiento	127
9.22	Error de prueba	128
9.23	Generalización	128
9.24	Brecha de generalización	128
9.25	Sobreaajuste	128
9.26	Subajuste	129
9.27	Complejidad del modelo	129
9.28	Ejemplo polinomial	129
9.29	Regularización	130
9.30	Regularización L2	130
9.31	Regularización L1	130
9.32	Sesgo y varianza	131
9.33	Sesgo del modelo	131
9.34	Varianza del modelo	131
9.35	Ruido irreducible	132
9.36	Compromiso entre sesgo y varianza	132
9.37	Error de aproximación	132
9.38	Error de estimación	133
9.39	Selección de modelos	133
9.40	División de datos	133
9.41	Validación cruzada	134
9.42	Clasificación óptima bajo pérdida 0-1	134
9.43	Regresión óptima bajo pérdida cuadrática	134
9.44	Regresión óptima bajo pérdida absoluta	135
9.45	Aprendizaje paramétrico	135
9.46	Aprendizaje no paramétrico	135
9.47	Aprendizaje determinista y probabilístico	136
9.48	Relación con regresión lineal	136
9.49	Relación con regresión logística	136
9.50	Relación con el método de vecinos más cercanos	136
9.51	Relación con árboles	137
9.52	Relación con redes neuronales	137
9.53	Conexión con R	137
9.54	Ejemplo integrado	138
9.55	Errores frecuentes	138
9.56	Ejercicios conceptuales	139
9.57	Ejercicio de riesgo empírico	139
9.58	Ejercicio de clasificación	139
9.59	Ejercicio de regularización	140

9.60 Ejercicio de sesgo y varianza	140
9.61 Ejercicio aplicado	140
9.62 Resumen	141
10 Teoría matemática de la clasificación	142
10.1 Introducción	142
10.2 Objetivos	142
10.3 Formulación de un problema de clasificación	143
10.4 Clasificador	143
10.5 Regiones de decisión	144
10.6 Frontera de decisión	144
10.7 Frontera lineal	144
10.8 Frontera no lineal	145
10.9 Probabilidades posteriores	145
10.10 Regla de clasificación por máxima probabilidad posterior	145
10.11 Función de pérdida general	146
10.12 Riesgo condicional	146
10.13 Regla de Bayes bajo pérdida 0-1	146
10.14 Riesgo de Bayes	147
10.15 Error de Bayes binario	147
10.16 Regla de Bayes con densidades	147
10.17 Funciones discriminantes	148
10.18 Pérdidas asimétricas	148
10.19 Clasificación sensible al costo	148
10.20 Clasificación binaria probabilística	149
10.21 Efecto del umbral	149
10.22 Matriz de confusión	149
10.23 Exactitud	150
10.24 Tasa de error	150
10.25 Sensibilidad	150
10.26 Especificidad	150
10.27 Tasa de falsos positivos	151
10.28 Tasa de falsos negativos	151
10.29 Precisión positiva	151
10.30 Valor predictivo negativo	151
10.31 Medida F1	151
10.32 Exactitud balanceada	152
10.33 Prevalencia	152
10.34 Ejemplo de matriz de confusión	152
10.35 Limitaciones de la exactitud	153
10.36 Curva ROC	153
10.37 Interpretación de la curva ROC	153
10.38 Área bajo la curva	154
10.39 Curva precisión-recall	154
10.40 Calibración	154
10.41 Discriminación y calibración	155
10.42 Función de pérdida logarítmica	155
10.43 Brier score	155

10.44	Clasificación multiclase	155
10.45	Matriz de confusión multiclase	156
10.46	Métricas por clase	156
10.47	Promedio macro	156
10.48	Promedio ponderado	156
10.49	Promedio micro	156
10.50	Estrategia uno contra el resto	157
10.51	Estrategia uno contra uno	157
10.52	Regiones de decisión multiclase	157
10.53	Relación con regresión logística	157
10.54	Relación con el método de vecinos más cercanos	158
10.55	Relación con árboles de decisión	158
10.56	Relación con SVM	158
10.57	Conexión con R	158
10.58	Ejemplo integrado	159
10.59	Errores frecuentes	160
10.60	Ejercicios conceptuales	160
10.61	Ejercicio de matriz de confusión	161
10.62	Ejercicio de pérdidas asimétricas	161
10.63	Ejercicio de regla de Bayes	162
10.64	Ejercicio de umbral	162
10.65	Ejercicio multiclase	162
10.66	Ejercicio aplicado	163
10.67	Resumen	163
11	Evaluación, validación y selección de modelos	164
11.1	Introducción	164
11.2	Objetivos	164
11.3	Error de generalización	165
11.4	Error de entrenamiento	165
11.5	Optimismo de entrenamiento	165
11.6	Conjunto de prueba	166
11.7	División entrenamiento-validación-prueba	166
11.7.1	Entrenamiento	166
11.7.2	Validación	167
11.7.3	Prueba	167
11.8	Proporciones de partición	167
11.9	Partición aleatoria	167
11.10	Partición estratificada	168
11.11	Partición por grupos	168
11.12	Método holdout	168
11.13	Validación cruzada de K pliegues	169
11.14	Interpretación	169
11.15	Sesgo de validación cruzada	170
11.16	Varianza de validación cruzada	170
11.17	Validación cruzada repetida	170
11.18	Leave-one-out	171
11.19	Ventajas y limitaciones de LOOCV	171

11.20Validación cruzada estratificada	171
11.21Validación cruzada agrupada	171
11.22Validación cruzada para series de tiempo	172
11.23Ventana deslizante	172
11.24Bootstrap	172
11.25Probabilidad de exclusión	173
11.26Error out-of-bag	173
11.27Estimador bootstrap del error	173
11.28Estimador .632	174
11.29Bootstrap para incertidumbre	174
11.30Selección de hiperparámetros	174
11.31Búsqueda en rejilla	175
11.32Búsqueda aleatoria	175
11.33Optimización bayesiana	175
11.34Fuga de información	176
11.35Preprocesamiento correcto	176
11.36Pipeline	176
11.37Selección de variables dentro de la validación	177
11.38Validación cruzada anidada	177
11.38.1 Ciclo externo	177
11.38.2 Ciclo interno	177
11.39Sesgo por selección	177
11.40Regla de un error estándar	178
11.41Comparación de modelos	178
11.42Prueba de McNemar	178
11.43Intervalo para error de clasificación	179
11.44Incertidumbre del error cuadrático medio	179
11.45Reproducibilidad	180
11.46Métrica principal	180
11.47Evaluación en regresión	180
11.47.1 Error cuadrático medio	180
11.47.2 Raíz del error cuadrático medio	180
11.47.3 Error absoluto medio	181
11.47.4 Coeficiente de determinación	181
11.48Evaluación en clasificación	181
11.49Conexión con R	181
11.50Ejemplo manual de validación cruzada	182
11.51Ejemplo de fuga de información	182
11.52Diseño recomendado de evaluación	183
11.53Errores frecuentes	183
11.54Ejercicios conceptuales	183
11.55Ejercicio de holdout	184
11.56Ejercicio de validación cruzada	184
11.57Ejercicio bootstrap	184
11.58Ejercicio de selección	184
11.59Ejercicio de fuga de información	185
11.60Ejercicio aplicado	185
11.61Resumen	186

12 Regularización y control de la complejidad	187
12.1 Introducción	187
12.2 Objetivos	187
12.3 Motivación	188
12.4 Problemas de multicolinealidad	188
12.5 Problema penalizado general	189
12.6 Interpretación del parámetro de regularización	189
12.7 Formulación restringida	190
12.8 Regresión ridge	190
12.9 Forma matricial de ridge	190
12.10 Derivación del estimador ridge	191
12.11 Efecto sobre la invertibilidad	191
12.12 Interpretación espectral	192
12.13 Factores de contracción	192
12.14 Sesgo de ridge	192
12.15 Varianza de ridge	193
12.16 Ridge y el compromiso sesgo-varianza	193
12.17 Geometría de ridge	193
12.18 Estandarización	194
12.19 LASSO	194
12.20 Forma restringida de LASSO	194
12.21 No diferenciabilidad	195
12.22 Subgradiente	195
12.23 Operador soft-thresholding	196
12.24 Caso ortonormal	196
12.25 Geometría de LASSO	196
12.26 Selección de variables	197
12.27 Limitaciones de LASSO	197
12.28 Elastic net	197
12.29 Casos particulares	198
12.30 Ventaja de elastic net	198
12.31 Caminos de regularización	198
12.32 Valor máximo del parámetro de regularización	199
12.33 Selección del parámetro de regularización	199
12.34 Ridge como estimación bayesiana	199
12.35 LASSO como estimación bayesiana	200
12.36 Regularización en regresión logística	200
12.37 Regularización en redes neuronales	200
12.37.1 Weight decay	200
12.37.2 Dropout	200
12.37.3 Early stopping	200
12.37.4 Data augmentation	201
12.38 Regularización en árboles	201
12.39 Regularización explícita e implícita	201
12.40 Grados de libertad efectivos	201
12.41 Relación con la estabilidad	202
12.42 Variables categóricas	202
12.43 Group LASSO	202

12.44	Regularización adaptativa	203
12.45	Regularización y causalidad	203
12.46	Conexión con R	203
12.47	Ejemplo numérico ridge	204
12.48	Comparación conceptual	205
12.49	Errores frecuentes	205
12.50	Ejercicios conceptuales	206
12.51	Ejercicio de derivación ridge	206
12.52	Ejercicio de soft-thresholding	206
12.53	Ejercicio de validación	207
12.54	Ejercicio comparativo	207
12.55	Ejercicio aplicado	207
12.56	Resumen	208
III	III. Modelos de regresión	209
13	Regresión lineal simple	210
13.1	Introducción	210
13.2	Objetivos	210
13.3	Formulación del modelo	210
13.4	Interpretación de los parámetros	211
13.4.1	Intercepto	211
13.4.2	Pendiente	211
13.5	Supuestos clásicos	212
13.5.1	Linealidad	212
13.5.2	Media cero de los errores	212
13.5.3	Varianza constante	212
13.5.4	Independencia	212
13.5.5	Normalidad	212
13.6	Función de regresión	213
13.7	Criterio de mínimos cuadrados	213
13.8	Derivación de las ecuaciones normales	213
13.9	Estimador de la pendiente	214
13.10	Estimador del intercepto	214
13.11	Relación con covarianza y varianza	215
13.12	Interpretación geométrica	215
13.13	Propiedades de los residuos	216
13.14	Insensibilidad de la pendiente	216
13.15	Insensibilidad del intercepto	217
13.16	Varianza de la pendiente	217
13.17	Varianza del intercepto	217
13.18	Covarianza entre estimadores	218
13.19	Teorema de Gauss-Markov	218
13.20	Estimación de la varianza del error	218
13.21	Error estándar residual	219
13.22	Distribución de los estimadores	219
13.23	Error estándar de la pendiente	219

13.24	Error estándar del intercepto	219
13.25	Prueba de hipótesis para la pendiente	219
13.26	Interpretación correcta	220
13.27	Intervalo de confianza para la pendiente	220
13.28	Intervalo de confianza para el intercepto	220
13.29	Estimación de la respuesta media	221
13.30	Intervalo de confianza para la media	221
13.31	Intervalo de predicción	221
13.32	Descomposición de la variabilidad	222
13.33	Coefficiente de determinación	222
13.34	Interpretación del coeficiente de determinación	222
13.35	Tabla ANOVA	223
13.36	Residuos	223
13.37	Residuos estandarizados	223
13.38	Matriz sombrero	224
13.39	Apalancamiento	224
13.40	Varianza de los residuos	224
13.41	Residuos studentizados	225
13.42	Distancia de Cook	225
13.43	Diagnóstico de linealidad	225
13.44	Diagnóstico de homocedasticidad	225
13.45	Diagnóstico de normalidad	226
13.46	Diagnóstico de independencia	226
13.47	Heterocedasticidad	226
13.48	Errores estándar robustos	226
13.49	Transformaciones	227
13.50	Extrapolación	227
13.51	Correlación y regresión	227
13.52	Regresión y causalidad	228
13.53	Relación con máxima verosimilitud	228
13.54	Relación con aprendizaje supervisado	228
13.55	Conexión con R	229
13.56	Ejemplo numérico	230
13.57	Errores frecuentes	231
13.58	Ejercicios conceptuales	231
13.59	Ejercicio de estimación	231
13.60	Ejercicio de inferencia	232
13.61	Ejercicio de ANOVA	232
13.62	Ejercicio de predicción	233
13.63	Ejercicio de diagnóstico	233
13.64	Ejercicio aplicado	233
13.65	Resumen	234
14	Regresión lineal múltiple	235
15	Regresión logística	236

IV IV. Métodos de clasificación	237
16 Vecinos más cercanos	238
17 Árboles de decisión	239
18 Bosques aleatorios	240
19 Máquinas de vectores de soporte	241
20 Redes neuronales artificiales	242
V V. Aprendizaje no supervisado	243
21 Análisis de componentes principales	244
22 Agrupamiento k-means	245
23 Agrupamiento jerárquico	246
24 Reglas de asociación	247
VI VI. Temas avanzados	248
25 Teoría de generalización	249
26 Series de tiempo y aprendizaje automático	250
Referencias	251

1 Fundamentos Matemáticos del Aprendizaje Automático

Teoría, demostraciones y formulación rigurosa

Bienvenida

Este libro desarrolla los fundamentos matemáticos de los principales métodos de aprendizaje automático. Su propósito es explicar no solamente cómo se ejecutan los algoritmos, sino por qué funcionan, cuáles son sus supuestos y qué propiedades justifican su utilización.

La obra complementa el libro práctico *Aprendizaje y Clasificación Automática con R*. Ambos volúmenes pueden estudiarse por separado, aunque su lectura conjunta permite conectar la formulación matemática, el algoritmo y su implementación computacional.

Objetivos generales

Al finalizar el libro, el lector podrá:

- representar formalmente problemas de aprendizaje automático;
- comprender los fundamentos algebraicos, probabilísticos y estadísticos de los modelos;
- derivar los principales algoritmos de regresión, clasificación y agrupamiento;
- interpretar funciones de pérdida, criterios de optimización y métodos de regularización;
- analizar supuestos, limitaciones y propiedades de generalización;
- relacionar la teoría matemática con implementaciones en R.

2 Presentación

El aprendizaje automático se ha convertido en una de las áreas más importantes de la ciencia de datos, la inteligencia artificial, la estadística y la computación moderna. Sus métodos permiten construir sistemas capaces de identificar patrones, realizar predicciones, clasificar observaciones, descubrir estructuras ocultas y apoyar la toma de decisiones a partir de datos.

Sin embargo, el uso adecuado de estos métodos requiere algo más que aprender a ejecutar funciones en un lenguaje de programación. Detrás de cada algoritmo existen conceptos matemáticos que determinan su funcionamiento, sus alcances, sus limitaciones y las condiciones bajo las cuales sus resultados pueden considerarse confiables.

El presente libro tiene como propósito desarrollar, de manera rigurosa y progresiva, los fundamentos matemáticos de los principales métodos de aprendizaje automático. Se estudian los conceptos de álgebra lineal, probabilidad, estadística, cálculo multivariable y optimización que permiten formular y comprender los algoritmos de regresión, clasificación, reducción de dimensionalidad, agrupamiento y aprendizaje basado en reglas.

La obra ha sido concebida como el complemento teórico del libro *Aprendizaje y Clasificación Automática con R*. Mientras que aquel volumen se orienta principalmente a la aplicación de los algoritmos mediante datos reales, programación en R, visualización e interpretación de resultados, este segundo volumen se concentra en su formulación matemática, sus derivaciones, propiedades y fundamentos teóricos.

Ambos libros pueden estudiarse de manera independiente. No obstante, su utilización conjunta permitirá al lector relacionar tres niveles fundamentales del aprendizaje automático:

1. la formulación matemática del problema;
2. el procedimiento algorítmico utilizado para resolverlo;
3. su implementación computacional con datos reales.

El contenido se presenta de forma gradual. Cada capítulo comienza con una explicación conceptual del problema, seguida de la notación matemática necesaria, definiciones formales, proposiciones, teoremas, demostraciones y derivaciones. Posteriormente se desarrollan ejemplos numéricos manuales y se establece la conexión con los algoritmos estudiados en el volumen práctico.

3 Introducción

El aprendizaje automático estudia métodos capaces de construir reglas de predicción, clasificación o descripción a partir de datos. Desde el punto de vista matemático, aprender significa seleccionar una función dentro de una familia de modelos utilizando información contenida en una muestra.

Sea un conjunto de datos

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n,$$

donde cada vector $\mathbf{x}_i \in \mathbb{R}^p$ contiene las características de la observación i y y_i representa su respuesta.

El objetivo general del aprendizaje supervisado consiste en construir una función

$$f : \mathcal{X} \longrightarrow \mathcal{Y}$$

que produzca predicciones adecuadas para observaciones nuevas.

La construcción de esta función requiere responder preguntas fundamentales:

- ¿cómo se representa matemáticamente la información?
- ¿qué significa que dos observaciones sean semejantes?
- ¿cómo se mide el error de un modelo?
- ¿cómo se determina el mejor conjunto de parámetros?
- ¿qué condiciones permiten confiar en una predicción?
- ¿cómo se evita que un modelo memorice los datos de entrenamiento?

Estas preguntas requieren herramientas de álgebra lineal, probabilidad, estadística, cálculo y optimización. Los primeros capítulos del libro desarrollan dichas herramientas antes de aplicarlas a los principales algoritmos de aprendizaje automático.

4 Notación general

En esta obra se utilizarán las siguientes convenciones:

- Los escalares se representan mediante letras minúsculas: x, y, α, β .
- Los vectores se representan en negritas minúsculas: $\mathbf{x}, \mathbf{y}, \beta$.
- Las matrices se representan en negritas mayúsculas: $\mathbf{X}, \mathbf{A}, \Sigma$.
- Los conjuntos se representan mediante letras caligráficas o mayúsculas: $\mathcal{X}, \mathcal{Y}, \mathcal{D}$.
- El conjunto de los números reales se denota por $\mathbb{R}$.
- El espacio vectorial real de dimensión p se denota por $\mathbb{R}^p$.
- La transpuesta de una matriz o vector se representa mediante el superíndice T.
- La esperanza matemática se denota por $\mathbb{E}$.
- La varianza se denota por Var .
- La covarianza se denota por Cov .
- La norma euclidiana se denota por $\|\cdot\|_2$.
- La función indicadora se denota por $\mathbb{I}(\cdot)$.

Parte I

I. Fundamentos matemáticos

5 Lenguaje matemático, conjuntos y funciones

5.1. Introducción

El aprendizaje automático se construye sobre objetos matemáticos bien definidos: conjuntos de datos, espacios de características, funciones de predicción, reglas de decisión y medidas de error. Antes de estudiar algoritmos concretos, es necesario establecer un lenguaje común que permita expresar estos elementos con precisión.

En este capítulo se revisan los conceptos de conjuntos, relaciones y funciones, y se muestra cómo aparecen de manera natural en la formulación de problemas de aprendizaje automático.

5.2. Objetivos

Al finalizar el capítulo, el lector podrá:

1. reconocer y utilizar la notación básica de conjuntos;
2. distinguir entre elemento, subconjunto, unión, intersección y complemento;
3. interpretar el producto cartesiano;
4. definir formalmente una función;
5. distinguir dominio, codominio e imagen;
6. identificar funciones inyectivas, suprayectivas y biyectivas;
7. utilizar funciones indicadoras;
8. representar formalmente conjuntos de entrenamiento;
9. distinguir matemáticamente entre regresión y clasificación.

5.3. Conjuntos numéricos

Los conjuntos numéricos más utilizados son:

$$\mathbb{N} = \{1, 2, 3, \dots\},$$

$$\mathbb{Z} = \{\dots, -2, -1, 0, 1, 2, \dots\},$$

$$\mathbb{Q} = \left\{ \frac{a}{b} : a, b \in \mathbb{Z}, b \neq 0 \right\},$$

y

$$\mathbb{R},$$

que representa el conjunto de los números reales.

En aprendizaje automático también se utiliza frecuentemente el espacio

$$\mathbb{R}^p = \{(x_1, \dots, x_p) : x_j \in \mathbb{R}\}.$$

Cada elemento de $\mathbb{R}^p$ es un vector con p componentes.

Ejemplo 5.1. Una observación ambiental puede representarse mediante

$$\mathbf{x} = \begin{pmatrix} 42.3 \\ 18.7 \\ 61.0 \end{pmatrix} \in \mathbb{R}^3,$$

donde las componentes podrían corresponder a concentración de partículas, temperatura y humedad.

5.4. Concepto de conjunto

Definición 5.1. Un **conjunto** es una colección bien definida de objetos. Los objetos que forman parte del conjunto se denominan elementos.

Si x pertenece a un conjunto A , se escribe

$$x \in A.$$

Si no pertenece, se escribe

$$x \notin A.$$

Por ejemplo, si

$$A = \{2, 4, 6, 8\},$$

entonces

$$4 \in A$$

y

$$5 \notin A.$$

5.5. Formas de especificar conjuntos

Un conjunto puede describirse por extensión o por comprensión.

5.5.1. Por extensión

Se enumeran sus elementos:

$$A = \{1, 2, 3, 4, 5\}.$$

5.5.2. Por comprensión

Se especifica una propiedad que deben satisfacer sus elementos:

$$A = \{x \in \mathbb{N} : 1 \leq x \leq 5\}.$$

La expresión después de los dos puntos se interpreta como “tal que”.

5.6. Igualdad de conjuntos

Dos conjuntos A y B son iguales si contienen exactamente los mismos elementos:

$$A = B \iff (\forall x)(x \in A \iff x \in B).$$

El orden de los elementos no importa. Por ejemplo,

$$\{1, 2, 3\} = \{3, 1, 2\}.$$

La repetición tampoco modifica un conjunto:

$$\{1, 1, 2, 3\} = \{1, 2, 3\}.$$

5.7. Subconjuntos

Definición 5.2. Se dice que A es un subconjunto de B si cada elemento de A también pertenece a B .

Formalmente,

$$A \subseteq B \iff (\forall x)(x \in A \Rightarrow x \in B).$$

Si además $A \neq B$, entonces A es un subconjunto propio de B .

Ejemplo 5.2. Sean

$$A = \{1, 2\}, \quad B = \{1, 2, 3, 4\}.$$

Entonces

$$A \subseteq B.$$

5.8. Conjunto vacío

El conjunto que no contiene elementos se denomina conjunto vacío y se denota por

$$\emptyset.$$

El conjunto vacío es subconjunto de todo conjunto:

$$\emptyset \subseteq A.$$

5.9. Operaciones entre conjuntos

5.9.1. Unión

La unión de A y B es el conjunto de elementos que pertenecen a A , a B o a ambos:

$$A \cup B = \{x : x \in A \text{ o } x \in B\}.$$

5.9.2. Intersección

La intersección contiene los elementos comunes:

$$A \cap B = \{x : x \in A \text{ y } x \in B\}.$$

5.9.3. Diferencia

La diferencia $A \setminus B$ contiene los elementos de A que no pertenecen a B :

$$A \setminus B = \{x : x \in A \text{ y } x \notin B\}.$$

5.9.4. Complemento

Si U es el conjunto universal, el complemento de A es

$$A^c = U \setminus A.$$

Ejemplo 5.3. Sean

$$A = \{1, 2, 3, 4\}, \quad B = \{3, 4, 5, 6\}.$$

Entonces

$$A \cup B = \{1, 2, 3, 4, 5, 6\},$$

$$A \cap B = \{3, 4\},$$

$$A \setminus B = \{1, 2\},$$

y

$$B \setminus A = \{5, 6\}.$$

5.10. Propiedades fundamentales

Para cualesquiera conjuntos A , B y C se cumplen:

5.10.1. Conmutatividad

$$A \cup B = B \cup A,$$

$$A \cap B = B \cap A.$$

5.10.2. Asociatividad

$$(A \cup B) \cup C = A \cup (B \cup C),$$

$$(A \cap B) \cap C = A \cap (B \cap C).$$

5.10.3. Distributividad

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C),$$

$$A \cup (B \cap C) = (A \cup B) \cap (A \cup C).$$

5.10.4. Leyes de De Morgan

$$(A \cup B)^c = A^c \cap B^c,$$

$$(A \cap B)^c = A^c \cup B^c.$$

Estas propiedades serán importantes posteriormente en probabilidad, reglas de asociación y teoría de clasificación.

5.11. Producto cartesiano

Definición 5.3. El producto cartesiano de dos conjuntos A y B se define como

$$A \times B = \{(a, b) : a \in A, b \in B\}.$$

Si

$$A = \{1, 2\}, \quad B = \{a, b\},$$

entonces

$$A \times B = \{(1, a), (1, b), (2, a), (2, b)\}.$$

El producto cartesiano permite representar observaciones con varias características. En general,

$$\mathbb{R}^p = \underbrace{\mathbb{R} \times \cdots \times \mathbb{R}}_{p \text{ veces}}.$$

5.12. Relaciones

Definición 5.4. Una relación entre los conjuntos A y B es cualquier subconjunto de $A \times B$.

Una relación R puede escribirse como

$$R \subseteq A \times B.$$

Si $(a, b) \in R$, se dice que a está relacionado con b .

En clasificación, una muestra etiquetada puede verse como un conjunto de pares ordenados que relaciona cada observación con una clase.

5.13. Funciones

Definición 5.5. Una función f de un conjunto A a un conjunto B es una regla que asigna a cada elemento de A exactamente un elemento de B .

Se escribe

$$f : A \longrightarrow B.$$

El conjunto A es el dominio y B es el codominio.

Si $x \in A$, el valor asignado se denota por $f(x)$.

Ejemplo 5.4. Sea

$$f : \mathbb{R} \longrightarrow \mathbb{R}$$

definida por

$$f(x) = 2x + 1.$$

Entonces

$$f(3) = 7.$$

5.14. Dominio, codominio e imagen

Para una función

$$f : A \rightarrow B,$$

el dominio es A y el codominio es B .

La imagen de f es

$$\text{Im}(f) = \{f(x) : x \in A\}.$$

Siempre se cumple

$$\text{Im}(f) \subseteq B.$$

El codominio y la imagen no necesariamente coinciden.

5.15. Imagen e imagen inversa de conjuntos

Si $C \subseteq A$, la imagen de C es

$$f(C) = \{f(x) : x \in C\}.$$

Si $D \subseteq B$, la imagen inversa de D es

$$f^{-1}(D) = \{x \in A : f(x) \in D\}.$$

La notación $f^{-1}(D)$ no exige que f sea invertible.

5.16. Funciones inyectivas, suprayectivas y biyectivas

5.16.1. Función inyectiva

Definición 5.6. Una función $f : A \rightarrow B$ es inyectiva si elementos distintos del dominio tienen imágenes distintas.

Equivalentemente,

$$f(x_1) = f(x_2) \Rightarrow x_1 = x_2.$$

5.16.2. Función suprayectiva

Definición 5.7. Una función $f : A \rightarrow B$ es suprayectiva si cada elemento de B es imagen de al menos un elemento de A .

Formalmente,

$$(\forall y \in B)(\exists x \in A) \quad f(x) = y.$$

5.16.3. Función biyectiva

Definición 5.8. Una función es biyectiva si es simultáneamente inyectiva y suprayectiva.

Las funciones biyectivas poseen una función inversa.

5.17. Composición de funciones

Sean

$$f : A \rightarrow B$$

y

$$g : B \rightarrow C.$$

La composición de g con f se define como

$$(g \circ f)(x) = g(f(x)).$$

La composición es esencial en redes neuronales, donde cada capa aplica una transformación a la salida de la capa anterior.

Ejemplo 5.5. Sean

$$f(x) = 2x + 1, \quad g(x) = x^2.$$

Entonces

$$(g \circ f)(x) = (2x + 1)^2.$$

En cambio,

$$(f \circ g)(x) = 2x^2 + 1.$$

En general,

$$g \circ f \neq f \circ g.$$

5.18. Función indicadora

Definición 5.9. Sea A un conjunto. La función indicadora de A se define por

$$\mathbb{I}_A(x) = \begin{cases} 1, & x \in A, \\ 0, & x \notin A. \end{cases}$$

También se utiliza la notación

$$\mathbb{I}(x \in A).$$

En clasificación, la función indicadora permite contar observaciones de una clase:

$$n_k = \sum_{i=1}^n \mathbb{I}(y_i = k).$$

La proporción de observaciones de la clase k es

$$\hat{p}_k = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(y_i = k).$$

Esta expresión aparecerá en árboles de decisión, matrices de confusión y medidas de evaluación.

5.19. Sumatorias y productorias

La sumatoria

$$\sum_{i=1}^n x_i$$

representa

$$x_1 + x_2 + \cdots + x_n.$$

La productoria

$$\prod_{i=1}^n x_i$$

representa

$$x_1 x_2 \cdots x_n.$$

La media aritmética de una muestra es

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

La productoria será especialmente importante en funciones de verosimilitud.

5.20. Representación formal de datos

Sea

$$\mathcal{X} \subseteq \mathbb{R}^p$$

el espacio de características y sea $\mathcal{Y}$ el espacio de respuestas.

Un conjunto de datos supervisado se representa como

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n \subseteq \mathcal{X} \times \mathcal{Y}.$$

Cada vector

$$\mathbf{x}_i = \begin{pmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{pmatrix}$$

contiene los valores de las p características de la observación i .

La matriz de datos se representa como

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix} \in \mathbb{R}^{n \times p}.$$

El vector de respuestas es

$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}.$$

5.21. Regresión y clasificación

5.21.1. Regresión

En un problema de regresión, la respuesta es numérica:

$$\mathcal{Y} \subseteq \mathbb{R}.$$

Se busca una función

$$f : \mathcal{X} \rightarrow \mathbb{R}.$$

Por ejemplo, estimar la concentración de un contaminante:

$$f(\mathbf{x}) = \hat{y}.$$

5.21.2. Clasificación binaria

En clasificación binaria,

$$\mathcal{Y} = \{0, 1\}$$

o bien

$$\mathcal{Y} = \{-1, 1\}.$$

La función de clasificación tiene la forma

$$f : \mathcal{X} \rightarrow \{0, 1\}.$$

5.21.3. Clasificación multiclase

En clasificación multiclase,

$$\mathcal{Y} = \{1, 2, \dots, K\}.$$

Entonces

$$f : \mathcal{X} \rightarrow \{1, \dots, K\}.$$

5.22. Función objetivo desconocida

En aprendizaje supervisado se supone que existe una relación entre las características y la respuesta. Puede representarse idealmente mediante una función desconocida

$$f^* : \mathcal{X} \rightarrow \mathcal{Y}.$$

Los datos satisfacen aproximadamente

$$y_i = f^*(\mathbf{x}_i) + \varepsilon_i$$

en regresión, donde ε_i representa variación aleatoria o error.

El objetivo del aprendizaje consiste en construir una aproximación

$$\hat{f} \approx f^*.$$

5.23. Ejemplo integrado

Supóngase que se desea clasificar la calidad del aire utilizando tres variables:

1. concentración de partículas PM10;
2. temperatura;
3. humedad relativa.

El espacio de características es

$$\mathcal{X} \subseteq \mathbb{R}^3.$$

La respuesta puede definirse como

$$\mathcal{Y} = \{\text{buena, regular, mala}\}.$$

Una observación es

$$\mathbf{x}_i = \begin{pmatrix} \text{PM10}_i \\ \text{temperatura}_i \\ \text{humedad}_i \end{pmatrix}.$$

El conjunto de entrenamiento es

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n.$$

El clasificador buscado es una función

$$\hat{f} : \mathbb{R}^3 \rightarrow \{\text{buena, regular, mala}\}.$$

5.24. Conexión con R

En R, una tabla de datos puede interpretarse como una representación computacional de la matriz $\mathbf{X}$ y del vector $\mathbf{y}$.

```
datos <- data.frame(  
  pm10 = c(38, 75, 112, 46),  
  temperatura = c(19, 23, 27, 21),  
  humedad = c(64, 52, 43, 58),  
  calidad = c("buena", "regular", "mala", "buena")  
)  
  
X <- as.matrix(datos[, c("pm10", "temperatura", "humedad")])  
y <- datos$calidad
```

Matemáticamente,

$$\mathbf{X} \in \mathbb{R}^{4 \times 3}$$

y

$$\mathbf{y} = \begin{pmatrix} \text{buena} \\ \text{regular} \\ \text{mala} \\ \text{buena} \end{pmatrix}.$$

5.25. Errores frecuentes

1. Confundir un elemento con un subconjunto.
2. Suponer que el codominio y la imagen siempre son iguales.
3. Confundir $f^{-1}(D)$ con la función inversa.
4. Olvidar que una función debe asignar exactamente una salida a cada entrada.
5. Considerar que el orden de los elementos cambia un conjunto.
6. Confundir una observación $\mathbf{x}_i$ con toda la matriz $\mathbf{X}$.
7. Suponer que toda clasificación utiliza únicamente las etiquetas 0 y 1.

5.26. Ejercicios

5.26.1. Ejercicios conceptuales

1. Explique la diferencia entre $x \in A$ y $\{x\} \subseteq A$.
2. Explique la diferencia entre dominio, codominio e imagen.
3. ¿Por qué una función de clasificación puede considerarse una regla de decisión?
4. ¿Qué diferencia existe entre $\mathbb{R}^p$ y $\mathbb{R}^{n \times p}$?
5. ¿Por qué el conjunto de entrenamiento es un subconjunto de $\mathcal{X} \times \mathcal{Y}$?

5.26.2. Ejercicios de conjuntos

Sean

$$A = \{1, 2, 3, 4, 5\}$$

y

$$B = \{4, 5, 6, 7\}.$$

Determine:

1. $A \cup B$;
2. $A \cap B$;
3. $A \setminus B$;
4. $B \setminus A$.

5.26.3. Ejercicios de funciones

Sea

$$f : \mathbb{R} \rightarrow \mathbb{R}, \quad f(x) = 3x - 2.$$

1. Calcule $f(0)$, $f(2)$ y $f(-1)$.
2. Determine la imagen del conjunto $\{0, 1, 2\}$.
3. Determine $f^{-1}(\{1, 4\})$.
4. Analice si f es inyectiva.
5. Analice si f es suprayectiva.

5.26.4. Ejercicio de clasificación

Considere las observaciones:

$$\mathbf{x}_1 = (20, 60), \quad \mathbf{x}_2 = (45, 48), \quad \mathbf{x}_3 = (80, 35),$$

con etiquetas

$$y_1 = \text{baja}, \quad y_2 = \text{media}, \quad y_3 = \text{alta}.$$

1. Identifique $\mathcal{X}$ y $\mathcal{Y}$.
2. Escriba formalmente el conjunto de entrenamiento.
3. Construya la matriz $\mathbf{X}$.
4. Construya el vector $\mathbf{y}$.
5. Escriba el tipo de función que representaría al clasificador.

5.27. Resumen

En este capítulo se estableció el lenguaje matemático básico del libro. Se definieron conjuntos, subconjuntos, operaciones entre conjuntos, productos cartesianos, relaciones y funciones. También se introdujeron dominio, codominio, imagen, composición y función indicadora.

Finalmente, se formuló un conjunto de datos supervisado como

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n \subseteq \mathcal{X} \times \mathcal{Y},$$

y se distinguieron formalmente los problemas de regresión y clasificación. Esta notación será utilizada en todos los capítulos posteriores.

6 Álgebra lineal para aprendizaje automático

6.1. Introducción

El álgebra lineal constituye uno de los lenguajes fundamentales del aprendizaje automático. Los conjuntos de datos se representan mediante vectores y matrices; los modelos lineales utilizan combinaciones lineales; el análisis de componentes principales depende de valores y vectores propios; las redes neuronales realizan sucesivas transformaciones matriciales; y numerosos algoritmos se formulan como problemas de proyección, factorización u optimización en espacios vectoriales.

Este capítulo desarrolla los conceptos esenciales de álgebra lineal que se utilizarán a lo largo del libro. El objetivo no es presentar únicamente reglas de cálculo, sino explicar el significado geométrico y estadístico de cada operación.

6.2. Objetivos

Al finalizar el capítulo, el lector podrá:

1. distinguir escalares, vectores y matrices;
2. realizar operaciones básicas con vectores y matrices;
3. interpretar una combinación lineal;
4. analizar independencia y dependencia lineal;
5. comprender los conceptos de espacio vectorial, subespacio, base y dimensión;
6. calcular y utilizar productos internos y normas;
7. interpretar ortogonalidad y proyección;
8. representar sistemas de ecuaciones mediante matrices;
9. comprender rango, espacio columna y espacio nulo;
10. interpretar valores y vectores propios;
11. comprender la descomposición espectral;
12. reconocer la función de la descomposición en valores singulares;
13. relacionar estos conceptos con algoritmos de aprendizaje automático.

6.3. Escalares

Definición 6.1. Un **escalar** es un elemento de un campo numérico, normalmente el conjunto de los números reales $\mathbb{R}$.

Los escalares se representan mediante letras minúsculas:

$$a, \quad b, \quad x, \quad \alpha, \quad \beta.$$

Ejemplos de escalares en aprendizaje automático son:

- una observación individual;
- un coeficiente de regresión;
- una tasa de aprendizaje;
- una probabilidad;
- una función de pérdida;
- una distancia entre dos observaciones.

6.4. Vectores

Definición 6.2. Un **vector** de dimensión p es una lista ordenada de p escalares.

Un vector columna se escribe como

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{pmatrix} \in \mathbb{R}^p.$$

Su transpuesta es un vector fila:

$$\mathbf{x}^T = (x_1 \quad x_2 \quad \cdots \quad x_p).$$

Ejemplo 6.1. Una observación ambiental con concentración de PM10, temperatura y humedad puede representarse mediante

$$\mathbf{x} = \begin{pmatrix} 52.4 \\ 23.1 \\ 47.0 \end{pmatrix}.$$

En este caso,

$$\mathbf{x} \in \mathbb{R}^3.$$

6.5. Igualdad de vectores

Dos vectores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ son iguales si todas sus componentes correspondientes son iguales:

$$\mathbf{x} = \mathbf{y} \iff x_j = y_j \quad \text{para todo } j = 1, \dots, p.$$

6.6. Suma de vectores

Sean

$$\mathbf{x} = \begin{pmatrix} x_1 \\ \vdots \\ x_p \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_p \end{pmatrix}.$$

La suma se define componente a componente:

$$\mathbf{x} + \mathbf{y} = \begin{pmatrix} x_1 + y_1 \\ \vdots \\ x_p + y_p \end{pmatrix}.$$

Ejemplo 6.2. Si

$$\mathbf{x} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} 3 \\ 4 \end{pmatrix},$$

entonces

$$\mathbf{x} + \mathbf{y} = \begin{pmatrix} 5 \\ 5 \end{pmatrix}.$$

6.7. Multiplicación por un escalar

Si $\alpha \in \mathbb{R}$ y $\mathbf{x} \in \mathbb{R}^p$, entonces

$$\alpha \mathbf{x} = \begin{pmatrix} \alpha x_1 \\ \vdots \\ \alpha x_p \end{pmatrix}.$$

Geoméricamente, la multiplicación por un escalar modifica la longitud del vector y, si $\alpha < 0$, también invierte su dirección.

6.8. Combinaciones lineales

Definición 6.3. Una **combinación lineal** de los vectores $\mathbf{v}_1, \dots, \mathbf{v}_k$ es cualquier vector de la forma

$$\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k,$$

donde $\alpha_1, \dots, \alpha_k \in \mathbb{R}$.

Las combinaciones lineales aparecen en prácticamente todos los modelos lineales.

Por ejemplo, en regresión lineal múltiple,

$$\hat{y} = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p.$$

La predicción es una combinación lineal de las características.

6.9. Combinación convexa

Una combinación lineal se denomina convexa si

$$\alpha_j \geq 0$$

para todo j , y

$$\sum_{j=1}^k \alpha_j = 1.$$

En ese caso,

$$\mathbf{z} = \sum_{j=1}^k \alpha_j \mathbf{v}_j$$

se encuentra dentro de la envolvente convexa de los vectores.

Este concepto será importante en optimización y teoría de clasificación.

6.10. Independencia lineal

Definición 6.4. Los vectores $\mathbf{v}_1, \dots, \mathbf{v}_k$ son linealmente independientes si la ecuación

$$\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k = \mathbf{0}$$

implica

$$\alpha_1 = \dots = \alpha_k = 0.$$

Si existe una solución no trivial, los vectores son linealmente dependientes.

Ejemplo 6.3. Los vectores

$$\mathbf{v}_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad \mathbf{v}_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

son linealmente independientes.

En cambio,

$$\mathbf{v}_3 = \begin{pmatrix} 2 \\ 4 \end{pmatrix}, \quad \mathbf{v}_4 = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$$

son linealmente dependientes porque

$$\mathbf{v}_3 = 2\mathbf{v}_4.$$

6.11. Espacios vectoriales

Definición 6.5. Un **espacio vectorial** sobre $\mathbb{R}$ es un conjunto de objetos llamados vectores, equipado con operaciones de suma y multiplicación por escalares que satisfacen ciertas propiedades algebraicas.

El ejemplo principal es $\mathbb{R}^p$.

Las propiedades fundamentales incluyen:

1. cerradura bajo la suma;
2. asociatividad;
3. conmutatividad;
4. existencia del vector cero;
5. existencia del inverso aditivo;
6. cerradura bajo multiplicación por escalares;
7. distributividad;
8. compatibilidad de escalares;
9. identidad escalar.

6.12. Subespacios

Definición 6.6. Un subconjunto W de un espacio vectorial V es un **subespacio vectorial** si:

1. contiene al vector cero;
2. es cerrado bajo la suma;
3. es cerrado bajo la multiplicación por escalares.

Por ejemplo, el conjunto

$$W = \left\{ \begin{pmatrix} x \\ 2x \end{pmatrix} : x \in \mathbb{R} \right\}$$

es un subespacio de $\mathbb{R}^2$.

6.13. Espacio generado

Definición 6.7. El espacio generado por los vectores $\mathbf{v}_1, \dots, \mathbf{v}_k$ es el conjunto de todas sus combinaciones lineales.

Se denota por

$$\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\}.$$

Por ejemplo,

$$\text{span}\left\{\begin{pmatrix} 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \end{pmatrix}\right\} = \mathbb{R}^2.$$

6.14. Base y dimensión

Definición 6.8. Una **base** de un espacio vectorial V es un conjunto de vectores linealmente independientes que genera todo el espacio.

La base canónica de $\mathbb{R}^p$ es

$$\mathbf{e}_1, \dots, \mathbf{e}_p,$$

donde

$$\mathbf{e}_1 = \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}, \quad \mathbf{e}_2 = \begin{pmatrix} 0 \\ 1 \\ \vdots \\ 0 \end{pmatrix}, \quad \dots$$

La dimensión de un espacio vectorial es el número de vectores de cualquier base.

Por tanto,

$$\dim(\mathbb{R}^p) = p.$$

6.15. Matrices

Definición 6.9. Una **matriz** de dimensión $n \times p$ es un arreglo rectangular de números con n filas y p columnas.

Se escribe

$$\mathbf{A} = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1p} \\ a_{21} & a_{22} & \cdots & a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{np} \end{pmatrix} \in \mathbb{R}^{n \times p}.$$

En aprendizaje automático, una matriz de datos se representa habitualmente mediante

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

donde:

- n es el número de observaciones;
- p es el número de características.

6.16. Filas y columnas

La fila i de $\mathbf{X}$ representa la observación i :

$$\mathbf{x}_i^T = (x_{i1} \quad \cdots \quad x_{ip}).$$

La columna j representa la característica j :

$$\mathbf{x}_{\cdot j} = \begin{pmatrix} x_{1j} \\ \vdots \\ x_{nj} \end{pmatrix}.$$

6.17. Matrices especiales

6.17.1. Matriz cero

$$\mathbf{0} = \begin{pmatrix} 0 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 0 \end{pmatrix}.$$

6.17.2. Matriz identidad

La matriz identidad de orden p es

$$\mathbf{I}_p = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{pmatrix}.$$

Cumple

$$\mathbf{I}_p \mathbf{x} = \mathbf{x}.$$

6.17.3. Matriz diagonal

Una matriz diagonal tiene ceros fuera de la diagonal principal:

$$\mathbf{D} = \text{diag}(d_1, \dots, d_p).$$

6.17.4. Matriz simétrica

Definición 6.10. Una matriz cuadrada $\mathbf{A}$ es simétrica si

$$\mathbf{A}^\top = \mathbf{A}.$$

Las matrices de covarianza son simétricas.

6.18. Suma de matrices

Si

$$\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times p},$$

entonces

$$\mathbf{A} + \mathbf{B} = (a_{ij} + b_{ij}).$$

La suma solamente está definida cuando ambas matrices tienen las mismas dimensiones.

6.19. Multiplicación de una matriz por un escalar

Si $\alpha \in \mathbb{R}$, entonces

$$\alpha \mathbf{A} = (\alpha a_{ij}).$$

6.20. Producto matricial

Sean

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

y

$$\mathbf{B} \in \mathbb{R}^{p \times m}.$$

El producto

$$\mathbf{C} = \mathbf{AB}$$

es una matriz de dimensión $n \times m$, cuyos elementos son

$$c_{ij} = \sum_{k=1}^p a_{ik} b_{kj}.$$

Ejemplo 6.4. Sean

$$\mathbf{A} = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}, \quad \mathbf{B} = \begin{pmatrix} 2 & 0 \\ 1 & 5 \end{pmatrix}.$$

Entonces

$$\mathbf{AB} = \begin{pmatrix} 1(2) + 2(1) & 1(0) + 2(5) \\ 3(2) + 4(1) & 3(0) + 4(5) \end{pmatrix} = \begin{pmatrix} 4 & 10 \\ 10 & 20 \end{pmatrix}.$$

En general,

$$\mathbf{AB} \neq \mathbf{BA}.$$

6.21. Matriz transpuesta

La transpuesta de una matriz $\mathbf{A} \in \mathbb{R}^{n \times p}$ es la matriz

$$\mathbf{A}^T \in \mathbb{R}^{p \times n}$$

obtenida intercambiando filas por columnas.

Se cumplen las propiedades:

$$(\mathbf{A}^T)^T = \mathbf{A},$$

$$(\mathbf{A} + \mathbf{B})^T = \mathbf{A}^T + \mathbf{B}^T,$$

$$(\mathbf{AB})^T = \mathbf{B}^T \mathbf{A}^T.$$

6.22. Producto interno

Definición 6.11. El producto interno euclidiano de dos vectores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ se define como

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^T \mathbf{y} = \sum_{j=1}^p x_j y_j.$$

Ejemplo 6.5. Si

$$\mathbf{x} = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} 4 \\ 0 \\ -1 \end{pmatrix},$$

entonces

$$\mathbf{x}^T \mathbf{y} = 1(4) + 2(0) + 3(-1) = 1.$$

6.23. Norma

Definición 6.12. La norma euclidiana de un vector $\mathbf{x} \in \mathbb{R}^p$ es

$$\|\mathbf{x}\|_2 = \sqrt{\mathbf{x}^T \mathbf{x}} = \sqrt{\sum_{j=1}^p x_j^2}.$$

La norma representa la longitud del vector.

Se cumplen:

1. $\|\mathbf{x}\|_2 \geq 0$;
2. $\|\mathbf{x}\|_2 = 0$ si y solo si $\mathbf{x} = \mathbf{0}$;
3. $\|\alpha \mathbf{x}\|_2 = |\alpha| \|\mathbf{x}\|_2$;
4. $\|\mathbf{x} + \mathbf{y}\|_2 \leq \|\mathbf{x}\|_2 + \|\mathbf{y}\|_2$.

6.24. Distancia euclidiana

La distancia entre $\mathbf{x}$ y $\mathbf{y}$ se define como

$$d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_2.$$

Esta distancia es la base del algoritmo k -NN y del método k -means.

Ejemplo 6.6. Sean

$$\mathbf{x} = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} 4 \\ 6 \end{pmatrix}.$$

Entonces

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{(1-4)^2 + (2-6)^2} = 5.$$

6.25. Desigualdad de Cauchy-Schwarz

Teorema 6.1. Para cualesquiera vectores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,

$$|\mathbf{x}^T \mathbf{y}| \leq \|\mathbf{x}\|_2 \|\mathbf{y}\|_2.$$

Esta desigualdad permite definir el ángulo entre dos vectores.

6.26. Ángulo entre vectores

Si $\mathbf{x} \neq \mathbf{0}$ y $\mathbf{y} \neq \mathbf{0}$, se define

$$\cos \theta = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\|_2 \|\mathbf{y}\|_2}.$$

Este concepto es relevante en similitud coseno y análisis de texto.

6.27. Ortogonalidad

Definición 6.13. Dos vectores $\mathbf{x}$ y $\mathbf{y}$ son ortogonales si

$$\mathbf{x}^\top \mathbf{y} = 0.$$

La ortogonalidad generaliza la idea geométrica de perpendicularidad.

6.28. Vectores ortonormales

Un conjunto de vectores $\mathbf{q}_1, \dots, \mathbf{q}_k$ es ortonormal si:

$$\mathbf{q}_i^\top \mathbf{q}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Si las columnas de una matriz cuadrada $\mathbf{Q}$ son ortonormales, entonces

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}.$$

Por tanto,

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top.$$

6.29. Proyección ortogonal

Sea $\mathbf{u} \neq \mathbf{0}$. La proyección de $\mathbf{x}$ sobre $\mathbf{u}$ es

$$\text{proj}_{\mathbf{u}}(\mathbf{x}) = \frac{\mathbf{x}^T \mathbf{u}}{\mathbf{u}^T \mathbf{u}} \mathbf{u}.$$

Si $\|\mathbf{u}\|_2 = 1$, entonces

$$\text{proj}_{\mathbf{u}}(\mathbf{x}) = (\mathbf{x}^T \mathbf{u}) \mathbf{u}.$$

La regresión lineal puede interpretarse geométricamente como una proyección del vector de respuestas sobre el espacio generado por las columnas de la matriz de diseño.

6.30. Sistemas de ecuaciones lineales

Un sistema de n ecuaciones con p incógnitas puede escribirse como

$$\mathbf{A}\mathbf{x} = \mathbf{b}.$$

Por ejemplo,

$$\begin{aligned} 2x_1 + x_2 &= 5, \\ x_1 - 3x_2 &= -4 \end{aligned}$$

se representa como

$$\begin{pmatrix} 2 & 1 \\ 1 & -3 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 5 \\ -4 \end{pmatrix}.$$

6.31. Matriz inversa

Definición 6.14. Una matriz cuadrada $\mathbf{A}$ es invertible si existe una matriz $\mathbf{A}^{-1}$ tal que

$$\mathbf{A}^{-1} \mathbf{A} = \mathbf{A} \mathbf{A}^{-1} = \mathbf{I}.$$

Si $\mathbf{A}$ es invertible, el sistema

$$\mathbf{Ax} = \mathbf{b}$$

tiene la solución única

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b}.$$

En la práctica computacional, normalmente no se calcula la inversa explícita; se utilizan métodos numéricos para resolver el sistema.

6.32. Determinante

El determinante de una matriz cuadrada $\mathbf{A}$ se denota por

$$\det(\mathbf{A}).$$

Una matriz es invertible si y solo si

$$\det(\mathbf{A}) \neq 0.$$

El determinante también mide el factor de cambio de volumen inducido por una transformación lineal.

6.33. Rango

Definición 6.15. El rango de una matriz $\mathbf{A}$ es el número máximo de columnas linealmente independientes.

Se denota por

$$\text{rank}(\mathbf{A}).$$

Si

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

entonces

$$\text{rank}(\mathbf{A}) \leq \min(n, p).$$

6.34. Espacio columna

El espacio columna de $\mathbf{A}$ es

$$\text{Col}(\mathbf{A}) = \text{span}\{\mathbf{a}_1, \dots, \mathbf{a}_p\},$$

donde $\mathbf{a}_j$ es la columna j de $\mathbf{A}$.

6.35. Espacio nulo

El espacio nulo de $\mathbf{A}$ es

$$\text{Null}(\mathbf{A}) = \{\mathbf{x} : \mathbf{Ax} = \mathbf{0}\}.$$

Si el espacio nulo contiene vectores distintos de cero, las columnas de $\mathbf{A}$ son linealmente dependientes.

6.36. Transformaciones lineales

Definición 6.16. Una función

$$T : \mathbb{R}^p \rightarrow \mathbb{R}^m$$

es lineal si para todos $\mathbf{x}, \mathbf{y}$ y todos $\alpha, \beta \in \mathbb{R}$,

$$T(\alpha\mathbf{x} + \beta\mathbf{y}) = \alpha T(\mathbf{x}) + \beta T(\mathbf{y}).$$

Toda transformación lineal puede representarse mediante una matriz:

$$T(\mathbf{x}) = \mathbf{Ax}.$$

6.37. Formas cuadráticas

Definición 6.17. Una forma cuadrática es una expresión de la forma

$$q(\mathbf{x}) = \mathbf{x}^T \mathbf{A} \mathbf{x},$$

donde $\mathbf{A}$ es una matriz cuadrada.

Las formas cuadráticas aparecen en:

- funciones de pérdida;
- distancias de Mahalanobis;
- regresión ridge;
- análisis de componentes principales;
- modelos gaussianos.

6.38. Matrices definidas positivas

Definición 6.18. Una matriz simétrica $\mathbf{A}$ es definida positiva si

$$\mathbf{x}^T \mathbf{A} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$.

Es semidefinida positiva si

$$\mathbf{x}^T \mathbf{A} \mathbf{x} \geq 0.$$

Las matrices de covarianza son semidefinidas positivas.

6.39. Valores y vectores propios

Definición 6.19. Sea $\mathbf{A} \in \mathbb{R}^{p \times p}$. Un vector no nulo $\mathbf{v}$ es un vector propio de $\mathbf{A}$ si existe un escalar λ tal que

$$\mathbf{A} \mathbf{v} = \lambda \mathbf{v}.$$

El escalar λ se denomina valor propio asociado.

La ecuación puede escribirse como

$$(\mathbf{A} - \lambda \mathbf{I})\mathbf{v} = \mathbf{0}.$$

Para que exista una solución no trivial, se requiere

$$\det(\mathbf{A} - \lambda \mathbf{I}) = 0.$$

Esta ecuación se denomina ecuación característica.

Ejemplo 6.7. Considere

$$\mathbf{A} = \begin{pmatrix} 2 & 0 \\ 0 & 5 \end{pmatrix}.$$

Entonces

$$\mathbf{A} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = 2 \begin{pmatrix} 1 \\ 0 \end{pmatrix},$$

y

$$\mathbf{A} \begin{pmatrix} 0 \\ 1 \end{pmatrix} = 5 \begin{pmatrix} 0 \\ 1 \end{pmatrix}.$$

Por tanto, los valores propios son 2 y 5.

6.40. Interpretación geométrica

Un vector propio conserva su dirección bajo la transformación lineal $\mathbf{A}$. Únicamente cambia su escala mediante el factor λ .

Esta propiedad será esencial en PCA, donde los vectores propios de la matriz de covarianza determinan las direcciones principales de variabilidad.

6.41. Descomposición espectral

Teorema 6.2. *Toda matriz real simétrica $\mathbf{A}$ puede escribirse como*

$$\mathbf{A} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^T,$$

donde:

- $\mathbf{Q}$ es una matriz ortogonal;
- las columnas de $\mathbf{Q}$ son vectores propios ortonormales;
- $\mathbf{\Lambda}$ es diagonal y contiene los valores propios.

Esta factorización permite comprender la acción de una matriz simétrica como:

1. un cambio de coordenadas;
2. un escalamiento;
3. un regreso al sistema original.

6.42. Matriz de covarianza

Sea una variable aleatoria vectorial

$$\mathbf{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_p \end{pmatrix}.$$

Su matriz de covarianza es

$$\Sigma = \text{Cov}(\mathbf{X}) = \mathbb{E}[(\mathbf{X} - \mu)(\mathbf{X} - \mu)^T].$$

La matriz Σ es simétrica y semidefinida positiva.

6.43. Descomposición en valores singulares

Definición 6.20. Toda matriz

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

puede escribirse como

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T,$$

donde:

- $\mathbf{U}$ contiene los vectores singulares izquierdos;
- $\mathbf{V}$ contiene los vectores singulares derechos;
- $\mathbf{\Sigma}$ contiene los valores singulares.

Los valores singulares son no negativos y se relacionan con los valores propios de

$$\mathbf{A}^T \mathbf{A}$$

y

$$\mathbf{A}\mathbf{A}^T.$$

La SVD es fundamental para:

- reducción de dimensionalidad;
- compresión;
- cálculo estable de pseudoinversas;
- análisis de componentes principales;
- aproximación de matrices;
- sistemas de recomendación.

6.44. Aproximación de rango bajo

Si

$$\mathbf{A} = \sum_{j=1}^r \sigma_j \mathbf{u}_j \mathbf{v}_j^T,$$

donde

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0,$$

una aproximación de rango $k < r$ es

$$\mathbf{A}_k = \sum_{j=1}^k \sigma_j \mathbf{u}_j \mathbf{v}_j^T.$$

Esta aproximación conserva las direcciones más importantes de la matriz.

6.45. Pseudoinversa

Cuando una matriz no es cuadrada o no es invertible, puede utilizarse la pseudoinversa de Moore-Penrose:

$$\mathbf{A}^+.$$

Si

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T,$$

entonces

$$\mathbf{A}^+ = \mathbf{V}\mathbf{\Sigma}^+\mathbf{U}^T.$$

La pseudoinversa permite obtener soluciones de mínimos cuadrados incluso cuando la matriz de diseño tiene dependencia lineal.

6.46. Relación con regresión lineal

El modelo de regresión lineal múltiple se escribe como

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}.$$

El estimador de mínimos cuadrados satisface

$$\mathbf{X}^T\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}^T\mathbf{y}.$$

Si $\mathbf{X}^T\mathbf{X}$ es invertible,

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y}.$$

Geométricamente,

$$\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$$

es la proyección ortogonal de $\mathbf{y}$ sobre el espacio columna de $\mathbf{X}$.

6.47. Relación con PCA

En PCA se buscan direcciones unitarias $\mathbf{a}$ que maximicen la varianza proyectada:

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

El problema

$$\max_{\|\mathbf{a}\|_2=1} \mathbf{a}^\top \Sigma \mathbf{a}$$

conduce al vector propio asociado al mayor valor propio de Σ .

6.48. Relación con redes neuronales

En una capa neuronal,

$$\mathbf{z} = \mathbf{W}\mathbf{x} + \mathbf{b}.$$

La matriz $\mathbf{W}$ realiza una transformación lineal y $\mathbf{b}$ agrega un desplazamiento. Posteriormente se aplica una función no lineal.

Por tanto, cada capa combina álgebra lineal y cálculo.

6.49. Conexión con R

```
x <- c(1, 2, 3)
y <- c(4, 0, -1)

# Producto interno
sum(x * y)

# Norma euclidiana
sqrt(sum(x^2))

# Matriz
```

```

A <- matrix(
  c(1, 2,
    3, 4),
  nrow = 2,
  byrow = TRUE
)

# Transpuesta
t(A)

# Valores y vectores propios
eigen(A)

# Descomposición en valores singulares
svd(A)

```

6.50. Ejemplo numérico integrado

Considere la matriz de datos centrados

$$\mathbf{X} = \begin{pmatrix} -1 & -2 \\ 0 & 0 \\ 1 & 2 \end{pmatrix}.$$

Las columnas son linealmente dependientes porque

$$\mathbf{x}_{\cdot 2} = 2\mathbf{x}_{\cdot 1}.$$

La matriz de covarianza muestral es proporcional a

$$\mathbf{X}^T \mathbf{X} = \begin{pmatrix} 2 & 4 \\ 4 & 8 \end{pmatrix}.$$

Esta matriz tiene rango uno. Uno de sus valores propios es cero, lo que indica que no existe variabilidad independiente en una de las direcciones.

Este ejemplo anticipa dos problemas importantes:

1. multicolinealidad en regresión;
2. reducción de dimensionalidad mediante PCA.

6.51. Errores frecuentes

1. Confundir producto matricial con multiplicación componente a componente.
2. Suponer que $\mathbf{AB} = \mathbf{BA}$.
3. Confundir vector fila con vector columna.
4. Suponer que toda matriz cuadrada es invertible.
5. Confundir independencia lineal con ortogonalidad.
6. Pensar que rango es simplemente el número de columnas.
7. Confundir valores propios con vectores propios.
8. Utilizar la inversa explícita innecesariamente en cálculos numéricos.
9. Interpretar una matriz de covarianza sin considerar el escalamiento de variables.
10. Suponer que una matriz semidefinida positiva debe ser invertible.

6.52. Ejercicios conceptuales

1. Explique la diferencia entre escalar, vector y matriz.
2. ¿Qué significa que un conjunto de vectores sea linealmente independiente?
3. ¿Qué representa geoméricamente el producto interno?
4. ¿Cuál es la diferencia entre norma y distancia?
5. ¿Qué significa que dos vectores sean ortogonales?
6. ¿Qué representa el rango de una matriz?
7. ¿Por qué una matriz de covarianza es simétrica?
8. ¿Qué interpretación geométrica tiene un vector propio?
9. ¿Por qué la SVD puede aplicarse a matrices no cuadradas?
10. Explique la relación entre proyección ortogonal y regresión lineal.

6.53. Ejercicios de cálculo

Sean

$$\mathbf{x} = \begin{pmatrix} 2 \\ -1 \\ 3 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} 1 \\ 4 \\ 0 \end{pmatrix}.$$

Calcule:

1. $\mathbf{x} + \mathbf{y}$;
2. $3\mathbf{x}$;
3. $\mathbf{x}^T \mathbf{y}$;
4. $\|\mathbf{x}\|_2$;

5. $d(\mathbf{x}, \mathbf{y})$;
6. el ángulo entre ambos vectores.

6.54. Ejercicios de matrices

Sean

$$\mathbf{A} = \begin{pmatrix} 1 & 2 \\ 0 & 3 \end{pmatrix}, \quad \mathbf{B} = \begin{pmatrix} 4 & 1 \\ 2 & 5 \end{pmatrix}.$$

Calcule:

1. $\mathbf{A} + \mathbf{B}$;
2. $\mathbf{AB}$;
3. $\mathbf{BA}$;
4. $\mathbf{A}^T$;
5. $\det(\mathbf{A})$;
6. $\mathbf{A}^{-1}$, si existe.

6.55. Ejercicio de independencia lineal

Determine si los vectores

$$\mathbf{v}_1 = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}, \quad \mathbf{v}_2 = \begin{pmatrix} 2 \\ 4 \\ 6 \end{pmatrix}, \quad \mathbf{v}_3 = \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix}$$

son linealmente independientes.

6.56. Ejercicio de valores propios

Considere

$$\mathbf{A} = \begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix}.$$

1. Determine la ecuación característica.
2. Calcule los valores propios.
3. Calcule un vector propio asociado a cada valor propio.

4. Normalice los vectores propios.
5. Construya la descomposición espectral.

6.57. Ejercicio aplicado

Una base de datos contiene las variables:

- PM10;
- temperatura;
- humedad;
- velocidad del viento.

1. Escriba una observación como vector.
2. Escriba la matriz de datos para n observaciones.
3. Indique las dimensiones de la matriz.
4. Explique qué significa que dos columnas sean linealmente dependientes.
5. Describa una posible consecuencia de esa dependencia en regresión.
6. Explique cómo PCA podría ayudar a resolver el problema.

6.58. Resumen

En este capítulo se desarrollaron los conceptos de escalares, vectores, matrices, combinaciones lineales, independencia, bases, espacios vectoriales, productos internos, normas, distancias y proyecciones.

También se estudiaron sistemas lineales, inversas, rango, espacios columna y nulo, transformaciones lineales, formas cuadráticas, matrices definidas positivas, valores propios, descomposición espectral y descomposición en valores singulares.

Estas herramientas constituyen la base matemática de numerosos algoritmos de aprendizaje automático, entre ellos regresión lineal, PCA, máquinas de vectores de soporte, redes neuronales, agrupamiento y métodos de reducción de dimensionalidad.

7 Probabilidad y estadística para aprendizaje automático

7.1. Introducción

La probabilidad y la estadística proporcionan el marco matemático para representar incertidumbre, variabilidad y aprendizaje a partir de datos. Los algoritmos de aprendizaje automático no trabajan con relaciones completamente deterministas: las observaciones contienen ruido, los patrones son incompletos y las predicciones siempre están sujetas a cierto grado de incertidumbre.

La teoría de la probabilidad permite modelar fenómenos aleatorios, mientras que la estadística proporciona herramientas para inferir propiedades de una población a partir de una muestra. Ambas disciplinas son esenciales para comprender la clasificación probabilística, la regresión, la estimación de parámetros, la selección de modelos, la validación y la evaluación de predicciones.

7.2. Objetivos

Al finalizar el capítulo, el lector podrá:

1. definir un espacio de probabilidad;
2. interpretar eventos y operaciones entre eventos;
3. aplicar axiomas y propiedades de probabilidad;
4. utilizar probabilidad condicional e independencia;
5. comprender y aplicar el teorema de Bayes;
6. definir variables aleatorias discretas y continuas;
7. interpretar funciones de masa, densidad y distribución;
8. calcular esperanza, varianza y covarianza;
9. representar vectores aleatorios y matrices de covarianza;
10. comprender distribuciones conjuntas, marginales y condicionales;
11. interpretar la ley de los grandes números y el teorema central del límite;
12. comprender estimación puntual y por intervalos;
13. derivar estimadores por máxima verosimilitud;
14. relacionar estos conceptos con algoritmos de aprendizaje automático.

7.3. Experimentos aleatorios

Definición 7.1. Un **experimento aleatorio** es un procedimiento cuyo resultado no puede predecirse con certeza antes de realizarse, aunque sí puede describirse el conjunto de resultados posibles.

Ejemplos:

- observar si un paciente presenta o no una enfermedad;
- registrar la concentración de un contaminante;
- seleccionar una observación de una base de datos;
- clasificar un correo como deseado o no deseado.

7.4. Espacio muestral

Definición 7.2. El **espacio muestral** es el conjunto de todos los resultados posibles de un experimento aleatorio. Se denota por Ω .

Por ejemplo, para una clasificación binaria,

$$\Omega = \{0, 1\}.$$

Para una medición continua,

$$\Omega \subseteq \mathbb{R}.$$

7.5. Eventos

Definición 7.3. Un **evento** es cualquier subconjunto del espacio muestral.

Si $A \subseteq \Omega$, entonces A representa un evento.

Las operaciones entre eventos se expresan mediante conjuntos:

- unión: $A \cup B$;
- intersección: $A \cap B$;
- complemento: A^c ;
- diferencia: $A \setminus B$.

7.6. Sigma-álgebra

Definición 7.4. Una **sigma-álgebra** $\mathcal{F}$ sobre Ω es una colección de subconjuntos de Ω que satisface:

1. $\Omega \in \mathcal{F}$;
2. si $A \in \mathcal{F}$, entonces $A^c \in \mathcal{F}$;
3. si $A_1, A_2, \dots \in \mathcal{F}$, entonces

$$\bigcup_{i=1}^{\infty} A_i \in \mathcal{F}.$$

La sigma-álgebra contiene los eventos a los que puede asignarse probabilidad.

7.7. Espacio de probabilidad

Definición 7.5. Un **espacio de probabilidad** es una terna

$$(\Omega, \mathcal{F}, P),$$

donde:

- Ω es el espacio muestral;
- $\mathcal{F}$ es una sigma-álgebra;
- P es una medida de probabilidad.

7.8. Axiomas de probabilidad

La función

$$P : \mathcal{F} \rightarrow [0, 1]$$

satisface:

1. **No negatividad**

$$P(A) \geq 0.$$

2. **Normalización**

$$P(\Omega) = 1.$$

3. Aditividad numerable

Si $A_1, A_2, \dots$ son mutuamente excluyentes, entonces

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i).$$

7.9. Propiedades fundamentales

De los axiomas se deduce:

$$P(\emptyset) = 0,$$

$$P(A^c) = 1 - P(A),$$

$$P(A \cup B) = P(A) + P(B) - P(A \cap B),$$

y si $A \subseteq B$,

$$P(A) \leq P(B).$$

7.10. Probabilidad condicional

Definición 7.6. Si $P(B) > 0$, la probabilidad condicional de A dado B se define como

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}.$$

La probabilidad condicional permite actualizar la incertidumbre cuando se dispone de nueva información.

Ejemplo 7.1. Supóngase que:

$$P(A) = 0.30, \quad P(B) = 0.50, \quad P(A \cap B) = 0.20.$$

Entonces

$$P(A | B) = \frac{0.20}{0.50} = 0.40.$$

7.11. Regla del producto

De la definición anterior,

$$P(A \cap B) = P(A | B)P(B).$$

También,

$$P(A \cap B) = P(B | A)P(A).$$

Para varios eventos,

$$P(A_1 \cap \dots \cap A_n) = P(A_1) \prod_{i=2}^n P(A_i | A_1 \cap \dots \cap A_{i-1}).$$

7.12. Independencia

Definición 7.7. Dos eventos A y B son independientes si

$$P(A \cap B) = P(A)P(B).$$

Si $P(B) > 0$, esta condición equivale a

$$P(A | B) = P(A).$$

La independencia significa que conocer la ocurrencia de un evento no modifica la probabilidad del otro.

7.13. Partición del espacio muestral

Los eventos $B_1, \dots, B_k$ forman una partición de Ω si:

1. $B_i \cap B_j = \emptyset$ para $i \neq j$;
2. $\bigcup_{j=1}^k B_j = \Omega$.

7.14. Teorema de probabilidad total

Teorema 7.1. Si $B_1, \dots, B_k$ forman una partición de Ω , entonces para cualquier evento A ,

$$P(A) = \sum_{j=1}^k P(A \mid B_j)P(B_j).$$

7.15. Teorema de Bayes

Teorema 7.2. Si $B_1, \dots, B_k$ forman una partición y $P(A) > 0$, entonces

$$P(B_j \mid A) = \frac{P(A \mid B_j)P(B_j)}{\sum_{\ell=1}^k P(A \mid B_\ell)P(B_\ell)}.$$

En clasificación, la regla de Bayes permite calcular la probabilidad posterior de una clase dado un vector de características.

Para clases $C_1, \dots, C_K$,

$$P(C_k \mid \mathbf{x}) = \frac{P(\mathbf{x} \mid C_k)P(C_k)}{\sum_{j=1}^K P(\mathbf{x} \mid C_j)P(C_j)}.$$

7.16. Ejemplo de diagnóstico

Sea D el evento “el paciente tiene una enfermedad” y T^+ el evento “la prueba resulta positiva”.

Supóngase:

$$P(D) = 0.02,$$

$$P(T^+ \mid D) = 0.95,$$

$$P(T^+ \mid D^c) = 0.08.$$

Entonces

$$P(T^+) = P(T^+ \mid D)P(D) + P(T^+ \mid D^c)P(D^c).$$

Por tanto,

$$P(T^+) = 0.95(0.02) + 0.08(0.98) = 0.0974.$$

La probabilidad posterior es

$$P(D \mid T^+) = \frac{0.95(0.02)}{0.0974} \approx 0.195.$$

Aunque la prueba sea sensible, la baja prevalencia influye de manera importante en la probabilidad posterior.

7.17. Variables aleatorias

Definición 7.8. Una **variable aleatoria** es una función

$$X : \Omega \rightarrow \mathbb{R}.$$

Una variable aleatoria asigna un número real a cada resultado del experimento.

7.18. Variables aleatorias discretas

Definición 7.9. Una variable aleatoria es discreta si toma valores en un conjunto finito o numerable.

Su función de masa de probabilidad es

$$p_X(x) = P(X = x).$$

Debe satisfacer:

$$p_X(x) \geq 0,$$

$$\sum_x p_X(x) = 1.$$

7.19. Distribución Bernoulli

Una variable Bernoulli con parámetro p satisface

$$X \sim \text{Bernoulli}(p),$$

con

$$P(X = 1) = p, \quad P(X = 0) = 1 - p.$$

Su esperanza y varianza son

$$\mathbb{E}(X) = p,$$

$$\text{Var}(X) = p(1 - p).$$

Esta distribución es central en clasificación binaria y regresión logística.

7.20. Distribución binomial

Si

$$X \sim \text{Binomial}(n, p),$$

entonces

$$P(X = x) = \binom{n}{x} p^x (1 - p)^{n-x},$$

para

$$x = 0, 1, \dots, n.$$

La esperanza y varianza son

$$\mathbb{E}(X) = np,$$

$$\text{Var}(X) = np(1 - p).$$

7.21. Variables aleatorias continuas

Definición 7.10. Una variable aleatoria continua posee una función de densidad $f_X(x)$ tal que

$$P(a \leq X \leq b) = \int_a^b f_X(x) dx.$$

La densidad satisface:

$$f_X(x) \geq 0,$$

$$\int_{-\infty}^{\infty} f_X(x) dx = 1.$$

Para una variable continua,

$$P(X = x) = 0.$$

7.22. Función de distribución acumulada

Definición 7.11. La función de distribución acumulada de X se define como

$$F_X(x) = P(X \leq x).$$

Para una variable continua,

$$F_X(x) = \int_{-\infty}^x f_X(t) dt.$$

7.23. Distribución normal

Una variable normal se denota por

$$X \sim N(\mu, \sigma^2).$$

Su densidad es

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(x - \mu)^2}{2\sigma^2} \right].$$

La distribución normal desempeña un papel fundamental en inferencia estadística, regresión y teoría asintótica.

7.24. Esperanza matemática

Definición 7.12. La esperanza de una variable aleatoria discreta es

$$\mathbb{E}(X) = \sum_x x p_X(x).$$

Para una variable continua,

$$\mathbb{E}(X) = \int_{-\infty}^{\infty} x f_X(x) dx.$$

La esperanza representa el valor promedio teórico de la variable aleatoria.

7.25. Esperanza de una función

Si g es una función,

para variables discretas:

$$\mathbb{E}[g(X)] = \sum_x g(x) p_X(x),$$

y para variables continuas:

$$\mathbb{E}[g(X)] = \int_{-\infty}^{\infty} g(x) f_X(x) dx.$$

7.26. Linealidad de la esperanza

Teorema 7.3. Para cualesquiera variables aleatorias X y Y y escalares a, b ,

$$\mathbb{E}(aX + bY) = a\mathbb{E}(X) + b\mathbb{E}(Y).$$

La linealidad no requiere independencia.

7.27. Varianza

Definición 7.13. La varianza de X se define como

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}X)^2].$$

Equivalentemente,

$$\text{Var}(X) = \mathbb{E}(X^2) - [\mathbb{E}(X)]^2.$$

La desviación estándar es

$$\sigma_X = \sqrt{\text{Var}(X)}.$$

7.28. Propiedades de la varianza

Para constantes a y b ,

$$\text{Var}(aX + b) = a^2 \text{Var}(X).$$

Además,

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y).$$

Si X y Y son independientes,

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y).$$

7.29. Covarianza

Definición 7.14. La covarianza entre X y Y es

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)].$$

Equivalentemente,

$$\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y).$$

Si X y Y son independientes, entonces

$$\text{Cov}(X, Y) = 0.$$

La recíproca no siempre es verdadera.

7.30. Correlación

La correlación lineal es

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}.$$

Se cumple

$$-1 \leq \rho_{XY} \leq 1.$$

La correlación mide asociación lineal, no causalidad.

7.31. Variables aleatorias conjuntas

Sean X y Y variables aleatorias.

En el caso discreto, la función de masa conjunta es

$$p_{X,Y}(x, y) = P(X = x, Y = y).$$

En el caso continuo, la densidad conjunta es

$$f_{X,Y}(x, y).$$

Debe cumplirse

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f_{X,Y}(x, y) dx dy = 1.$$

7.32. Distribuciones marginales

A partir de una densidad conjunta,

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dy,$$

$$f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dx.$$

En el caso discreto se utilizan sumas.

7.33. Distribuciones condicionales

Si $f_Y(y) > 0$,

$$f_{X|Y}(x | y) = \frac{f_{X,Y}(x, y)}{f_Y(y)}.$$

Esta relación generaliza la probabilidad condicional.

7.34. Independencia de variables aleatorias

Las variables X y Y son independientes si

$$f_{X,Y}(x, y) = f_X(x)f_Y(y)$$

para todos los valores posibles.

7.35. Vectores aleatorios

Definición 7.15. Un vector aleatorio de dimensión p es

$$\mathbf{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_p \end{pmatrix}.$$

Su vector de medias es

$$\mu = \mathbb{E}(\mathbf{X}) = \begin{pmatrix} \mathbb{E}(X_1) \\ \vdots \\ \mathbb{E}(X_p) \end{pmatrix}.$$

7.36. Matriz de covarianza

Definición 7.16. La matriz de covarianza de $\mathbf{X}$ es

$$\Sigma = \text{Cov}(\mathbf{X}) = \mathbb{E}[(\mathbf{X} - \mu)(\mathbf{X} - \mu)^T].$$

Sus elementos son

$$\sigma_{ij} = \text{Cov}(X_i, X_j).$$

La diagonal contiene las varianzas:

$$\sigma_{ii} = \text{Var}(X_i).$$

La matriz de covarianza es simétrica y semidefinida positiva.

7.37. Distribución normal multivariada

Se escribe

$$\mathbf{X} \sim N_p(\mu, \Sigma).$$

Su densidad es

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left[-\frac{1}{2} (\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu) \right].$$

La forma cuadrática

$$(\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu)$$

corresponde a la distancia de Mahalanobis al cuadrado.

7.38. Muestra aleatoria

Definición 7.17. Una muestra aleatoria

$$X_1, \dots, X_n$$

es un conjunto de variables aleatorias independientes e idénticamente distribuidas.

Se escribe

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} F.$$

7.39. Media muestral

La media muestral es

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Su esperanza es

$$\mathbb{E}(\bar{X}) = \mu.$$

Si las observaciones son independientes,

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n}.$$

7.40. Varianza muestral

La varianza muestral es

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

El denominador $n-1$ permite que

$$\mathbb{E}(S^2) = \sigma^2.$$

7.41. Ley de los grandes números

Teorema 7.4. *Bajo condiciones regulares,*

$$\bar{X}_n \rightarrow \mu$$

cuando

$$n \rightarrow \infty.$$

La ley de los grandes números justifica el uso de promedios muestrales como aproximaciones de valores esperados.

7.42. Teorema central del límite

Teorema 7.5. *Si $X_1, \dots, X_n$ son iid con media μ y varianza finita σ^2 , entonces*

$$\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \xrightarrow{d} N(0, 1).$$

Este resultado explica por qué la distribución normal aparece en numerosos procedimientos de inferencia.

7.43. Estadísticos y parámetros

Un **parámetro** es una cantidad fija pero desconocida de una población, por ejemplo:

$$\mu, \quad \sigma^2, \quad p, \quad \beta.$$

Un **estadístico** es una función de la muestra:

$$T = T(X_1, \dots, X_n).$$

Por ejemplo,

$$\overline{X}$$

es un estadístico utilizado para estimar μ .

7.44. Estimación puntual

Definición 7.18. Un estimador $\hat{\theta}$ es un estadístico utilizado para aproximar un parámetro desconocido θ .

Propiedades deseables:

- insesgadez;
- consistencia;
- eficiencia;
- suficiencia.

7.45. Sesgo

El sesgo de un estimador es

$$\text{Bias}(\hat{\theta}) = \mathbb{E}(\hat{\theta}) - \theta.$$

Si

$$\mathbb{E}(\hat{\theta}) = \theta,$$

el estimador es insesgado.

7.46. Error cuadrático medio

El error cuadrático medio es

$$\text{MSE}(\hat{\theta}) = \mathbb{E} \left[(\hat{\theta} - \theta)^2 \right].$$

Se descompone como

$$\text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta}) + \text{Bias}(\hat{\theta})^2.$$

Esta identidad anticipa el compromiso entre sesgo y varianza en aprendizaje automático.

7.47. Consistencia

Un estimador es consistente si

$$\hat{\theta}_n \xrightarrow{P} \theta.$$

Es decir, la probabilidad de alejarse del parámetro verdadero disminuye al aumentar el tamaño de muestra.

7.48. Función de verosimilitud

Definición 7.19. Sea una muestra

$$x_1, \dots, x_n$$

proveniente de una distribución con parámetro θ . La función de verosimilitud es

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta).$$

La verosimilitud se interpreta como una función del parámetro, manteniendo fija la muestra observada.

7.49. Log-verosimilitud

La log-verosimilitud es

$$\ell(\theta) = \log L(\theta) = \sum_{i=1}^n \log f(x_i; \theta).$$

Se utiliza porque transforma productos en sumas y facilita la derivación.

7.50. Estimación por máxima verosimilitud

Definición 7.20. El estimador de máxima verosimilitud se define como

$$\hat{\theta}_{MV} = \arg \max_{\theta} L(\theta),$$

o equivalentemente,

$$\hat{\theta}_{MV} = \arg \max_{\theta} \ell(\theta).$$

7.51. Ejemplo Bernoulli

Supóngase que

$$X_i \sim \text{Bernoulli}(p).$$

La función de masa es

$$P(X_i = x_i) = p^{x_i} (1 - p)^{1-x_i}.$$

La verosimilitud es

$$L(p) = \prod_{i=1}^n p^{x_i} (1 - p)^{1-x_i}.$$

Entonces

$$L(p) = p^{\sum x_i} (1 - p)^{n - \sum x_i}.$$

La log-verosimilitud es

$$\ell(p) = \left(\sum_{i=1}^n x_i \right) \log p + \left(n - \sum_{i=1}^n x_i \right) \log(1 - p).$$

Derivando:

$$\frac{d\ell}{dp} = \frac{\sum x_i}{p} - \frac{n - \sum x_i}{1 - p}.$$

Igualando a cero:

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}.$$

Por tanto, el estimador de máxima verosimilitud de p es la proporción muestral.

7.52. Estimación bayesiana

En el enfoque bayesiano, el parámetro se considera aleatorio.

Se combinan:

- distribución previa:

$$p(\theta);$$

- verosimilitud:

$$p(\mathbf{x} \mid \theta);$$

- distribución posterior:

$$p(\theta \mid \mathbf{x}).$$

Por el teorema de Bayes,

$$p(\theta \mid \mathbf{x}) = \frac{p(\mathbf{x} \mid \theta)p(\theta)}{p(\mathbf{x})}.$$

Equivalentemente,

$$p(\theta \mid \mathbf{x}) \propto p(\mathbf{x} \mid \theta)p(\theta).$$

7.53. Intervalos de confianza

Un intervalo de confianza para un parámetro θ tiene la forma

$$[L(\mathbf{X}), U(\mathbf{X})].$$

Un intervalo con nivel $1 - \alpha$ satisface

$$P[L(\mathbf{X}) \leq \theta \leq U(\mathbf{X})] = 1 - \alpha.$$

La interpretación correcta se refiere al procedimiento de construcción, no a una probabilidad posterior sobre un parámetro fijo.

7.54. Pruebas de hipótesis

Una prueba de hipótesis compara:

$$H_0 : \theta \in \Theta_0$$

contra

$$H_1 : \theta \in \Theta_1.$$

Los errores posibles son:

- error tipo I: rechazar H_0 cuando es verdadera;
- error tipo II: no rechazar H_0 cuando es falsa.

El nivel de significancia es

$$\alpha = P(\text{rechazar } H_0 \mid H_0 \text{ verdadera}).$$

7.55. Relación con clasificación

En clasificación probabilística se selecciona la clase con mayor probabilidad posterior:

$$\hat{y} = \arg \max_k P(Y = k \mid \mathbf{x}).$$

Esta regla minimiza el error esperado bajo pérdida 0-1.

7.56. Relación con regresión logística

En regresión logística,

$$P(Y = 1 \mid \mathbf{x}) = \pi(\mathbf{x}),$$

donde

$$\pi(\mathbf{x}) = \frac{\exp(\beta_0 + \beta^T \mathbf{x})}{1 + \exp(\beta_0 + \beta^T \mathbf{x})}.$$

Los parámetros se estiman maximizando la verosimilitud Bernoulli.

7.57. Relación con árboles de decisión

La proporción de observaciones de la clase k en un nodo es

$$\hat{p}_k = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(y_i = k).$$

Estas probabilidades se utilizan en medidas como entropía e impureza de Gini.

7.58. Relación con PCA

La matriz de covarianza

$$\Sigma$$

resume la variabilidad conjunta de las características. PCA utiliza sus valores y vectores propios para encontrar direcciones de máxima varianza.

7.59. Conexión con R

```
x <- c(4, 6, 8, 7, 5)

# Media
mean(x)

# Varianza muestral
var(x)

# Desviación estándar
sd(x)

# Probabilidad binomial
dbinom(3, size = 5, prob = 0.4)

# Probabilidad acumulada normal
pnorm(1.96)

# Cuantil normal
qnorm(0.975)

# Simulación Bernoulli
rbinom(10, size = 1, prob = 0.30)

# Matriz de covarianza
datos <- data.frame(
  pm10 = c(40, 55, 68, 73),
  temperatura = c(18, 21, 24, 26),
  humedad = c(65, 58, 50, 45)
)

cov(datos)
cor(datos)
```

7.60. Ejemplo integrado de clasificación

Considere dos clases:

C_1 = calidad aceptable,

C_2 = calidad no aceptable.

Supóngase:

$$P(C_1) = 0.70, \quad P(C_2) = 0.30.$$

Para una observación $\mathbf{x}$,

$$P(\mathbf{x} \mid C_1) = 0.10,$$

$$P(\mathbf{x} \mid C_2) = 0.25.$$

Entonces,

$$P(C_1 \mid \mathbf{x}) = \frac{0.10(0.70)}{0.10(0.70) + 0.25(0.30)} \approx 0.483.$$

Además,

$$P(C_2 \mid \mathbf{x}) \approx 0.517.$$

La regla de Bayes clasifica la observación en C_2 .

7.61. Errores frecuentes

1. Confundir probabilidad conjunta con probabilidad condicional.
2. Suponer que eventos mutuamente excluyentes son independientes.
3. Interpretar una densidad como una probabilidad puntual.
4. Confundir independencia con covarianza cero.
5. Interpretar correlación como causalidad.
6. Confundir parámetro con estadístico.
7. Interpretar incorrectamente un intervalo de confianza.
8. Confundir verosimilitud con probabilidad del parámetro.
9. Suponer que una muestra grande corrige automáticamente sesgos de diseño.
10. Aplicar el teorema de Bayes sin considerar probabilidades previas.

7.62. Ejercicios conceptuales

1. Explique la diferencia entre experimento, espacio muestral y evento.
2. ¿Qué diferencia existe entre probabilidad conjunta y condicional?
3. Explique la diferencia entre independencia y exclusión mutua.
4. ¿Qué representa la esperanza matemática?
5. ¿Qué representa la varianza?
6. ¿Por qué covarianza cero no implica siempre independencia?
7. Explique la diferencia entre parámetro y estadístico.
8. ¿Qué significa que un estimador sea insesgado?
9. ¿Qué significa que un estimador sea consistente?
10. Explique la diferencia entre probabilidad y verosimilitud.

7.63. Ejercicios de probabilidad

Sean dos eventos A y B tales que

$$P(A) = 0.40, \quad P(B) = 0.55, \quad P(A \cap B) = 0.25.$$

Calcule:

1. $P(A \cup B)$;
2. $P(A^c)$;
3. $P(A | B)$;
4. $P(B | A)$;
5. determine si A y B son independientes.

7.64. Ejercicio de Bayes

Una enfermedad tiene prevalencia de 0.03. Una prueba tiene sensibilidad de 0.92 y especificidad de 0.90.

Calcule:

1. la probabilidad de un resultado positivo;
2. la probabilidad de enfermedad dado un resultado positivo;
3. la probabilidad de no enfermedad dado un resultado negativo;
4. interprete los resultados.

7.65. Ejercicio de esperanza y varianza

Sea X una variable aleatoria con distribución:

x	0	1	2	3
$P(X = x)$	0.10	0.25	0.40	0.25

Calcule:

1. $\mathbb{E}(X)$;
2. $\mathbb{E}(X^2)$;
3. $\text{Var}(X)$;
4. la desviación estándar.

7.66. Ejercicio de máxima verosimilitud

Considere la muestra Bernoulli:

1, 0, 1, 1, 0, 1, 1, 1, 0, 1.

1. Escriba la función de verosimilitud.
2. Escriba la log-verosimilitud.
3. Calcule el estimador de máxima verosimilitud de p .
4. Interprete el resultado.

7.67. Ejercicio aplicado

Una base de datos ambiental contiene:

- PM10;
- temperatura;
- humedad;
- velocidad del viento.

1. Defina un vector aleatorio.
2. Escriba el vector de medias.
3. Describa la matriz de covarianza.
4. Explique el significado de una covarianza positiva entre PM10 y temperatura.
5. Explique qué información adicional proporciona la correlación.
6. Indique cómo se relaciona esta matriz con PCA.

7.68. Resumen

En este capítulo se construyó el marco probabilístico y estadístico del aprendizaje automático. Se definieron espacios de probabilidad, eventos, probabilidad condicional, independencia y teorema de Bayes.

También se estudiaron variables aleatorias, funciones de masa y densidad, esperanza, varianza, covarianza, correlación, distribuciones conjuntas y vectores aleatorios.

Finalmente, se introdujeron conceptos de inferencia estadística, como estimadores, sesgo, consistencia, error cuadrático medio, máxima verosimilitud, estimación bayesiana, intervalos de confianza y pruebas de hipótesis.

Estos elementos serán utilizados posteriormente en regresión logística, clasificación bayesiana, árboles de decisión, PCA, validación y teoría de generalización.

8 Cálculo multivariable y optimización

8.1. Introducción

El cálculo multivariable y la optimización permiten describir cómo cambia una función cuando cambian varios parámetros al mismo tiempo. En aprendizaje automático, los modelos dependen de vectores o matrices de parámetros, y su entrenamiento consiste casi siempre en minimizar una función de pérdida.

La regresión lineal minimiza una suma de errores cuadrados; la regresión logística maximiza una log-verosimilitud; las máquinas de vectores de soporte resuelven problemas de optimización convexa; las redes neuronales ajustan millones de parámetros mediante gradientes; y numerosos métodos utilizan restricciones, multiplicadores de Lagrange o aproximaciones de segundo orden.

Este capítulo desarrolla las herramientas necesarias para formular y analizar estos procesos.

8.2. Objetivos

Al finalizar el capítulo, el lector podrá:

1. interpretar funciones de varias variables;
2. calcular derivadas parciales;
3. construir gradientes y matrices Jacobianas;
4. calcular e interpretar matrices Hessianas;
5. aplicar la regla de la cadena multivariable;
6. utilizar expansiones de Taylor;
7. identificar puntos críticos;
8. distinguir mínimos, máximos y puntos silla;
9. comprender convexidad y funciones convexas;
10. resolver problemas de optimización sin restricciones;
11. formular problemas con restricciones;
12. aplicar multiplicadores de Lagrange;
13. comprender descenso por gradiente;
14. interpretar métodos de Newton y aproximaciones de segundo orden;
15. relacionar estos conceptos con algoritmos de aprendizaje automático.

8.3. Funciones de varias variables

Definición 8.1. Una función de varias variables es una aplicación

$$f : \mathbb{R}^p \rightarrow \mathbb{R}.$$

Para

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{pmatrix},$$

se escribe

$$f(\mathbf{x}) = f(x_1, \dots, x_p).$$

Ejemplo 8.1. Considere

$$f(x_1, x_2) = x_1^2 + 2x_1x_2 + 3x_2^2.$$

Esta función asigna un número real a cada punto de $\mathbb{R}^2$.

8.4. Superficies de nivel

Para una constante c , el conjunto de nivel de f es

$$L_c = \{\mathbf{x} \in \mathbb{R}^p : f(\mathbf{x}) = c\}.$$

En dos variables, los conjuntos de nivel pueden representarse mediante curvas de nivel.

En optimización, estas curvas ayudan a visualizar la geometría de la función objetivo.

8.5. Derivadas parciales

Definición 8.2. La derivada parcial de f respecto de x_j se define como

$$\frac{\partial f}{\partial x_j} = \lim_{h \rightarrow 0} \frac{f(x_1, \dots, x_j + h, \dots, x_p) - f(x_1, \dots, x_j, \dots, x_p)}{h},$$

si el límite existe.

La derivada parcial mide la tasa de cambio de f respecto de una variable, manteniendo las demás constantes.

Ejemplo 8.2. Sea

$$f(x_1, x_2) = x_1^2 + 3x_1x_2 + 2x_2^2.$$

Entonces

$$\frac{\partial f}{\partial x_1} = 2x_1 + 3x_2,$$

y

$$\frac{\partial f}{\partial x_2} = 3x_1 + 4x_2.$$

8.6. Derivadas parciales de orden superior

Las segundas derivadas parciales son

$$\frac{\partial^2 f}{\partial x_i^2}$$

y las derivadas cruzadas son

$$\frac{\partial^2 f}{\partial x_i \partial x_j}.$$

Si f es suficientemente suave, se cumple el teorema de Clairaut:

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i}.$$

8.7. Gradiente

Definición 8.3. El gradiente de una función

$$f : \mathbb{R}^p \rightarrow \mathbb{R}$$

es el vector

$$\nabla f(\mathbf{x}) = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \vdots \\ \frac{\partial f}{\partial x_p} \end{pmatrix}.$$

El gradiente apunta en la dirección de máximo crecimiento local de la función.

La dirección opuesta,

$$-\nabla f(\mathbf{x}),$$

apunta en la dirección de máximo decrecimiento local.

Ejemplo 8.3. Para

$$f(x_1, x_2) = x_1^2 + 3x_1x_2 + 2x_2^2,$$

el gradiente es

$$\nabla f(x_1, x_2) = \begin{pmatrix} 2x_1 + 3x_2 \\ 3x_1 + 4x_2 \end{pmatrix}.$$

8.8. Derivada direccional

Sea $\mathbf{u}$ un vector unitario. La derivada direccional de f en la dirección $\mathbf{u}$ es

$$D_{\mathbf{u}}f(\mathbf{x}) = \nabla f(\mathbf{x})^T \mathbf{u}.$$

Por la desigualdad de Cauchy-Schwarz,

$$D_{\mathbf{u}}f(\mathbf{x}) \leq \|\nabla f(\mathbf{x})\|_2.$$

La igualdad se alcanza cuando

$$\mathbf{u} = \frac{\nabla f(\mathbf{x})}{\|\nabla f(\mathbf{x})\|_2}.$$

8.9. Funciones vectoriales

Una función vectorial tiene la forma

$$\mathbf{f}: \mathbb{R}^p \rightarrow \mathbb{R}^m.$$

Se escribe

$$\mathbf{f}(\mathbf{x}) = \begin{pmatrix} f_1(\mathbf{x}) \\ \vdots \\ f_m(\mathbf{x}) \end{pmatrix}.$$

8.10. Matriz Jacobiana

Definición 8.4. La matriz Jacobiana de

$$\mathbf{f}: \mathbb{R}^p \rightarrow \mathbb{R}^m$$

es

$$\mathbf{J}_{\mathbf{f}}(\mathbf{x}) = \begin{pmatrix} \frac{\partial f_1}{\partial x_1} & \cdots & \frac{\partial f_1}{\partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_m}{\partial x_1} & \cdots & \frac{\partial f_m}{\partial x_p} \end{pmatrix}.$$

Si $m = 1$, la Jacobiana coincide con el gradiente transpuesto.

8.11. Matriz Hessiana

Definición 8.5. La matriz Hessiana de una función escalar

$$f: \mathbb{R}^p \rightarrow \mathbb{R}$$

es

$$\mathbf{H}_f(\mathbf{x}) = \nabla^2 f(\mathbf{x}) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_p \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_p^2} \end{pmatrix}.$$

La Hessiana describe la curvatura local de la función.

Ejemplo 8.4. Para

$$f(x_1, x_2) = x_1^2 + 3x_1x_2 + 2x_2^2,$$

se tiene

$$\mathbf{H}_f = \begin{pmatrix} 2 & 3 \\ 3 & 4 \end{pmatrix}.$$

8.12. Diferenciales

La diferencial total de f es

$$df = \sum_{j=1}^p \frac{\partial f}{\partial x_j} dx_j.$$

En forma vectorial,

$$df = \nabla f(\mathbf{x})^\top d\mathbf{x}.$$

8.13. Regla de la cadena

Sea

$$\mathbf{z} = \mathbf{g}(\mathbf{x})$$

y

$$\mathbf{y} = \mathbf{f}(\mathbf{z}).$$

Entonces

$$\mathbf{J}_{f \circ g}(\mathbf{x}) = \mathbf{J}_f(g(\mathbf{x}))\mathbf{J}_g(\mathbf{x}).$$

Esta regla es la base matemática de la retropropagación en redes neuronales.

8.14. Ejemplo de regla de la cadena

Sea

$$z = x_1^2 + x_2^2,$$

y

$$f(z) = e^z.$$

Entonces

$$\frac{\partial f}{\partial x_1} = \frac{df}{dz} \frac{\partial z}{\partial x_1} = e^z(2x_1).$$

Por tanto,

$$\frac{\partial f}{\partial x_1} = 2x_1 e^{x_1^2 + x_2^2}.$$

Análogamente,

$$\frac{\partial f}{\partial x_2} = 2x_2 e^{x_1^2 + x_2^2}.$$

8.15. Derivación matricial básica

En aprendizaje automático, conviene utilizar identidades de cálculo matricial.

Si

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x},$$

entonces

$$\nabla_{\mathbf{x}} f = \mathbf{a}.$$

Si

$$f(\mathbf{x}) = \mathbf{x}^T \mathbf{x},$$

entonces

$$\nabla_{\mathbf{x}} f = 2\mathbf{x}.$$

Si

$$f(\mathbf{x}) = \mathbf{x}^T \mathbf{A} \mathbf{x},$$

entonces

$$\nabla_{\mathbf{x}} f = (\mathbf{A} + \mathbf{A}^T) \mathbf{x}.$$

Si $\mathbf{A}$ es simétrica,

$$\nabla_{\mathbf{x}} f = 2\mathbf{A} \mathbf{x}.$$

8.16. Expansión de Taylor de primer orden

Si f es diferenciable, cerca de $\mathbf{x}_0$ se aproxima por

$$f(\mathbf{x}) \approx f(\mathbf{x}_0) + \nabla f(\mathbf{x}_0)^T (\mathbf{x} - \mathbf{x}_0).$$

Esta es una aproximación lineal local.

8.17. Expansión de Taylor de segundo orden

Si f posee segundas derivadas,

$$f(\mathbf{x}) \approx f(\mathbf{x}_0) + \nabla f(\mathbf{x}_0)^\top (\mathbf{x} - \mathbf{x}_0) + \frac{1}{2}(\mathbf{x} - \mathbf{x}_0)^\top \mathbf{H}_f(\mathbf{x}_0)(\mathbf{x} - \mathbf{x}_0).$$

Los métodos de Newton utilizan esta aproximación.

8.18. Puntos críticos

Definición 8.6. Un punto $\mathbf{x}^*$ es crítico si

$$\nabla f(\mathbf{x}^*) = \mathbf{0}.$$

Un punto crítico puede ser:

- mínimo local;
- máximo local;
- punto silla.

8.19. Clasificación mediante la Hessiana

Si

$$\nabla f(\mathbf{x}^*) = \mathbf{0},$$

entonces:

- si $\mathbf{H}_f(\mathbf{x}^*)$ es definida positiva, $\mathbf{x}^*$ es mínimo local;
- si es definida negativa, es máximo local;
- si es indefinida, es punto silla;
- si es semidefinida, la prueba puede ser inconclusa.

8.20. Ejemplo de mínimo

Sea

$$f(x_1, x_2) = (x_1 - 2)^2 + (x_2 + 1)^2.$$

El gradiente es

$$\nabla f = \begin{pmatrix} 2(x_1 - 2) \\ 2(x_2 + 1) \end{pmatrix}.$$

Igualando a cero:

$$x_1 = 2, \quad x_2 = -1.$$

La Hessiana es

$$\mathbf{H}_f = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix},$$

que es definida positiva. Por tanto,

$$(2, -1)$$

es un mínimo global.

8.21. Optimización sin restricciones

Un problema de optimización sin restricciones tiene la forma

$$\min_{\theta \in \mathbb{R}^p} J(\theta).$$

Una condición necesaria de primer orden para un mínimo interior es

$$\nabla J(\theta^*) = \mathbf{0}.$$

Si además la Hessiana es definida positiva, el punto es un mínimo local estricto.

8.22. Funciones convexas

Definición 8.7. Una función

$$f : \mathbb{R}^p \rightarrow \mathbb{R}$$

es convexa si para todos $\mathbf{x}, \mathbf{y}$ y todo $\lambda \in [0, 1]$,

$$f(\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}) \leq \lambda f(\mathbf{x}) + (1 - \lambda) f(\mathbf{y}).$$

Geométricamente, el segmento entre dos puntos de la gráfica queda por encima de la gráfica.

8.23. Convexidad estricta

La función es estrictamente convexa si la desigualdad es estricta para

$$\mathbf{x} \neq \mathbf{y}$$

y

$$\lambda \in (0, 1).$$

Una función estrictamente convexa tiene a lo sumo un mínimo global.

8.24. Caracterización mediante el gradiente

Si f es diferenciable, es convexa si y solo si

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla f(\mathbf{x})^\top (\mathbf{y} - \mathbf{x})$$

para todos $\mathbf{x}, \mathbf{y}$.

8.25. Caracterización mediante la Hessiana

Si f es dos veces diferenciable, es convexa si

$$\mathbf{H}_f(\mathbf{x}) \succeq \mathbf{0}$$

para todo $\mathbf{x}$.

Es estrictamente convexa si la Hessiana es definida positiva.

8.26. Teorema del mínimo global

Teorema 8.1. *Si f es convexa y diferenciable, cualquier punto $\mathbf{x}^*$ que satisfice*

$$\nabla f(\mathbf{x}^*) = \mathbf{0}$$

es un mínimo global.

Este resultado es fundamental en regresión lineal, regresión logística y SVM.

8.27. Funciones cóncavas

Una función f es cóncava si $-f$ es convexa.

La maximización de una función cóncava equivale a la minimización de una función convexa.

La log-verosimilitud de muchos modelos estadísticos es cóncava.

8.28. Descenso por gradiente

Definición 8.8. El descenso por gradiente genera una sucesión

$$\theta^{(t+1)} = \theta^{(t)} - \eta_t \nabla J(\theta^{(t)}),$$

donde $\eta_t > 0$ es la tasa de aprendizaje.

El método avanza en dirección opuesta al gradiente.

8.29. Elección de la tasa de aprendizaje

Si η_t es demasiado grande, el algoritmo puede:

- oscilar;
- divergir;
- saltar sobre el mínimo.

Si es demasiado pequeña, la convergencia puede ser muy lenta.

8.30. Criterios de parada

El algoritmo puede detenerse cuando:

$$\|\nabla J(\theta^{(t)})\|_2 < \varepsilon,$$

o cuando

$$|J(\theta^{(t+1)}) - J(\theta^{(t)})| < \varepsilon,$$

o cuando se alcanza un número máximo de iteraciones.

8.31. Descenso por gradiente para una función cuadrática

Considere

$$J(\theta) = (\theta - 3)^2.$$

Entonces

$$J'(\theta) = 2(\theta - 3).$$

La actualización es

$$\theta^{(t+1)} = \theta^{(t)} - 2\eta(\theta^{(t)} - 3).$$

El mínimo se encuentra en

$$\theta^* = 3.$$

8.32. Descenso por gradiente por lotes

En aprendizaje supervisado,

$$J(\theta) = \frac{1}{n} \sum_{i=1}^n L_i(\theta).$$

El descenso por gradiente por lotes utiliza

$$\nabla J(\theta) = \frac{1}{n} \sum_{i=1}^n \nabla L_i(\theta).$$

Cada actualización utiliza toda la muestra.

8.33. Descenso por gradiente estocástico

El descenso estocástico utiliza una observación a la vez:

$$\theta^{(t+1)} = \theta^{(t)} - \eta_t \nabla L_i(\theta^{(t)}).$$

Es más ruidoso, pero puede ser más eficiente para bases grandes.

8.34. Mini-lotes

Una variante intermedia utiliza un subconjunto B_t :

$$\theta^{(t+1)} = \theta^{(t)} - \eta_t \frac{1}{|B_t|} \sum_{i \in B_t} \nabla L_i(\theta^{(t)}).$$

Esta estrategia es habitual en redes neuronales.

8.35. Método de Newton

El método de Newton utiliza la Hessiana:

$$\theta^{(t+1)} = \theta^{(t)} - \mathbf{H}_J(\theta^{(t)})^{-1} \nabla J(\theta^{(t)}).$$

Puede converger más rápido que el descenso por gradiente, pero requiere calcular e invertir la Hessiana.

8.36. Método de Newton-Raphson

En máxima verosimilitud, si se maximiza

$$\ell(\theta),$$

la actualización es

$$\theta^{(t+1)} = \theta^{(t)} - \mathbf{H}_\ell(\theta^{(t)})^{-1} \nabla \ell(\theta^{(t)}).$$

Este método se utiliza en regresión logística.

8.37. Problemas con restricciones

Un problema restringido tiene la forma

$$\min_{\mathbf{x}} f(\mathbf{x})$$

sujeito a

$$g_j(\mathbf{x}) = 0, \quad j = 1, \dots, m.$$

También pueden existir restricciones de desigualdad:

$$h_k(\mathbf{x}) \leq 0.$$

8.38. Multiplicadores de Lagrange

Definición 8.9. Para el problema

$$\min_{\mathbf{x}} f(\mathbf{x})$$

sujeito a

$$g(\mathbf{x}) = 0,$$

se define el Lagrangiano

$$\mathcal{L}(\mathbf{x}, \lambda) = f(\mathbf{x}) + \lambda g(\mathbf{x}).$$

Las condiciones de primer orden son

$$\nabla_{\mathbf{x}} \mathcal{L} = \mathbf{0},$$

y

$$g(\mathbf{x}) = 0.$$

8.39. Ejemplo de Lagrange

Minimizar

$$f(x_1, x_2) = x_1^2 + x_2^2$$

sujeito a

$$x_1 + x_2 = 1.$$

El Lagrangiano es

$$\mathcal{L} = x_1^2 + x_2^2 + \lambda(x_1 + x_2 - 1).$$

Las condiciones son

$$2x_1 + \lambda = 0,$$

$$2x_2 + \lambda = 0,$$

$$x_1 + x_2 = 1.$$

De las dos primeras,

$$x_1 = x_2.$$

Por tanto,

$$x_1 = x_2 = \frac{1}{2}.$$

8.40. Relación con PCA

En PCA se resuelve

$$\max_{\mathbf{a}} \mathbf{a}^T \Sigma \mathbf{a}$$

sujeto a

$$\mathbf{a}^T \mathbf{a} = 1.$$

El Lagrangiano es

$$\mathcal{L} = \mathbf{a}^T \Sigma \mathbf{a} - \lambda(\mathbf{a}^T \mathbf{a} - 1).$$

Al derivar,

$$2\Sigma \mathbf{a} - 2\lambda \mathbf{a} = \mathbf{0}.$$

Por tanto,

$$\Sigma \mathbf{a} = \lambda \mathbf{a}.$$

Así, las direcciones principales son vectores propios de la matriz de covarianza.

8.41. Restricciones de desigualdad y condiciones KKT

Para un problema

$$\min_{\mathbf{x}} f(\mathbf{x})$$

sujeto a

$$g_i(\mathbf{x}) \leq 0,$$

las condiciones de Karush-Kuhn-Tucker incluyen:

1. estacionariedad;
2. factibilidad primal;
3. factibilidad dual;
4. complementariedad.

En forma simplificada:

$$\nabla f(\mathbf{x}) + \sum_i \lambda_i \nabla g_i(\mathbf{x}) = \mathbf{0},$$

$$g_i(\mathbf{x}) \leq 0,$$

$$\lambda_i \geq 0,$$

$$\lambda_i g_i(\mathbf{x}) = 0.$$

Estas condiciones son fundamentales en máquinas de vectores de soporte.

8.42. Funciones de pérdida

Una función de pérdida mide el error de una predicción.

8.42.1. Pérdida cuadrática

$$L(y, \hat{y}) = (y - \hat{y})^2.$$

8.42.2. Pérdida absoluta

$$L(y, \hat{y}) = |y - \hat{y}|.$$

8.42.3. Pérdida logística

Para $y \in \{0, 1\}$,

$$L(y, \pi) = -[y \log \pi + (1 - y) \log(1 - \pi)].$$

8.42.4. Pérdida hinge

Para $y \in \{-1, 1\}$,

$$L(y, f(\mathbf{x})) = \max\{0, 1 - yf(\mathbf{x})\}.$$

8.43. Riesgo empírico

La función objetivo habitual es

$$\widehat{R}_n(f) = \frac{1}{n} \sum_{i=1}^n L(y_i, f(\mathbf{x}_i)).$$

El entrenamiento consiste en resolver

$$\hat{f} = \arg \min_{f \in \mathcal{F}} \widehat{R}_n(f).$$

8.44. Regularización

Para controlar la complejidad se añade una penalización:

$$\hat{\theta} = \arg \min_{\theta} \{J(\theta) + \lambda \Omega(\theta)\}.$$

Por ejemplo, con penalización cuadrática:

$$\Omega(\theta) = \|\theta\|_2^2.$$

8.45. Relación con regresión lineal

La función de pérdida es

$$J(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|_2^2.$$

Equivalentemente,

$$J(\beta) = (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta).$$

El gradiente es

$$\nabla_{\beta} J = -2\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\beta).$$

Igualando a cero,

$$\mathbf{X}^\top \mathbf{X} \hat{\beta} = \mathbf{X}^\top \mathbf{y}.$$

8.46. Relación con regresión logística

La log-verosimilitud es

$$\ell(\beta) = \sum_{i=1}^n [y_i \log \pi_i + (1 - y_i) \log(1 - \pi_i)].$$

Su gradiente es

$$\nabla \ell(\beta) = \mathbf{X}^T(\mathbf{y} - \pi).$$

La estimación se realiza mediante métodos iterativos.

8.47. Relación con redes neuronales

Una red neuronal compone funciones:

$$\mathbf{a}^{(l)} = \phi^{(l)}(\mathbf{W}^{(l)}\mathbf{a}^{(l-1)} + \mathbf{b}^{(l)}).$$

La retropropagación aplica repetidamente la regla de la cadena para calcular gradientes respecto de todos los parámetros.

8.48. Conexión con R

```
# Función cuadrática
f <- function(theta) {
  (theta - 3)^2
}

# Derivada
grad_f <- function(theta) {
  2 * (theta - 3)
}

# Descenso por gradiente
theta <- 0
eta <- 0.1

for (iter in 1:50) {
  theta <- theta - eta * grad_f(theta)
}

theta

# Optimización con optim()
resultado <- optim(
```

```

    par = 0,
    fn = f,
    method = "BFGS"
)

resultado$par

```

8.49. Ejemplo integrado

Considere

$$J(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2.$$

Las derivadas parciales son

$$\frac{\partial J}{\partial \beta_0} = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i),$$

y

$$\frac{\partial J}{\partial \beta_1} = -2 \sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i).$$

Igualando ambas expresiones a cero se obtienen las ecuaciones normales de regresión lineal simple.

Este ejemplo muestra cómo una función de pérdida se transforma en un sistema de ecuaciones mediante cálculo diferencial.

8.50. Errores frecuentes

1. Confundir derivada parcial con derivada total.
2. Utilizar el gradiente con una orientación matricial incorrecta.
3. Suponer que todo punto crítico es un mínimo.
4. Confundir Hessiana semidefinida con definida positiva.
5. Creer que una tasa de aprendizaje mayor siempre acelera la convergencia.
6. Ignorar la escala de las variables en métodos de gradiente.
7. Aplicar Newton cuando la Hessiana es singular o mal condicionada.
8. Suponer que todo problema de aprendizaje es convexo.
9. Confundir máximo de log-verosimilitud con mínimo de pérdida sin cambiar el signo.

10. Ignorar las restricciones al utilizar multiplicadores de Lagrange.

8.51. Ejercicios conceptuales

1. Explique la interpretación geométrica del gradiente.
2. ¿Qué información proporciona la Hessiana?
3. ¿Cuál es la diferencia entre una función convexa y una estrictamente convexa?
4. ¿Por qué un punto estacionario de una función convexa es mínimo global?
5. ¿Qué diferencia existe entre descenso por gradiente y método de Newton?
6. ¿Por qué la regla de la cadena es esencial en redes neuronales?
7. ¿Qué función cumplen los multiplicadores de Lagrange?
8. ¿Qué relación existe entre PCA y un problema de optimización restringida?
9. ¿Qué significa minimizar el riesgo empírico?
10. ¿Qué función cumple la regularización?

8.52. Ejercicios de derivación

Sea

$$f(x_1, x_2) = 3x_1^2 + 2x_1x_2 + 4x_2^2 - 6x_1 + 2x_2.$$

Calcule:

1. $\frac{\partial f}{\partial x_1}$;
2. $\frac{\partial f}{\partial x_2}$;
3. ∇f ;
4. $\mathbf{H}_f$;
5. los puntos críticos;
6. clasifique cada punto crítico.

8.53. Ejercicio de regla de la cadena

Sean

$$z_1 = x_1 + x_2,$$

$$z_2 = x_1x_2,$$

y

$$f(z_1, z_2) = z_1^2 + e^{z_2}.$$

Calcule:

1. $\frac{\partial f}{\partial x_1}$;
2. $\frac{\partial f}{\partial x_2}$;
3. la Jacobiana de (z_1, z_2) ;
4. verifique el resultado mediante la regla de la cadena matricial.

8.54. Ejercicio de descenso por gradiente

Considere

$$J(\theta) = (\theta - 5)^2.$$

Use:

$$\theta^{(0)} = 0,$$

y

$$\eta = 0.2.$$

Calcule manualmente las primeras cinco iteraciones.

8.55. Ejercicio de Lagrange

Minimice

$$f(x_1, x_2) = x_1^2 + 4x_2^2$$

sujeto a

$$x_1 + x_2 = 3.$$

1. Construya el Lagrangiano.

2. Obtenga las condiciones de primer orden.
3. Resuelva el sistema.
4. Verifique la naturaleza del punto obtenido.

8.56. Ejercicio aplicado a regresión

Sea

$$J(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|_2^2.$$

1. Expanda la expresión.
2. Calcule el gradiente respecto de β .
3. Obtenga las ecuaciones normales.
4. Explique bajo qué condición existe una solución única.
5. Interprete geoméricamente la solución.

8.57. Resumen

En este capítulo se estudiaron funciones de varias variables, derivadas parciales, gradientes, Jacobianas, Hessianas, diferenciales y regla de la cadena.

También se desarrollaron aproximaciones de Taylor, puntos críticos, clasificación mediante la Hessiana, convexidad, descenso por gradiente, métodos de Newton y problemas restringidos mediante multiplicadores de Lagrange y condiciones KKT.

Finalmente, se relacionaron estas herramientas con regresión lineal, regresión logística, PCA, SVM y redes neuronales. Estos conceptos permitirán derivar formalmente los algoritmos de los capítulos posteriores.

Parte II

II. Fundamentos del aprendizaje automático

9 Formulación matemática del aprendizaje supervisado

9.1. Introducción

El aprendizaje supervisado estudia métodos capaces de construir una regla de predicción a partir de observaciones etiquetadas. Cada observación contiene un conjunto de características y una respuesta conocida. El objetivo consiste en utilizar esa información para predecir correctamente la respuesta de nuevas observaciones.

Desde el punto de vista matemático, el aprendizaje supervisado puede formularse como un problema de selección de funciones. Se dispone de una familia de modelos posibles y se busca aquel que minimice una medida de error, no solamente sobre los datos observados, sino también sobre datos futuros provenientes del mismo proceso generador.

Esta distinción entre ajuste y generalización es central. Un modelo puede describir muy bien la muestra de entrenamiento y, sin embargo, producir predicciones deficientes fuera de ella. Por esta razón, la teoría del aprendizaje automático estudia funciones de pérdida, riesgo esperado, riesgo empírico, complejidad de modelos, regularización y validación.

9.2. Objetivos

Al finalizar el capítulo, el lector podrá:

1. formular matemáticamente un problema de aprendizaje supervisado;
2. distinguir entre espacio de entrada y espacio de salida;
3. interpretar una muestra de entrenamiento;
4. definir una función objetivo desconocida;
5. distinguir modelo, hipótesis y espacio de hipótesis;
6. comprender funciones de pérdida;
7. definir riesgo esperado y riesgo empírico;
8. interpretar el principio de minimización del riesgo empírico;
9. distinguir error de entrenamiento y error de generalización;
10. comprender sobreajuste y subajuste;
11. analizar el compromiso entre sesgo y varianza;

12. comprender regularización y complejidad de modelos;
13. interpretar ruido irreducible;
14. relacionar estos conceptos con regresión y clasificación.

9.3. Espacio de entrada

Definición 9.1. El **espacio de entrada** o espacio de características es el conjunto de todos los posibles vectores de atributos.

Se denota por

$$\mathcal{X}.$$

Frecuentemente,

$$\mathcal{X} \subseteq \mathbb{R}^p.$$

Cada observación se representa mediante

$$\mathbf{x} = \begin{pmatrix} x_1 \\ \vdots \\ x_p \end{pmatrix}.$$

Por ejemplo, en un problema ambiental:

$$\mathbf{x} = \begin{pmatrix} \text{PM10} \\ \text{temperatura} \\ \text{humedad} \\ \text{velocidad del viento} \end{pmatrix}.$$

9.4. Espacio de salida

Definición 9.2. El **espacio de salida** es el conjunto de posibles respuestas.

Se denota por

$$\mathcal{Y}.$$

En regresión,

$$\mathcal{Y} \subseteq \mathbb{R}.$$

En clasificación binaria,

$$\mathcal{Y} = \{0, 1\}$$

o

$$\mathcal{Y} = \{-1, 1\}.$$

En clasificación multiclase,

$$\mathcal{Y} = \{1, \dots, K\}.$$

9.5. Variable aleatoria conjunta

Se considera un par aleatorio

$$(\mathbf{X}, Y)$$

con distribución conjunta desconocida

$$P_{\mathbf{X}, Y}.$$

El vector $\mathbf{X}$ representa las características y Y la respuesta.

La distribución conjunta determina:

- qué observaciones son más probables;
- cómo se relacionan características y respuesta;
- cuánto ruido existe;
- cuál es la mejor regla de predicción posible.

9.6. Muestra de entrenamiento

Definición 9.3. Una muestra de entrenamiento es

$$\mathcal{D}_n = \{(\mathbf{x}_i, y_i)\}_{i=1}^n,$$

donde cada par es una realización de $(\mathbf{X}, Y)$.

Bajo el supuesto iid,

$$(\mathbf{x}_i, y_i) \stackrel{\text{iid}}{\sim} P_{\mathbf{X}, Y}.$$

La muestra contiene información parcial sobre la distribución verdadera.

9.7. Función objetivo desconocida

Se supone que existe una relación subyacente entre entrada y salida. Idealmente puede representarse mediante una función

$$f^* : \mathcal{X} \rightarrow \mathcal{Y}.$$

Esta función no se conoce directamente.

En regresión se suele escribir

$$Y = f^*(\mathbf{X}) + \varepsilon,$$

donde

$$\mathbb{E}(\varepsilon \mid \mathbf{X}) = 0.$$

El término ε representa ruido o variabilidad no explicada.

9.8. Hipótesis

Definición 9.4. Una **hipótesis** es una función candidata

$$f : \mathcal{X} \rightarrow \mathcal{Y}$$

que intenta aproximar la relación verdadera.

Por ejemplo, en regresión lineal,

$$f(\mathbf{x}) = \beta_0 + \beta^\top \mathbf{x}.$$

En clasificación mediante k -NN, la hipótesis se define a partir de las etiquetas de los vecinos más cercanos.

9.9. Espacio de hipótesis

Definición 9.5. El **espacio de hipótesis** es la familia de funciones candidatas entre las cuales se seleccionará el modelo.

Se denota por

$$\mathcal{F}.$$

Ejemplos:

9.9.1. Modelos lineales

$$\mathcal{F} = \left\{ f(\mathbf{x}) = \beta_0 + \beta^\top \mathbf{x} : \beta \in \mathbb{R}^p \right\}.$$

9.9.2. Árboles de decisión

$$\mathcal{F} = \{\text{árboles con profundidad máxima } d\}.$$

9.9.3. Redes neuronales

$$\mathcal{F} = \{\text{redes con una arquitectura determinada}\}.$$

La elección de $\mathcal{F}$ determina la complejidad del problema.

9.10. Parámetros e hiperparámetros

Los parámetros son cantidades aprendidas a partir de los datos:

$$\theta.$$

Ejemplos:

- coeficientes de regresión;
- pesos de una red neuronal;
- puntos de corte de un árbol.

Los hiperparámetros controlan la estructura del aprendizaje:

- número de vecinos k ;
- profundidad máxima de un árbol;
- parámetro de regularización λ ;
- tasa de aprendizaje;
- número de capas.

Los hiperparámetros no se estiman directamente mediante el mismo criterio utilizado para los parámetros; suelen seleccionarse mediante validación.

9.11. Función de pérdida

Definición 9.6. Una función de pérdida es una función

$$L : \mathcal{Y} \times \mathcal{Y} \rightarrow [0, \infty)$$

que cuantifica el costo de predecir $\hat{y}$ cuando la respuesta verdadera es y .

Se escribe

$$L(y, \hat{y}).$$

9.12. Pérdida cuadrática

En regresión,

$$L(y, \hat{y}) = (y - \hat{y})^2.$$

Penaliza con mayor intensidad los errores grandes.

9.13. Pérdida absoluta

$$L(y, \hat{y}) = |y - \hat{y}|.$$

Es más robusta frente a valores extremos.

9.14. Pérdida 0-1

En clasificación,

$$L(y, \hat{y}) = \mathbb{I}(y \neq \hat{y}).$$

La pérdida vale cero si la clasificación es correcta y uno si es incorrecta.

9.15. Pérdida logística

Para clasificación binaria,

$$L(y, \pi) = -[y \log \pi + (1 - y) \log(1 - \pi)].$$

Esta pérdida surge de la distribución Bernoulli.

9.16. Pérdida hinge

En SVM,

$$L(y, f(\mathbf{x})) = \max\{0, 1 - yf(\mathbf{x})\}.$$

Penaliza observaciones mal clasificadas o clasificadas con margen insuficiente.

9.17. Riesgo esperado

Definición 9.7. El riesgo esperado de una función f es

$$R(f) = \mathbb{E}_{(\mathbf{X}, Y)} [L(Y, f(\mathbf{X}))].$$

El riesgo esperado mide el error promedio sobre toda la distribución verdadera.

En forma integral,

$$R(f) = \int L(y, f(\mathbf{x})) dP_{\mathbf{X}, Y}(\mathbf{x}, y).$$

El objetivo ideal es encontrar

$$f_{\mathcal{F}}^* = \arg \min_{f \in \mathcal{F}} R(f).$$

9.18. Riesgo de Bayes

Si se permite elegir entre todas las funciones medibles, el menor riesgo posible es el riesgo de Bayes:

$$R^* = \inf_f R(f).$$

Una función que alcanza ese riesgo se denomina regla de Bayes.

9.19. Riesgo empírico

Como la distribución verdadera es desconocida, se utiliza la muestra.

Definición 9.8. El riesgo empírico es

$$\widehat{R}_n(f) = \frac{1}{n} \sum_{i=1}^n L(y_i, f(\mathbf{x}_i)).$$

Este riesgo puede calcularse directamente.

9.20. Minimización del riesgo empírico

Definición 9.9. El principio de minimización del riesgo empírico selecciona

$$\hat{f}_n = \arg \min_{f \in \mathcal{F}} \widehat{R}_n(f).$$

Esta idea está detrás de numerosos algoritmos.

9.20.1. Regresión lineal

$$\hat{\beta} = \arg \min_{\beta} \frac{1}{n} \sum_{i=1}^n (y_i - \beta_0 - \beta^\top \mathbf{x}_i)^2.$$

9.20.2. Clasificación

$$\hat{f} = \arg \min_f \frac{1}{n} \sum_{i=1}^n \mathbb{I}(y_i \neq f(\mathbf{x}_i)).$$

9.21. Error de entrenamiento

El error de entrenamiento es el riesgo empírico evaluado sobre la muestra utilizada para ajustar el modelo:

$$\text{Err}_{train} = \widehat{R}_n(\hat{f}).$$

Un error de entrenamiento bajo no garantiza buen desempeño futuro.

9.22. Error de prueba

El error de prueba se estima usando observaciones no utilizadas durante el ajuste:

$$\text{Err}_{test} = \frac{1}{m} \sum_{j=1}^m L(y_j^{test}, \hat{f}(\mathbf{x}_j^{test})).$$

El error de prueba aproxima el error de generalización.

9.23. Generalización

Definición 9.10. La **generalización** es la capacidad de un modelo para realizar predicciones adecuadas sobre observaciones nuevas.

Un modelo generaliza bien cuando

$$R(\hat{f})$$

es pequeño.

9.24. Brecha de generalización

La diferencia

$$R(\hat{f}) - \widehat{R}_n(\hat{f})$$

se denomina brecha de generalización.

Una brecha grande indica que el desempeño observado en entrenamiento es demasiado optimista.

9.25. Sobreajuste

Definición 9.11. Existe sobreajuste cuando un modelo se adapta excesivamente a la muestra de entrenamiento y captura ruido o particularidades que no se repiten en datos nuevos.

Características:

- error de entrenamiento muy bajo;
- error de prueba alto;

- elevada complejidad;
- alta sensibilidad a pequeñas variaciones de la muestra.

9.26. Subajuste

Definición 9.12. Existe subajuste cuando el modelo es demasiado simple para representar la relación subyacente.

Características:

- error de entrenamiento alto;
- error de prueba alto;
- incapacidad para capturar patrones importantes.

9.27. Complejidad del modelo

La complejidad puede asociarse con:

- número de parámetros;
- profundidad de un árbol;
- grado de un polinomio;
- número de capas de una red;
- flexibilidad del espacio de hipótesis;
- dimensión VC;
- norma de los parámetros.

Un espacio de hipótesis demasiado amplio puede reducir el error de entrenamiento, pero aumentar el riesgo de sobreajuste.

9.28. Ejemplo polinomial

Considere modelos

$$f_d(x) = \beta_0 + \beta_1 x + \cdots + \beta_d x^d.$$

Si d es pequeño, puede existir subajuste.

Si d es muy grande, puede existir sobreajuste.

El objetivo es seleccionar un nivel de complejidad que equilibre ajuste y generalización.

9.29. Regularización

Definición 9.13. La regularización añade una penalización a la función objetivo para controlar la complejidad del modelo.

La forma general es

$$\hat{f} = \arg \min_{f \in \mathcal{F}} \{ \widehat{R}_n(f) + \lambda \Omega(f) \}.$$

Aquí:

- $\Omega(f)$ mide complejidad;
- $\lambda \geq 0$ controla la intensidad de la penalización.

9.30. Regularización L2

Para un vector de parámetros,

$$\Omega(\theta) = \|\theta\|_2^2.$$

Entonces,

$$\hat{\theta} = \arg \min_{\theta} \{ \widehat{R}_n(\theta) + \lambda \|\theta\|_2^2 \}.$$

Esta penalización reduce la magnitud de los parámetros.

9.31. Regularización L1

$$\Omega(\theta) = \|\theta\|_1 = \sum_{j=1}^p |\theta_j|.$$

La penalización L1 puede producir parámetros exactamente iguales a cero y favorecer selección de variables.

9.32. Sesgo y varianza

El error de predicción puede analizarse mediante sesgo, varianza y ruido irreducible.

Supóngase

$$Y = f^*(\mathbf{X}) + \varepsilon,$$

con

$$\mathbb{E}(\varepsilon) = 0, \quad \text{Var}(\varepsilon) = \sigma^2.$$

Para una observación fija $\mathbf{x}_0$,

$$\mathbb{E} \left[(Y - \hat{f}(\mathbf{x}_0))^2 \right] = \text{Bias}^2 + \text{Var} + \sigma^2.$$

9.33. Sesgo del modelo

El sesgo se define como

$$\text{Bias}[\hat{f}(\mathbf{x}_0)] = \mathbb{E}[\hat{f}(\mathbf{x}_0)] - f^*(\mathbf{x}_0).$$

Un modelo muy rígido suele tener sesgo alto.

9.34. Varianza del modelo

La varianza es

$$\text{Var}[\hat{f}(\mathbf{x}_0)] = \mathbb{E} \left[\left(\hat{f}(\mathbf{x}_0) - \mathbb{E}[\hat{f}(\mathbf{x}_0)] \right)^2 \right].$$

Un modelo muy flexible suele tener varianza alta.

9.35. Ruido irreducible

El término

$$\sigma^2$$

representa variabilidad que no puede eliminarse mediante ningún modelo basado en las características disponibles.

Puede deberse a:

- errores de medición;
- variables omitidas;
- procesos inherentemente aleatorios;
- etiquetas incorrectas.

9.36. Compromiso entre sesgo y varianza

Al aumentar la complejidad:

- el sesgo tiende a disminuir;
- la varianza tiende a aumentar.

Al reducir la complejidad:

- el sesgo tiende a aumentar;
- la varianza tiende a disminuir.

La selección de modelos busca un equilibrio.

9.37. Error de aproximación

Incluso con infinitos datos, puede ocurrir que

$$f^* \notin \mathcal{F}.$$

El error debido a la limitación del espacio de hipótesis se denomina error de aproximación.

9.38. Error de estimación

La muestra es finita, por lo que la función seleccionada puede diferir del mejor elemento de $\mathcal{F}$.

Este componente se denomina error de estimación.

En términos conceptuales:

$$\text{error total} = \text{error de aproximación} + \text{error de estimación} + \text{ruido}.$$

9.39. Selección de modelos

La selección de modelos consiste en elegir:

- una familia de hipótesis;
- una estructura;
- hiperparámetros;
- intensidad de regularización.

No debe hacerse utilizando el conjunto de prueba final.

9.40. División de datos

Una estrategia común divide los datos en:

1. entrenamiento;
2. validación;
3. prueba.

El conjunto de entrenamiento ajusta parámetros.

El conjunto de validación selecciona hiperparámetros.

El conjunto de prueba evalúa el modelo final.

9.41. Validación cruzada

Cuando los datos son limitados, puede emplearse validación cruzada.

La muestra se divide en K subconjuntos:

$$I_1, \dots, I_K.$$

El error de validación cruzada es

$$CV_K = \frac{1}{K} \sum_{k=1}^K \frac{1}{|I_k|} \sum_{i \in I_k} L(y_i, \hat{f}^{(-k)}(\mathbf{x}_i)).$$

9.42. Clasificación óptima bajo pérdida 0-1

En clasificación, para una observación $\mathbf{x}$, el riesgo condicional de predecir la clase k es

$$R(k | \mathbf{x}) = P(Y \neq k | \mathbf{x}).$$

Como

$$P(Y \neq k | \mathbf{x}) = 1 - P(Y = k | \mathbf{x}),$$

la mejor decisión es

$$f^*(\mathbf{x}) = \arg \max_k P(Y = k | \mathbf{x}).$$

Esta es la regla de Bayes.

9.43. Regresión óptima bajo pérdida cuadrática

Para una observación fija $\mathbf{x}$, se desea minimizar

$$\mathbb{E}[(Y - a)^2 | \mathbf{X} = \mathbf{x}].$$

La solución es

$$a = \mathbb{E}[Y | \mathbf{X} = \mathbf{x}].$$

Por tanto, la función óptima bajo pérdida cuadrática es

$$f^*(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}].$$

9.44. Regresión óptima bajo pérdida absoluta

Si se minimiza

$$\mathbb{E}[|Y - a| \mid \mathbf{X} = \mathbf{x}],$$

la solución es una mediana condicional de Y dado $\mathbf{X} = \mathbf{x}$.

Esto muestra que diferentes funciones de pérdida conducen a diferentes objetivos estadísticos.

9.45. Aprendizaje paramétrico

En un modelo paramétrico,

$$f_\theta \in \mathcal{F}$$

se describe mediante un número finito de parámetros.

Ejemplo:

$$f_\beta(\mathbf{x}) = \beta_0 + \beta^\top \mathbf{x}.$$

9.46. Aprendizaje no paramétrico

Los métodos no paramétricos no fijan una forma funcional rígida.

Ejemplos:

- k -NN;
- árboles;
- estimadores kernel.

La complejidad puede crecer con el tamaño de la muestra.

9.47. Aprendizaje determinista y probabilístico

Un modelo determinista produce directamente

$$\hat{y} = f(\mathbf{x}).$$

Un modelo probabilístico estima una distribución:

$$P(Y \mid \mathbf{X} = \mathbf{x}).$$

Por ejemplo, regresión logística estima

$$P(Y = 1 \mid \mathbf{x}).$$

9.48. Relación con regresión lineal

En regresión lineal se minimiza

$$\widehat{R}_n(\beta) = \frac{1}{n} \sum_{i=1}^n (y_i - \beta_0 - \beta^\top \mathbf{x}_i)^2.$$

El espacio de hipótesis es lineal en los parámetros.

9.49. Relación con regresión logística

En regresión logística se minimiza la pérdida logarítmica:

$$\widehat{R}_n(\beta) = -\frac{1}{n} \sum_{i=1}^n [y_i \log \pi_i + (1 - y_i) \log(1 - \pi_i)].$$

9.50. Relación con el método de vecinos más cercanos

En k -NN, el espacio de hipótesis depende directamente de la muestra. La complejidad se controla mediante k :

- k pequeño: baja sesgo, alta varianza;
- k grande: mayor sesgo, menor varianza.

9.51. Relación con árboles

En árboles de decisión, la profundidad controla complejidad:

- árboles profundos pueden sobreajustar;
- árboles poco profundos pueden subajustar.

La poda actúa como regularización estructural.

9.52. Relación con redes neuronales

En redes neuronales, la complejidad depende de:

- número de capas;
- número de neuronas;
- número de parámetros;
- funciones de activación;
- regularización;
- cantidad de datos.

9.53. Conexión con R

```
set.seed(123)

# Datos simulados
n <- 100
x <- runif(n, -2, 2)
y <- 1 + 2 * x + rnorm(n, sd = 1)

datos <- data.frame(x = x, y = y)

# División entrenamiento-prueba
indices <- sample(seq_len(n), size = 0.8 * n)

entrenamiento <- datos[indices, ]
prueba <- datos[-indices, ]

# Modelo
modelo <- lm(y ~ x, data = entrenamiento)
```

```
# Predicciones
pred <- predict(modelo, newdata = prueba)

# Error cuadrático medio de prueba
mean((prueba$y - pred)^2)
```

9.54. Ejemplo integrado

Supóngase que se comparan tres modelos para predecir una variable continua:

1. modelo constante;
2. modelo lineal;
3. polinomio de grado 12.

Resultados hipotéticos:

Modelo	Error de entrenamiento	Error de prueba
Constante	18.2	18.7
Lineal	5.3	5.8
Polinomio grado 12	0.4	14.9

Interpretación:

- el modelo constante presenta subajuste;
- el modelo lineal logra mejor equilibrio;
- el polinomio de grado 12 presenta sobreajuste.

9.55. Errores frecuentes

1. Suponer que menor error de entrenamiento implica mejor modelo.
2. Utilizar el conjunto de prueba para seleccionar hiperparámetros.
3. Confundir parámetros con hiperparámetros.
4. Suponer que toda regularización mejora siempre el modelo.
5. Ignorar el ruido irreducible.
6. Confundir sesgo estadístico con error sistemático de medición.
7. Evaluar un modelo con los mismos datos usados para ajustarlo.
8. Elegir una función de pérdida sin considerar el objetivo real.
9. Comparar modelos sin utilizar la misma partición o procedimiento de validación.
10. Interpretar una brecha pequeña como garantía absoluta de buen desempeño.

9.56. Ejercicios conceptuales

1. Explique la diferencia entre $\mathcal{X}$ y $\mathcal{Y}$.
2. ¿Qué diferencia existe entre una hipótesis y el espacio de hipótesis?
3. ¿Qué significa minimizar el riesgo esperado?
4. ¿Por qué se utiliza el riesgo empírico?
5. Explique la diferencia entre error de entrenamiento y error de prueba.
6. ¿Qué es la brecha de generalización?
7. Explique sobreajuste y subajuste.
8. ¿Qué papel cumple la regularización?
9. ¿Qué diferencia existe entre sesgo y varianza?
10. ¿Qué representa el ruido irreducible?

9.57. Ejercicio de riesgo empírico

Considere las respuestas verdaderas

$$\mathbf{y} = \begin{pmatrix} 2 \\ 4 \\ 5 \\ 7 \end{pmatrix}$$

y las predicciones

$$\hat{\mathbf{y}} = \begin{pmatrix} 3 \\ 3 \\ 6 \\ 8 \end{pmatrix}.$$

Calcule:

1. la pérdida cuadrática individual;
2. el riesgo empírico cuadrático;
3. la pérdida absoluta individual;
4. el riesgo empírico absoluto.

9.58. Ejercicio de clasificación

Sean las etiquetas verdaderas

$$(1, 0, 1, 1, 0, 0, 1, 0)$$

y las predicciones

$$(1, 1, 1, 0, 0, 0, 1, 1).$$

Calcule el riesgo empírico bajo pérdida 0-1.

9.59. Ejercicio de regularización

Considere

$$J(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda\|\beta\|_2^2.$$

1. Explique el papel de cada término.
2. Analice qué ocurre cuando $\lambda = 0$.
3. Analice qué ocurre cuando λ es muy grande.
4. Derive el gradiente.
5. Obtenga la solución formal.

9.60. Ejercicio de sesgo y varianza

Compare conceptualmente:

1. un modelo lineal;
2. un árbol profundo;
3. un k -NN con $k = 1$;
4. un k -NN con $k = n$.

Indique cuáles tienden a tener mayor sesgo y cuáles mayor varianza.

9.61. Ejercicio aplicado

Se desea predecir la concentración diaria de PM10 utilizando temperatura, humedad y velocidad del viento.

1. Defina $\mathcal{X}$.
2. Defina $\mathcal{Y}$.
3. Escriba la muestra de entrenamiento.

4. Proponga una función de pérdida.
5. Defina el riesgo esperado.
6. Defina el riesgo empírico.
7. Explique cómo evaluaría la generalización.
8. Describa una situación de sobreajuste.
9. Describa una situación de subajuste.
10. Proponga una estrategia de regularización o validación.

9.62. Resumen

En este capítulo se formuló matemáticamente el aprendizaje supervisado como un problema de selección de funciones. Se definieron espacios de entrada y salida, muestras de entrenamiento, hipótesis, espacios de hipótesis, parámetros e hiperparámetros.

También se estudiaron funciones de pérdida, riesgo esperado, riesgo empírico, minimización del riesgo empírico y generalización.

Finalmente, se analizaron sobreajuste, subajuste, complejidad, regularización, sesgo, varianza, ruido irreducible y selección de modelos. Estos conceptos servirán como base para la teoría de clasificación y para los algoritmos específicos de los capítulos posteriores.

10 Teoría matemática de la clasificación

10.1. Introducción

La clasificación consiste en asignar una etiqueta discreta a una observación a partir de sus características. En un problema binario, la respuesta puede pertenecer a una de dos clases; en un problema multiclase, puede pertenecer a una de varias categorías.

Desde el punto de vista matemático, un clasificador es una función que divide el espacio de características en regiones de decisión. Cada región se asocia con una clase. La teoría de clasificación estudia cómo construir estas regiones, cómo medir el costo de los errores y cuál es la mejor regla de decisión posible bajo una distribución probabilística dada.

En este capítulo se desarrollan la regla de Bayes, el riesgo condicional, el error de Bayes, las fronteras de decisión y las principales métricas de evaluación.

10.2. Objetivos

Al finalizar el capítulo, el lector podrá:

1. formular un problema de clasificación binaria y multiclase;
2. definir una regla de decisión;
3. interpretar regiones y fronteras de decisión;
4. calcular riesgo condicional;
5. derivar la regla de Bayes;
6. interpretar el error de Bayes;
7. comprender pérdidas asimétricas;
8. construir una matriz de confusión;
9. calcular exactitud, error, sensibilidad, especificidad y precisión;
10. interpretar valor predictivo positivo y negativo;
11. comprender curvas ROC y área bajo la curva;
12. analizar el efecto del umbral de decisión;
13. extender la formulación al caso multiclase;
14. relacionar estos conceptos con algoritmos concretos.

10.3. Formulación de un problema de clasificación

Sea

$$\mathbf{X} \in \mathcal{X} \subseteq \mathbb{R}^p$$

un vector de características y sea

$$Y \in \mathcal{Y}$$

la etiqueta de clase.

En clasificación binaria,

$$\mathcal{Y} = \{0, 1\}$$

o

$$\mathcal{Y} = \{-1, 1\}.$$

En clasificación multiclase,

$$\mathcal{Y} = \{1, 2, \dots, K\}.$$

10.4. Clasificador

Definición 10.1. Un **clasificador** es una función

$$f : \mathcal{X} \rightarrow \mathcal{Y}.$$

Para una observación $\mathbf{x}$, la predicción es

$$\hat{y} = f(\mathbf{x}).$$

10.5. Regiones de decisión

Para cada clase k , se define la región

$$R_k = \{\mathbf{x} \in \mathcal{X} : f(\mathbf{x}) = k\}.$$

Las regiones satisfacen:

$$R_i \cap R_j = \emptyset, \quad i \neq j,$$

y

$$\bigcup_{k=1}^K R_k = \mathcal{X}.$$

10.6. Frontera de decisión

Definición 10.2. La frontera de decisión es el conjunto de puntos que separa dos o más regiones de clasificación.

En clasificación binaria, si el clasificador se basa en una función discriminante $g(\mathbf{x})$, puede definirse como

$$f(\mathbf{x}) = \begin{cases} 1, & g(\mathbf{x}) \geq 0, \\ 0, & g(\mathbf{x}) < 0. \end{cases}$$

La frontera de decisión es

$$\{\mathbf{x} : g(\mathbf{x}) = 0\}.$$

10.7. Frontera lineal

Si

$$g(\mathbf{x}) = \beta_0 + \beta^\top \mathbf{x},$$

entonces la frontera es el hiperplano

$$\beta_0 + \beta^T \mathbf{x} = 0.$$

10.8. Frontera no lineal

Si g contiene términos polinomiales, funciones kernel o composiciones no lineales, la frontera puede ser curva o altamente compleja.

10.9. Probabilidades posteriores

Para cada clase k , se define

$$\eta_k(\mathbf{x}) = P(Y = k \mid \mathbf{X} = \mathbf{x}).$$

Estas probabilidades satisfacen

$$\eta_k(\mathbf{x}) \geq 0$$

y

$$\sum_{k=1}^K \eta_k(\mathbf{x}) = 1.$$

10.10. Regla de clasificación por máxima probabilidad posterior

Una regla natural es seleccionar

$$f(\mathbf{x}) = \arg \max_k \eta_k(\mathbf{x}).$$

Esta regla será óptima bajo pérdida 0-1.

10.11. Función de pérdida general

Sea

$$L(j, k)$$

el costo de predecir la clase j cuando la clase verdadera es k .

En pérdida 0-1,

$$L(j, k) = \begin{cases} 0, & j = k, \\ 1, & j \neq k. \end{cases}$$

10.12. Riesgo condicional

Definición 10.3. El riesgo condicional de predecir la clase j dado $\mathbf{x}$ es

$$R(j | \mathbf{x}) = \sum_{k=1}^K L(j, k) P(Y = k | \mathbf{X} = \mathbf{x}).$$

La decisión óptima es

$$f^*(\mathbf{x}) = \arg \min_j R(j | \mathbf{x}).$$

10.13. Regla de Bayes bajo pérdida 0-1

Con pérdida 0-1,

$$R(j | \mathbf{x}) = 1 - P(Y = j | \mathbf{X} = \mathbf{x}).$$

Por tanto,

$$f^*(\mathbf{x}) = \arg \max_j P(Y = j | \mathbf{X} = \mathbf{x}).$$

Teorema 10.1. *Bajo pérdida 0-1, la regla que asigna a cada observación la clase con mayor probabilidad posterior minimiza el riesgo esperado de clasificación.*

10.14. Riesgo de Bayes

El riesgo mínimo posible es

$$R^* = P(f^*(\mathbf{X}) \neq Y).$$

También puede escribirse como

$$R^* = \mathbb{E} \left[1 - \max_k P(Y = k \mid \mathbf{X}) \right].$$

Este riesgo representa el error irreducible de clasificación.

10.15. Error de Bayes binario

En clasificación binaria,

$$\eta(\mathbf{x}) = P(Y = 1 \mid \mathbf{X} = \mathbf{x}).$$

La regla de Bayes es

$$f^*(\mathbf{x}) = \begin{cases} 1, & \eta(\mathbf{x}) \geq \frac{1}{2}, \\ 0, & \eta(\mathbf{x}) < \frac{1}{2}. \end{cases}$$

El error condicional mínimo es

$$\min\{\eta(\mathbf{x}), 1 - \eta(\mathbf{x})\}.$$

10.16. Regla de Bayes con densidades

Por el teorema de Bayes,

$$P(Y = k \mid \mathbf{x}) = \frac{p(\mathbf{x} \mid Y = k)P(Y = k)}{p(\mathbf{x})}.$$

Como el denominador es común a todas las clases,

$$f^*(\mathbf{x}) = \arg \max_k p(\mathbf{x} \mid Y = k)P(Y = k).$$

10.17. Funciones discriminantes

Se pueden definir funciones

$$g_k(\mathbf{x}) = \log p(\mathbf{x} \mid Y = k) + \log P(Y = k).$$

Entonces,

$$f^*(\mathbf{x}) = \arg \max_k g_k(\mathbf{x}).$$

El uso del logaritmo transforma productos en sumas.

10.18. Pérdidas asimétricas

En muchos problemas, los errores no tienen el mismo costo.

Sea clasificación binaria y considérese:

- C_{10} : costo de predecir 1 cuando la clase verdadera es 0;
- C_{01} : costo de predecir 0 cuando la clase verdadera es 1.

La regla óptima predice 1 si

$$C_{10}P(Y = 0 \mid \mathbf{x}) < C_{01}P(Y = 1 \mid \mathbf{x}).$$

Equivalentemente,

$$P(Y = 1 \mid \mathbf{x}) > \frac{C_{10}}{C_{10} + C_{01}}.$$

Por tanto, el umbral óptimo no siempre es 0.5.

10.19. Clasificación sensible al costo

Este enfoque es importante cuando:

- una enfermedad grave no debe pasar inadvertida;
- detectar fraude es más importante que evitar falsas alarmas;
- un accidente severo tiene un costo mucho mayor que uno leve;
- las clases están desbalanceadas.

10.20. Clasificación binaria probabilística

Un modelo probabilístico produce

$$\hat{\pi}(\mathbf{x}) = \widehat{P}(Y = 1 \mid \mathbf{x}).$$

Luego se define

$$\hat{y} = \begin{cases} 1, & \hat{\pi}(\mathbf{x}) \geq t, \\ 0, & \hat{\pi}(\mathbf{x}) < t, \end{cases}$$

donde t es el umbral.

10.21. Efecto del umbral

Al disminuir t :

- aumenta el número de positivos predichos;
- aumenta la sensibilidad;
- puede disminuir la especificidad.

Al aumentar t :

- disminuyen los positivos predichos;
- puede aumentar la especificidad;
- puede disminuir la sensibilidad.

10.22. Matriz de confusión

Para clasificación binaria:

Clase real / predicha	Positiva	Negativa
Positiva	Verdadero positivo (VP)	Falso negativo (FN)
Negativa	Falso positivo (FP)	Verdadero negativo (VN)

La suma total es

$$n = VP + VN + FP + FN.$$

10.23. Exactitud

Definición 10.4. La exactitud es

$$\text{Accuracy} = \frac{VP + VN}{VP + VN + FP + FN}.$$

10.24. Tasa de error

$$\text{Error} = \frac{FP + FN}{n}.$$

Además,

$$\text{Error} = 1 - \text{Accuracy}.$$

10.25. Sensibilidad

Definición 10.5. La sensibilidad o tasa de verdaderos positivos es

$$\text{Sensibilidad} = \frac{VP}{VP + FN}.$$

Mide la proporción de positivos reales correctamente detectados.

También se denomina:

- recall;
- true positive rate;
- tasa de detección.

10.26. Especificidad

Definición 10.6. La especificidad o tasa de verdaderos negativos es

$$\text{Especificidad} = \frac{VN}{VN + FP}.$$

10.27. Tasa de falsos positivos

$$\text{FPR} = \frac{FP}{FP + VN} = 1 - \text{Especificidad}.$$

10.28. Tasa de falsos negativos

$$\text{FNR} = \frac{FN}{FN + VP} = 1 - \text{Sensibilidad}.$$

10.29. Precisión positiva

Definición 10.7. La precisión o valor predictivo positivo es

$$\text{Precision} = \frac{VP}{VP + FP}.$$

Mide qué proporción de las predicciones positivas es correcta.

10.30. Valor predictivo negativo

$$\text{VPN} = \frac{VN}{VN + FN}.$$

10.31. Medida F1

La medida F1 es la media armónica entre precisión y sensibilidad:

$$F_1 = 2 \frac{\text{Precision} \cdot \text{Sensibilidad}}{\text{Precision} + \text{Sensibilidad}}.$$

Equivalentemente,

$$F_1 = \frac{2VP}{2VP + FP + FN}.$$

10.32. Exactitud balanceada

En clases desbalanceadas puede utilizarse

$$\text{Balanced Accuracy} = \frac{\text{Sensibilidad} + \text{Especificidad}}{2}.$$

10.33. Prevalencia

La prevalencia observada de la clase positiva es

$$\text{Prev} = \frac{VP + FN}{n}.$$

Los valores predictivos dependen de la prevalencia.

10.34. Ejemplo de matriz de confusión

Supóngase:

$$VP = 45, \quad FN = 5, \quad FP = 10, \quad VN = 40.$$

Entonces,

$$\text{Accuracy} = \frac{45 + 40}{100} = 0.85.$$

La sensibilidad es

$$\frac{45}{45 + 5} = 0.90.$$

La especificidad es

$$\frac{40}{40 + 10} = 0.80.$$

La precisión es

$$\frac{45}{45 + 10} \approx 0.818.$$

10.35. Limitaciones de la exactitud

Considere una base con:

- 990 observaciones negativas;
- 10 observaciones positivas.

Un clasificador que siempre predice negativo obtiene

$$\text{Accuracy} = \frac{990}{1000} = 0.99.$$

Sin embargo,

$$\text{Sensibilidad} = 0.$$

Por tanto, la exactitud puede ser engañosa en datos desbalanceados.

10.36. Curva ROC

Definición 10.8. La curva ROC representa la tasa de verdaderos positivos frente a la tasa de falsos positivos para distintos umbrales.

Sus ejes son:

$$x = \text{FPR},$$

$$y = \text{TPR}.$$

Cada umbral produce un punto en la curva.

10.37. Interpretación de la curva ROC

Un clasificador ideal se aproxima al punto

$$(0, 1).$$

Un clasificador aleatorio se aproxima a la diagonal

$$\text{TPR} = \text{FPR}.$$

10.38. Área bajo la curva

Definición 10.9. El área bajo la curva ROC se denota por AUC.

Puede interpretarse como la probabilidad de que el clasificador asigne una puntuación mayor a una observación positiva que a una negativa elegidas al azar.

Valores típicos:

- 0.5: discriminación aleatoria;
- cercano a 1: excelente discriminación;
- menor que 0.5: orden inverso sistemático.

10.39. Curva precisión-recall

En problemas con fuerte desbalance, puede ser más informativa la curva precisión-recall.

Esta curva representa:

Precision

frente a

Recall.

10.40. Calibración

Un clasificador está bien calibrado si, entre las observaciones con probabilidad predicha cercana a p , aproximadamente una proporción p pertenece realmente a la clase positiva.

Por ejemplo, entre observaciones con predicción 0.8, cerca del 80 % debería ser positiva.

10.41. Discriminación y calibración

Un modelo puede:

- discriminar bien pero estar mal calibrado;
- estar bien calibrado pero discriminar poco;
- cumplir ambas propiedades;
- no cumplir ninguna.

La AUC mide discriminación, no calibración.

10.42. Función de pérdida logarítmica

Para una observación binaria,

$$L(y, \pi) = -[y \log \pi + (1 - y) \log(1 - \pi)].$$

La pérdida penaliza con fuerza probabilidades muy confiadas pero incorrectas.

10.43. Brier score

El Brier score es

$$\text{Brier} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{\pi}_i)^2.$$

Evalúa predicciones probabilísticas y combina calibración con discriminación.

10.44. Clasificación multiclase

Para K clases,

$$\mathcal{Y} = \{1, \dots, K\}.$$

El clasificador produce

$$\hat{y} = \arg \max_k \widehat{P}(Y = k \mid \mathbf{x}).$$

10.45. Matriz de confusión multiclase

La matriz contiene $K \times K$ entradas.

La posición (i, j) representa el número de observaciones cuya clase real es i y cuya clase predicha es j .

10.46. Métricas por clase

Para cada clase k , puede considerarse:

- clase k como positiva;
- todas las demás como negativas.

Así se calculan sensibilidad, especificidad y precisión por clase.

10.47. Promedio macro

El promedio macro asigna el mismo peso a cada clase:

$$M_{\text{macro}} = \frac{1}{K} \sum_{k=1}^K M_k.$$

10.48. Promedio ponderado

El promedio ponderado utiliza el tamaño de cada clase:

$$M_{\text{ponderado}} = \sum_{k=1}^K w_k M_k,$$

donde

$$w_k = \frac{n_k}{n}.$$

10.49. Promedio micro

El promedio micro agrega primero los conteos de todas las clases y después calcula la métrica.

Es más sensible a las clases mayoritarias.

10.50. Estrategia uno contra el resto

Para cada clase k se entrena un clasificador binario:

$$k \text{ contra } \mathcal{Y} \setminus \{k\}.$$

10.51. Estrategia uno contra uno

Se entrena un clasificador para cada par de clases.

El número de clasificadores es

$$\binom{K}{2} = \frac{K(K-1)}{2}.$$

10.52. Regiones de decisión multiclase

Si se utilizan funciones discriminantes

$$g_1(\mathbf{x}), \dots, g_K(\mathbf{x}),$$

la región de la clase k es

$$R_k = \{\mathbf{x} : g_k(\mathbf{x}) \geq g_j(\mathbf{x}) \text{ para todo } j\}.$$

10.53. Relación con regresión logística

En regresión logística binaria,

$$\hat{\pi}(\mathbf{x}) = \frac{e^{\beta_0 + \beta^T \mathbf{x}}}{1 + e^{\beta_0 + \beta^T \mathbf{x}}}.$$

La frontera con umbral 0.5 satisface

$$\beta_0 + \beta^T \mathbf{x} = 0.$$

10.54. Relación con el método de vecinos más cercanos

En k -NN, las probabilidades posteriores pueden estimarse como

$$\widehat{P}(Y = c \mid \mathbf{x}) = \frac{1}{k} \sum_{i \in N_k(\mathbf{x})} \mathbb{I}(y_i = c).$$

La clase predicha es la de mayor frecuencia local.

10.55. Relación con árboles de decisión

En una hoja terminal,

$$\widehat{P}(Y = c \mid \mathbf{x}) = \frac{n_c}{n_{\text{hoja}}}.$$

El árbol asigna la clase más frecuente.

10.56. Relación con SVM

SVM produce una función de puntuación

$$g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b.$$

La clasificación es

$$f(\mathbf{x}) = \text{sign}(g(\mathbf{x})).$$

La distancia a la frontera se relaciona con el margen.

10.57. Conexión con R

```
real <- factor(  
  c(1, 1, 1, 0, 0, 0, 1, 0),  
  levels = c(0, 1)  
)
```

```

pred <- factor(
  c(1, 1, 0, 0, 1, 0, 1, 0),
  levels = c(0, 1)
)

tabla <- table(
  Real = real,
  Predicha = pred
)

tabla

VP <- tabla["1", "1"]
FN <- tabla["1", "0"]
FP <- tabla["0", "1"]
VN <- tabla["0", "0"]

accuracy <- (VP + VN) / sum(tabla)
sensibilidad <- VP / (VP + FN)
especificidad <- VN / (VN + FP)
precision <- VP / (VP + FP)

accuracy
sensibilidad
especificidad
precision

```

10.58. Ejemplo integrado

Considere un modelo para identificar accidentes severos.

La clase positiva es

$$Y = 1 = \text{accidente severo.}$$

Supóngase:

$$VP = 60, \quad FN = 15, \quad FP = 25, \quad VN = 400.$$

La exactitud es

$$\frac{60 + 400}{500} = 0.92.$$

La sensibilidad es

$$\frac{60}{60 + 15} = 0.80.$$

La especificidad es

$$\frac{400}{400 + 25} \approx 0.941.$$

La precisión es

$$\frac{60}{60 + 25} \approx 0.706.$$

Aunque la exactitud es alta, la sensibilidad indica que uno de cada cinco accidentes severos no es detectado.

10.59. Errores frecuentes

1. Confundir sensibilidad con precisión.
2. Interpretar exactitud alta como buen desempeño universal.
3. Elegir el umbral únicamente por conveniencia.
4. Ignorar costos distintos entre falsos positivos y falsos negativos.
5. Interpretar AUC como exactitud.
6. Suponer que una AUC alta implica buena calibración.
7. Comparar métricas calculadas con particiones diferentes.
8. Promediar métricas multiclase sin indicar el esquema.
9. Evaluar el modelo final sobre los datos de entrenamiento.
10. Ignorar la prevalencia al interpretar valores predictivos.

10.60. Ejercicios conceptuales

1. Explique qué representa una frontera de decisión.
2. ¿Qué diferencia existe entre una regla discriminante y una probabilidad posterior?
3. ¿Por qué la regla de Bayes minimiza la pérdida 0-1?
4. ¿Qué representa el error de Bayes?
5. ¿Por qué el umbral óptimo puede ser distinto de 0.5?

6. Explique la diferencia entre sensibilidad y precisión.
7. ¿Por qué la exactitud puede ser engañosa?
8. ¿Qué mide la curva ROC?
9. ¿Qué mide la AUC?
10. Explique la diferencia entre discriminación y calibración.

10.61. Ejercicio de matriz de confusión

Considere:

$$VP = 72, \quad FN = 18, \quad FP = 24, \quad VN = 186.$$

Calcule:

1. exactitud;
2. tasa de error;
3. sensibilidad;
4. especificidad;
5. precisión;
6. valor predictivo negativo;
7. F1;
8. exactitud balanceada.

10.62. Ejercicio de pérdidas asimétricas

Supóngase:

$$C_{10} = 1,$$

$$C_{01} = 4.$$

1. Calcule el umbral óptimo.
2. Explique qué tipo de error es más costoso.
3. Determine la decisión para probabilidades posteriores:
 - 0.15;
 - 0.30;
 - 0.60.

10.63. Ejercicio de regla de Bayes

Considere dos clases:

$$P(C_1) = 0.65, \quad P(C_2) = 0.35.$$

Para una observación $\mathbf{x}$:

$$p(\mathbf{x} \mid C_1) = 0.12,$$

$$p(\mathbf{x} \mid C_2) = 0.25.$$

1. Calcule las probabilidades posteriores.
2. Determine la clase según la regla de Bayes.
3. Explique el efecto de las probabilidades previas.

10.64. Ejercicio de umbral

Un modelo produce las probabilidades:

$$0.92, 0.81, 0.64, 0.48, 0.31, 0.12.$$

1. Determine las clases con umbral 0.5.
2. Determine las clases con umbral 0.3.
3. Explique cómo cambia la sensibilidad esperada.
4. Explique cómo cambia la especificidad esperada.

10.65. Ejercicio multiclase

Un problema tiene tres clases:

$$\mathcal{Y} = \{A, B, C\}.$$

Para una observación,

$$P(A \mid \mathbf{x}) = 0.20,$$

$$P(B \mid \mathbf{x}) = 0.55,$$

$$P(C \mid \mathbf{x}) = 0.25.$$

1. Determine la clase de Bayes.
2. Calcule el riesgo condicional bajo pérdida 0-1 para cada decisión.
3. Verifique que la decisión óptima minimiza el riesgo.

10.66. Ejercicio aplicado

Se desea clasificar la calidad del aire en:

{buena, regular, mala}.

1. Defina el espacio de salida.
2. Proponga funciones discriminantes.
3. Defina las regiones de decisión.
4. Construya una matriz de confusión hipotética.
5. Explique cómo calcularía sensibilidad por clase.
6. Compare promedio macro y ponderado.
7. Explique qué métrica usaría si la clase “mala” es poco frecuente pero crítica.

10.67. Resumen

En este capítulo se formuló la clasificación como una regla de decisión sobre el espacio de características. Se definieron regiones y fronteras de decisión, probabilidades posteriores, riesgo condicional y regla de Bayes.

También se estudiaron pérdidas asimétricas, clasificación sensible al costo, matrices de confusión y métricas como exactitud, sensibilidad, especificidad, precisión, F1 y exactitud balanceada.

Finalmente, se desarrollaron curvas ROC, AUC, calibración y clasificación multiclase. Estos conceptos serán esenciales para evaluar y comparar los algoritmos de clasificación de los capítulos posteriores.

11 Evaluación, validación y selección de modelos

11.1. Introducción

La evaluación de modelos tiene como propósito estimar qué tan bien funcionará un algoritmo sobre observaciones nuevas. Esta tarea es distinta del ajuste. Durante el entrenamiento, el modelo utiliza una muestra para estimar parámetros; durante la evaluación, se intenta medir su capacidad de generalización.

Una evaluación incorrecta puede producir conclusiones engañosas. Si se utiliza la misma información para entrenar y evaluar, el error obtenido será optimista. Si el conjunto de prueba interviene en la selección de hiperparámetros, deja de ser una evaluación imparcial. Si el preprocesamiento se realiza antes de dividir los datos, puede existir fuga de información.

En este capítulo se desarrollan formalmente la partición entrenamiento-validación-prueba, la validación cruzada, leave-one-out, bootstrap, validación anidada y selección de hiperparámetros.

11.2. Objetivos

Al finalizar el capítulo, el lector podrá:

1. distinguir entrenamiento, validación y prueba;
2. definir un estimador del error de generalización;
3. comprender el sesgo optimista del error de entrenamiento;
4. aplicar particiones aleatorias y estratificadas;
5. formular validación cruzada de K pliegues;
6. interpretar leave-one-out;
7. comprender métodos bootstrap;
8. comparar sesgo y varianza de estimadores de error;
9. seleccionar hiperparámetros sin contaminar el conjunto de prueba;
10. comprender validación cruzada anidada;
11. detectar fuga de información;
12. evaluar modelos en series de tiempo;
13. comparar modelos de forma estadísticamente válida;
14. diseñar un procedimiento reproducible de evaluación.

11.3. Error de generalización

Sea $\hat{f}_{\mathcal{D}}$ un modelo ajustado con una muestra $\mathcal{D}$.

Su error de generalización es

$$R(\hat{f}_{\mathcal{D}}) = \mathbb{E} \left[L(Y, \hat{f}_{\mathcal{D}}(\mathbf{X})) \mid \mathcal{D} \right].$$

La esperanza se toma respecto de una nueva observación $(\mathbf{X}, Y)$ proveniente del mismo proceso generador.

Este riesgo es desconocido porque la distribución $P_{\mathbf{X}, Y}$ es desconocida.

11.4. Error de entrenamiento

El error de entrenamiento es

$$\widehat{R}_{train} = \frac{1}{n} \sum_{i=1}^n L(y_i, \hat{f}_{\mathcal{D}}(\mathbf{x}_i)).$$

Como el modelo fue ajustado usando esas mismas observaciones, suele cumplirse

$$\widehat{R}_{train} < R(\hat{f}_{\mathcal{D}}).$$

Esta diferencia se denomina optimismo.

11.5. Optimismo de entrenamiento

Definición 11.1. El optimismo es la diferencia entre el error esperado sobre datos nuevos y el error observado sobre los datos de entrenamiento.

Formalmente,

$$\text{Opt} = \mathbb{E} \left[R(\hat{f}_{\mathcal{D}}) - \widehat{R}_{train} \right].$$

Los modelos más flexibles suelen presentar mayor optimismo.

11.6. Conjunto de prueba

Sea

$$\mathcal{D}_{test} = \{(\mathbf{x}_j^{test}, y_j^{test})\}_{j=1}^m$$

una muestra independiente del entrenamiento.

El error de prueba es

$$\widehat{R}_{test} = \frac{1}{m} \sum_{j=1}^m L(y_j^{test}, \hat{f}_{\mathcal{D}}(\mathbf{x}_j^{test})).$$

Condicionado al modelo ajustado,

$$\mathbb{E} [\widehat{R}_{test} \mid \mathcal{D}] = R(\hat{f}_{\mathcal{D}}).$$

Por tanto, el error de prueba es un estimador insesgado del riesgo del modelo fijo, siempre que el conjunto de prueba sea independiente y no intervenga en decisiones previas.

11.7. División entrenamiento-validación-prueba

Una muestra puede dividirse en tres partes:

$$\mathcal{D} = \mathcal{D}_{train} \cup \mathcal{D}_{val} \cup \mathcal{D}_{test},$$

con intersecciones vacías.

11.7.1. Entrenamiento

Se utiliza para estimar parámetros.

11.7.2. Validación

Se utiliza para seleccionar:

- hiperparámetros;
- arquitectura;
- variables;
- umbrales;
- intensidad de regularización.

11.7.3. Prueba

Se utiliza una sola vez para estimar el desempeño final.

11.8. Proporciones de partición

No existe una proporción universal. Algunas opciones son:

- 60 % – 20 % – 20 %;
- 70 % – 15 % – 15 %;
- 80 % – 20 %, usando validación cruzada dentro del entrenamiento.

La elección depende de:

- tamaño total;
- complejidad del modelo;
- cantidad de hiperparámetros;
- prevalencia de clases;
- costo de obtener datos.

11.9. Partición aleatoria

En una partición aleatoria, cada observación tiene probabilidad de ser asignada a cada subconjunto.

Este procedimiento supone intercambiabilidad de las observaciones.

No debe utilizarse sin cuidado cuando existen:

- series de tiempo;
- datos agrupados;
- mediciones repetidas;
- pacientes con varias observaciones;

- dependencia espacial.

11.10. Partición estratificada

Definición 11.2. Una partición estratificada conserva aproximadamente la proporción de clases en cada subconjunto.

Si

$$\hat{p}_k = \frac{n_k}{n},$$

se busca que

$$\hat{p}_{k,train} \approx \hat{p}_{k,val} \approx \hat{p}_{k,test}.$$

Es especialmente importante en clases desbalanceadas.

11.11. Partición por grupos

Si varias observaciones pertenecen al mismo individuo, estación, empresa o unidad experimental, todas deben mantenerse dentro del mismo subconjunto.

De lo contrario, el modelo puede aprender características específicas del grupo y producir una evaluación artificialmente optimista.

11.12. Método holdout

El método holdout utiliza una sola partición:

$$\mathcal{D} = \mathcal{D}_{train} \cup \mathcal{D}_{test}.$$

Ventajas:

- simple;
- rápido;
- útil con muestras grandes.

Desventajas:

- alta dependencia de una sola partición;

- puede tener alta varianza;
- utiliza menos datos para entrenar.

11.13. Validación cruzada de K pliegues

Definición 11.3. La validación cruzada de K pliegues divide la muestra en subconjuntos

$$I_1, \dots, I_K$$

aproximadamente del mismo tamaño.

Para cada pliegue k :

1. se ajusta el modelo sin I_k ;
2. se evalúa sobre I_k .

Sea

$$\hat{f}^{(-k)}$$

el modelo entrenado sin el pliegue k .

El error es

$$CV_K = \frac{1}{n} \sum_{k=1}^K \sum_{i \in I_k} L(y_i, \hat{f}^{(-k)}(\mathbf{x}_i)).$$

Si los pliegues tienen igual tamaño,

$$CV_K = \frac{1}{K} \sum_{k=1}^K \hat{R}_k.$$

11.14. Interpretación

Cada observación se utiliza:

- una vez para validación;
- $K - 1$ veces como parte del entrenamiento.

Los valores habituales son

$$K = 5$$

o

$$K = 10.$$

11.15. Sesgo de validación cruzada

Cada modelo se entrena con

$$\frac{K-1}{K}n$$

observaciones.

Por tanto, CV_K estima el error de un modelo entrenado con menos observaciones que el modelo final.

Esto puede introducir un sesgo ligeramente pesimista.

11.16. Varianza de validación cruzada

Los errores de los pliegues no son independientes porque los conjuntos de entrenamiento se superponen.

Por ello, calcular la varianza como si fueran observaciones independientes puede subestimar la incertidumbre.

11.17. Validación cruzada repetida

Se repite la creación de pliegues B veces:

$$CV_{K,B} = \frac{1}{B} \sum_{b=1}^B CV_K^{(b)}.$$

La repetición reduce la dependencia respecto de una sola división.

11.18. Leave-one-out

Definición 11.4. Leave-one-out cross-validation corresponde a

$$K = n.$$

Cada modelo se entrena con $n - 1$ observaciones y se evalúa en una sola.

El estimador es

$$CV_{LOO} = \frac{1}{n} \sum_{i=1}^n L(y_i, \hat{f}^{(-i)}(\mathbf{x}_i)).$$

11.19. Ventajas y limitaciones de LOOCV

Ventajas:

- casi toda la muestra se usa para entrenar;
- bajo sesgo.

Limitaciones:

- puede tener alta varianza;
- alto costo computacional;
- los modelos ajustados son muy similares;
- no siempre supera a $K = 5$ o $K = 10$.

11.20. Validación cruzada estratificada

En clasificación, los pliegues deben preservar la proporción de clases.

Esto evita que algún pliegue carezca de observaciones de una clase minoritaria.

11.21. Validación cruzada agrupada

Cuando existen grupos, se dividen grupos completos, no observaciones individuales.

Se utiliza, por ejemplo, cuando hay:

- múltiples mediciones por paciente;
- observaciones por escuela;
- registros por estación;

- datos por empresa.

11.22. Validación cruzada para series de tiempo

En series temporales no debe mezclarse aleatoriamente pasado y futuro.

Una estrategia es la ventana creciente.

Para tiempos

$$1, \dots, T,$$

se realizan ajustes como:

$$\{1, \dots, t\} \rightarrow \{t + 1\}.$$

El error temporal es

$$CV_{time} = \frac{1}{M} \sum_{m=1}^M L(y_{t_m+1}, \hat{f}_{1:t_m}(\mathbf{x}_{t_m+1})).$$

11.23. Ventana deslizante

Se entrena con una ventana de longitud fija w :

$$\{t - w + 1, \dots, t\} \rightarrow \{t + 1\}.$$

Es útil cuando el proceso cambia con el tiempo.

11.24. Bootstrap

Definición 11.5. Una muestra bootstrap se obtiene seleccionando n observaciones con reemplazo de la muestra original.

Se denota por

$$\mathcal{D}^{*(b)}.$$

Cada muestra bootstrap contiene observaciones repetidas y deja fuera algunas observaciones originales.

11.25. Probabilidad de exclusión

La probabilidad de que una observación no sea seleccionada en una muestra bootstrap es

$$\left(1 - \frac{1}{n}\right)^n.$$

Cuando n es grande,

$$\left(1 - \frac{1}{n}\right)^n \approx e^{-1} \approx 0.368.$$

Por tanto, aproximadamente el 36.8 % de las observaciones queda fuera de cada muestra bootstrap.

11.26. Error out-of-bag

Las observaciones no seleccionadas forman el conjunto out-of-bag.

El modelo bootstrap se evalúa sobre esas observaciones.

Este principio se utiliza en random forest.

11.27. Estimador bootstrap del error

Para B muestras bootstrap,

$$\widehat{R}_{boot} = \frac{1}{B} \sum_{b=1}^B \widehat{R}_{OOB}^{(b)}.$$

11.28. Estimador .632

El estimador .632 combina error de entrenamiento y error out-of-bag:

$$\widehat{R}_{.632} = 0.368\widehat{R}_{train} + 0.632\widehat{R}_{OOB}.$$

La ponderación se relaciona con la proporción esperada de observaciones distintas presentes en una muestra bootstrap.

11.29. Bootstrap para incertidumbre

Además de estimar error, bootstrap puede aproximar la distribución de un estadístico.

Sea

$$T = T(\mathcal{D}).$$

Se calculan

$$T^{*(1)}, \dots, T^{*(B)}.$$

La varianza bootstrap es

$$\widehat{\text{Var}}_{boot}(T) = \frac{1}{B-1} \sum_{b=1}^B \left(T^{*(b)} - \overline{T}^* \right)^2.$$

11.30. Selección de hiperparámetros

Sea $\lambda \in \Lambda$ un hiperparámetro.

Para cada valor se estima

$$CV_K(\lambda).$$

Se selecciona

$$\hat{\lambda} = \arg \min_{\lambda \in \Lambda} CV_K(\lambda).$$

Después se reajusta el modelo usando toda la muestra de entrenamiento con $\hat{\lambda}$.

11.31. Búsqueda en rejilla

Se define una rejilla

$$\Lambda = \{\lambda_1, \dots, \lambda_M\}.$$

Se evalúa cada combinación.

Ventajas:

- sistemática;
- reproducible.

Desventajas:

- costosa en espacios grandes;
- ineficiente si muchos valores son irrelevantes.

11.32. Búsqueda aleatoria

Se seleccionan combinaciones aleatorias de hiperparámetros.

Puede ser más eficiente cuando solo algunas dimensiones tienen gran influencia.

11.33. Optimización bayesiana

Construye un modelo sustituto de la función

$$\lambda \mapsto CV(\lambda)$$

y utiliza una función de adquisición para elegir nuevas evaluaciones.

Es útil cuando cada entrenamiento es costoso.

11.34. Fuga de información

Definición 11.6. Existe fuga de información cuando el proceso de entrenamiento utiliza información que no estaría disponible al momento de realizar una predicción real.

Ejemplos:

- normalizar antes de dividir;
- imputar usando toda la base;
- seleccionar variables con todo el conjunto;
- usar el conjunto de prueba para ajustar el umbral;
- incluir variables creadas después del evento objetivo;
- mezclar observaciones del mismo paciente entre entrenamiento y prueba.

11.35. Preprocesamiento correcto

Toda transformación debe aprenderse únicamente en entrenamiento.

Por ejemplo, para estandarizar:

$$\tilde{x}_{ij} = \frac{x_{ij} - \hat{\mu}_{j,train}}{\hat{\sigma}_{j,train}}.$$

Los valores de validación y prueba se transforman usando las estadísticas del entrenamiento.

No deben recalcularse con cada conjunto.

11.36. Pipeline

Un pipeline integra:

1. imputación;
2. transformación;
3. selección de variables;
4. ajuste del modelo;
5. predicción.

Durante validación cruzada, todo el pipeline debe reajustarse dentro de cada pliegue.

11.37. Selección de variables dentro de la validación

Si la selección de variables se realiza antes de validar, el estimador del error queda sesgado.

El procedimiento correcto para cada pliegue es:

1. seleccionar variables usando solo entrenamiento interno;
2. ajustar el modelo;
3. evaluar en el pliegue retenido.

11.38. Validación cruzada anidada

Definición 11.7. La validación cruzada anidada utiliza un ciclo externo para estimar desempeño y un ciclo interno para seleccionar hiperparámetros.

11.38.1. Ciclo externo

Divide los datos en pliegues de evaluación.

11.38.2. Ciclo interno

Dentro del entrenamiento externo, selecciona hiperparámetros.

El error anidado es

$$CV_{nested} = \frac{1}{K_{ext}} \sum_{k=1}^{K_{ext}} \widehat{R}_k^{ext}.$$

Este procedimiento reduce el sesgo de selección.

11.39. Sesgo por selección

Si se prueban muchos modelos y se reporta el mejor valor de validación, el resultado tiende a ser optimista.

Esto ocurre porque se selecciona el mínimo entre estimaciones ruidosas:

$$\min_m \widehat{R}_m.$$

La validación anidada separa selección y evaluación.

11.40. Regla de un error estándar

Supóngase que λ_{min} minimiza el error medio.

La regla de un error estándar selecciona el modelo más simple cuyo error satisface

$$CV(\lambda) \leq CV(\lambda_{min}) + SE(\lambda_{min}).$$

Esta regla favorece modelos más parsimoniosos.

11.41. Comparación de modelos

Supóngase que se comparan modelos A y B .

En cada pliegue se calcula

$$d_k = R_{A,k} - R_{B,k}.$$

Una diferencia promedio negativa favorece a A :

$$\bar{d} = \frac{1}{K} \sum_{k=1}^K d_k.$$

Sin embargo, los pliegues no son independientes, por lo que las pruebas estadísticas deben interpretarse con cautela.

11.42. Prueba de McNemar

Para dos clasificadores evaluados sobre las mismas observaciones, se consideran:

- n_{01} : A falla y B acierta;
- n_{10} : A acierta y B falla.

El estadístico aproximado es

$$\chi^2 = \frac{(|n_{01} - n_{10}| - 1)^2}{n_{01} + n_{10}}.$$

Esta prueba analiza si los patrones de error difieren.

11.43. Intervalo para error de clasificación

Si el error observado es

$$\hat{p} = \frac{e}{m},$$

una aproximación del error estándar es

$$SE(\hat{p}) = \sqrt{\frac{\hat{p}(1 - \hat{p})}{m}}.$$

Una aproximación normal es

$$\hat{p} \pm z_{\alpha/2} SE(\hat{p}).$$

Para muestras pequeñas o proporciones extremas son preferibles métodos como Wilson.

11.44. Incertidumbre del error cuadrático medio

Para pérdidas

$$\ell_1, \dots, \ell_m,$$

el error medio es

$$\bar{\ell} = \frac{1}{m} \sum_{i=1}^m \ell_i.$$

Su error estándar aproximado es

$$SE(\bar{\ell}) = \frac{s_{\ell}}{\sqrt{m}},$$

si las observaciones de prueba son independientes.

11.45. Reproducibilidad

Un proceso reproducible debe registrar:

- semilla aleatoria;
- particiones;
- variables;
- transformaciones;
- hiperparámetros;
- métrica principal;
- software y versiones;
- procedimiento de selección.

11.46. Métrica principal

La métrica principal debe definirse antes de comparar modelos.

Ejemplos:

- RMSE en regresión;
- sensibilidad en detección médica;
- AUC en discriminación;
- F1 en clases desbalanceadas;
- pérdida logarítmica para probabilidades.

Elegir la métrica después de observar resultados puede introducir sesgo.

11.47. Evaluación en regresión

11.47.1. Error cuadrático medio

$$MSE = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2.$$

11.47.2. Raíz del error cuadrático medio

$$RMSE = \sqrt{MSE}.$$

11.47.3. Error absoluto medio

$$MAE = \frac{1}{m} \sum_{i=1}^m |y_i - \hat{y}_i|.$$

11.47.4. Coeficiente de determinación

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}.$$

En prueba, R^2 puede ser negativo.

11.48. Evaluación en clasificación

La selección de métricas depende de:

- balance de clases;
- costo de errores;
- uso de probabilidades;
- objetivo operativo;
- umbral disponible.

No debe evaluarse un clasificador exclusivamente mediante exactitud cuando las clases están desbalanceadas.

11.49. Conexión con R

```
set.seed(123)

n <- 150
datos <- data.frame(
  x1 = rnorm(n),
  x2 = rnorm(n)
)

datos$y <- 2 + 1.5 * datos$x1 - datos$x2 + rnorm(n)

# Partición holdout
```

```

id_train <- sample(seq_len(n), size = 0.8 * n)

train <- datos[id_train, ]
test <- datos[-id_train, ]

modelo <- lm(y ~ x1 + x2, data = train)

pred <- predict(modelo, newdata = test)

rmse <- sqrt(mean((test$y - pred)^2))
mae <- mean(abs(test$y - pred))

rmse
mae

```

11.50. Ejemplo manual de validación cruzada

Considere seis observaciones divididas en tres pliegues:

$$I_1 = \{1, 2\}, \quad I_2 = \{3, 4\}, \quad I_3 = \{5, 6\}.$$

Los errores de validación son:

$$\widehat{R}_1 = 2.0, \quad \widehat{R}_2 = 3.5, \quad \widehat{R}_3 = 2.5.$$

Entonces,

$$CV_3 = \frac{2.0 + 3.5 + 2.5}{3} = \frac{8}{3} \approx 2.67.$$

11.51. Ejemplo de fuga de información

Supóngase que se estandariza una variable usando:

$$\hat{\mu}_{total} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Si esta media incluye observaciones de prueba, el entrenamiento utiliza indirectamente información futura.

La transformación correcta usa:

$$\hat{\mu}_{train} = \frac{1}{n_{train}} \sum_{i \in train} x_i.$$

11.52. Diseño recomendado de evaluación

Un procedimiento robusto puede ser:

1. separar un conjunto de prueba final;
2. definir una métrica principal;
3. construir un pipeline;
4. seleccionar hiperparámetros mediante validación cruzada;
5. reajustar con todo el entrenamiento;
6. evaluar una sola vez en prueba;
7. reportar incertidumbre y métricas complementarias.

11.53. Errores frecuentes

1. Reportar error de entrenamiento como desempeño final.
2. Usar el conjunto de prueba para seleccionar modelos.
3. Normalizar antes de dividir.
4. Seleccionar variables con toda la base.
5. Mezclar observaciones del mismo grupo entre entrenamiento y prueba.
6. Aleatorizar series de tiempo.
7. Comparar modelos usando particiones distintas.
8. Probar muchas configuraciones y reportar solo la mejor sin validación anidada.
9. Elegir la métrica después de ver resultados.
10. Omitir la incertidumbre de las estimaciones.

11.54. Ejercicios conceptuales

1. Explique la diferencia entre entrenamiento, validación y prueba.
2. ¿Por qué el error de entrenamiento es optimista?
3. ¿Qué ventaja ofrece la validación cruzada?
4. ¿Qué diferencia existe entre K -fold y LOOCV?
5. ¿Por qué debe utilizarse estratificación?
6. ¿Qué es fuga de información?
7. ¿Por qué el preprocesamiento debe realizarse dentro de cada pliegue?
8. ¿Qué problema resuelve la validación anidada?

9. ¿Qué significa la regla de un error estándar?
10. ¿Por qué no debe aleatorizarse una serie temporal?

11.55. Ejercicio de holdout

Una muestra contiene 1 000 observaciones.

1. Calcule los tamaños para una división 70 % – 15 % – 15 %.
2. Explique el uso de cada subconjunto.
3. Proponga una alternativa usando validación cruzada.
4. Analice qué ocurriría si solo existen 40 observaciones positivas.

11.56. Ejercicio de validación cruzada

Los errores de cinco pliegues son:

0.18, 0.22, 0.20, 0.25, 0.15.

Calcule:

1. el error medio;
2. la desviación estándar;
3. el error estándar aproximado;
4. un intervalo descriptivo de dos errores estándar.

11.57. Ejercicio bootstrap

Para $n = 100$:

1. calcule aproximadamente la proporción esperada de observaciones no seleccionadas;
2. calcule la cantidad esperada de observaciones out-of-bag;
3. explique cómo se estima el error OOB;
4. relacione este procedimiento con random forest.

11.58. Ejercicio de selección

Se obtienen los siguientes errores:

λ	Error CV	Error estándar
0.01	0.245	0.012
0.10	0.228	0.010
1.00	0.231	0.009
10.00	0.260	0.011

1. Seleccione el mínimo.
2. Aplique la regla de un error estándar.
3. Explique cuál modelo sería más simple si una penalización mayor implica mayor regularización.

11.59. Ejercicio de fuga de información

Analice los siguientes procedimientos e indique si existe fuga:

1. imputar antes de dividir;
2. seleccionar variables antes de validación cruzada;
3. ajustar el umbral usando prueba;
4. dividir pacientes, pero no observaciones;
5. calcular medias solo en entrenamiento y aplicarlas a prueba;
6. usar registros posteriores al diagnóstico para predecir el diagnóstico.

11.60. Ejercicio aplicado

Se desea comparar regresión logística, random forest y SVM para clasificar accidentes severos.

Diseñe un procedimiento que incluya:

1. partición;
2. estratificación;
3. métrica principal;
4. preprocesamiento;
5. selección de hiperparámetros;
6. validación anidada;
7. evaluación final;
8. comparación de errores;
9. reporte de incertidumbre;
10. prevención de fuga de información.

11.61. Resumen

En este capítulo se desarrollaron los fundamentos de evaluación y selección de modelos. Se distinguieron error de entrenamiento, validación, prueba y generalización.

También se estudiaron holdout, validación cruzada de K pliegues, leave-one-out, validación repetida, validación agrupada y evaluación temporal.

Finalmente, se introdujeron bootstrap, error out-of-bag, selección de hiperparámetros, validación anidada, fuga de información, pipelines, comparación de modelos y reproducibilidad. Estas herramientas son indispensables para obtener evaluaciones confiables y evitar conclusiones optimistas.

12 Regularización y control de la complejidad

12.1. Introducción

La regularización es una de las ideas centrales del aprendizaje automático moderno. Su propósito es controlar la complejidad de un modelo para mejorar su capacidad de generalización. En lugar de minimizar únicamente el error de entrenamiento, se añade una penalización que desalienta soluciones excesivamente flexibles, inestables o difíciles de interpretar.

La regularización puede entenderse desde distintos puntos de vista:

- como una penalización añadida a la función de pérdida;
- como una restricción sobre el tamaño de los parámetros;
- como una forma de reducir varianza;
- como una estrategia para combatir la multicolinealidad;
- como un mecanismo de selección de variables;
- como una forma de incorporar información previa.

En este capítulo se desarrollan formalmente ridge, LASSO y elastic net, así como sus interpretaciones geométricas y estadísticas.

12.2. Objetivos

Al finalizar el capítulo, el lector podrá:

1. explicar por qué se utiliza regularización;
2. formular problemas penalizados;
3. relacionar penalización y restricción;
4. derivar el estimador ridge;
5. interpretar la penalización L_2 ;
6. formular el problema LASSO;
7. interpretar la penalización L_1 ;
8. comprender por qué LASSO produce coeficientes exactamente iguales a cero;
9. formular elastic net;
10. analizar el efecto del parámetro de regularización;
11. comprender la relación entre regularización, sesgo y varianza;

12. interpretar regularización desde un punto de vista bayesiano;
13. seleccionar λ mediante validación;
14. reconocer limitaciones y precauciones prácticas.

12.3. Motivación

Considere el modelo lineal

$$\mathbf{y} = \mathbf{X}\beta + \varepsilon.$$

El estimador de mínimos cuadrados es

$$\hat{\beta}_{OLS} = \arg \min_{\beta} \|\mathbf{y} - \mathbf{X}\beta\|_2^2.$$

Si $\mathbf{X}^\top \mathbf{X}$ es invertible,

$$\hat{\beta}_{OLS} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

Sin embargo, este estimador puede presentar problemas cuando:

- existen variables altamente correlacionadas;
- p es grande;
- $p \geq n$;
- hay ruido considerable;
- el modelo tiene demasiada flexibilidad;
- se desea seleccionar variables.

12.4. Problemas de multicolinealidad

Cuando algunas columnas de $\mathbf{X}$ están altamente correlacionadas, la matriz

$$\mathbf{X}^\top \mathbf{X}$$

puede estar mal condicionada.

Esto provoca:

- coeficientes inestables;
- gran varianza;

- sensibilidad a pequeñas perturbaciones;
- signos difíciles de interpretar;
- predicciones poco robustas.

12.5. Problema penalizado general

Definición 12.1. Un problema de regularización tiene la forma

$$\hat{\beta} = \arg \min_{\beta} \{L(\beta) + \lambda \Omega(\beta)\},$$

donde:

- $L(\beta)$ es la pérdida;
- $\Omega(\beta)$ mide complejidad;
- $\lambda \geq 0$ controla la intensidad de regularización.

Cuando

$$\lambda = 0,$$

se recupera el modelo sin penalización.

Cuando λ aumenta, la penalización adquiere mayor peso.

12.6. Interpretación del parámetro de regularización

Un valor pequeño de λ :

- permite mayor flexibilidad;
- reduce sesgo;
- puede aumentar varianza.

Un valor grande:

- reduce la magnitud de los coeficientes;
- aumenta estabilidad;
- puede aumentar sesgo;
- puede producir subajuste.

12.7. Formulación restringida

El problema penalizado puede relacionarse con

$$\min_{\beta} L(\beta)$$

sujeto a

$$\Omega(\beta) \leq t.$$

Existe una correspondencia entre λ y t , bajo condiciones regulares.

La forma penalizada utiliza λ ; la forma restringida limita directamente la complejidad.

12.8. Regresión ridge

Definición 12.2. La regresión ridge minimiza

$$J_{ridge}(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda \|\beta\|_2^2.$$

La penalización es

$$\|\beta\|_2^2 = \sum_{j=1}^p \beta_j^2.$$

Habitualmente el intercepto no se penaliza.

12.9. Forma matricial de ridge

La función objetivo puede escribirse como

$$J_{ridge}(\beta) = (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta) + \lambda \beta^\top \beta.$$

12.10. Derivación del estimador ridge

Derivando respecto de β ,

$$\nabla J_{ridge} = -2\mathbf{X}^\top(\mathbf{y} - \mathbf{X}\beta) + 2\lambda\beta.$$

Igualando a cero,

$$-2\mathbf{X}^\top\mathbf{y} + 2\mathbf{X}^\top\mathbf{X}\beta + 2\lambda\beta = \mathbf{0}.$$

Entonces,

$$(\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I})\beta = \mathbf{X}^\top\mathbf{y}.$$

Por tanto,

$$\hat{\beta}_{ridge} = (\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I})^{-1} \mathbf{X}^\top\mathbf{y}.$$

12.11. Efecto sobre la invertibilidad

Incluso si

$$\mathbf{X}^\top\mathbf{X}$$

es singular, para $\lambda > 0$,

$$\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I}$$

es definida positiva y, por tanto, invertible.

Esta es una ventaja fundamental de ridge.

12.12. Interpretación espectral

Supóngase que

$$\mathbf{X}^\top \mathbf{X} = \mathbf{Q} \Lambda \mathbf{Q}^\top,$$

donde

$$\Lambda = \text{diag}(\mu_1, \dots, \mu_p).$$

Entonces,

$$(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} = \mathbf{Q} \text{diag} \left(\frac{1}{\mu_j + \lambda} \right) \mathbf{Q}^\top.$$

Ridge reduce con mayor intensidad las direcciones asociadas a valores propios pequeños.

12.13. Factores de contracción

En las coordenadas principales, el factor de contracción es

$$\frac{\mu_j}{\mu_j + \lambda}.$$

Se cumple

$$0 \leq \frac{\mu_j}{\mu_j + \lambda} < 1.$$

Cuando μ_j es pequeño, la contracción es mayor.

12.14. Sesgo de ridge

Condicionado a $\mathbf{X}$,

$$\mathbb{E}[\hat{\beta}_{ridge}] = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{X} \beta.$$

Por tanto, ridge es sesgado cuando $\lambda > 0$.

12.15. Varianza de ridge

Si

$$\text{Var}(\varepsilon) = \sigma^2 \mathbf{I},$$

entonces

$$\text{Var}(\hat{\beta}_{ridge}) = \sigma^2 (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{X} (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1}.$$

Ridge introduce sesgo, pero puede reducir considerablemente la varianza.

12.16. Ridge y el compromiso sesgo-varianza

El error cuadrático medio de los parámetros puede disminuir si la reducción de varianza compensa el aumento de sesgo.

Esta es la razón estadística de la regularización.

12.17. Geometría de ridge

La forma restringida es

$$\min_{\beta} \|\mathbf{y} - \mathbf{X}\beta\|_2^2$$

sujeto a

$$\sum_{j=1}^p \beta_j^2 \leq t.$$

La región factible es una esfera o circunferencia L_2 .

La solución aparece donde una curva de nivel de la pérdida toca la región restringida.

12.18. Estandarización

Ridge depende de la escala de las variables.

Antes de ajustar, suele utilizarse

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}.$$

Sin estandarización, las variables con escalas grandes reciben una penalización relativa diferente.

12.19. LASSO

Definición 12.3. LASSO minimiza

$$J_{lasso}(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda \|\beta\|_1.$$

La norma L_1 es

$$\|\beta\|_1 = \sum_{j=1}^p |\beta_j|.$$

12.20. Forma restringida de LASSO

$$\min_{\beta} \|\mathbf{y} - \mathbf{X}\beta\|_2^2$$

sujeto a

$$\sum_{j=1}^p |\beta_j| \leq t.$$

12.21. No diferenciabilidad

La función

$$|\beta|$$

no es diferenciable en

$$\beta = 0.$$

Por tanto, LASSO no posee una solución matricial cerrada análoga a ridge.

Se utilizan métodos como:

- descenso por coordenadas;
- subgradientes;
- LARS;
- métodos proximales.

12.22. Subgradiente

Para

$$g(\beta) = |\beta|,$$

el subgradiente es

$$\partial g(\beta) = \begin{cases} \{1\}, & \beta > 0, \\ [-1, 1], & \beta = 0, \\ \{-1\}, & \beta < 0. \end{cases}$$

Las condiciones óptimas se expresan mediante subgradientes.

12.23. Operador soft-thresholding

Definición 12.4. El operador de umbral suave se define como

$$S(z, \gamma) = \text{sign}(z) \max\{|z| - \gamma, 0\}.$$

Este operador reduce la magnitud y puede producir exactamente cero.

12.24. Caso ortonormal

Si

$$\mathbf{X}^\top \mathbf{X} = \mathbf{I},$$

la solución LASSO tiene la forma

$$\hat{\beta}_j = S\left(\hat{\beta}_{j,OLS}, \frac{\lambda}{2}\right),$$

según la convención de escala utilizada.

12.25. Geometría de LASSO

La región

$$\|\beta\|_1 \leq t$$

tiene forma de rombo en dos dimensiones.

Sus vértices están sobre los ejes coordenados. Las curvas de nivel de la pérdida tienen mayor probabilidad de tocar un vértice.

Por ello, LASSO produce coeficientes exactamente iguales a cero.

12.26. Selección de variables

Si

$$\hat{\beta}_j = 0,$$

la variable j queda excluida del modelo.

LASSO realiza simultáneamente:

- ajuste;
- contracción;
- selección de variables.

12.27. Limitaciones de LASSO

LASSO puede presentar dificultades cuando:

- las variables están fuertemente correlacionadas;
- $p \gg n$;
- existen grupos de variables similares;
- la señal está distribuida entre muchas variables pequeñas.

En grupos correlacionados, puede seleccionar una variable y excluir otras de forma inestable.

12.28. Elastic net

Definición 12.5. Elastic net combina penalizaciones L_1 y L_2 :

$$J_{EN}(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda_1 \|\beta\|_1 + \lambda_2 \|\beta\|_2^2.$$

Otra parametrización es

$$J_{EN}(\beta) = L(\beta) + \lambda \left[\alpha \|\beta\|_1 + (1 - \alpha) \|\beta\|_2^2 \right],$$

con

$$0 \leq \alpha \leq 1.$$

12.29. Casos particulares

Si

$$\alpha = 1,$$

se obtiene LASSO.

Si

$$\alpha = 0,$$

se obtiene ridge.

Si

$$0 < \alpha < 1,$$

se obtiene elastic net.

12.30. Ventaja de elastic net

Elastic net puede:

- seleccionar variables;
- estabilizar grupos correlacionados;
- funcionar mejor cuando $p > n$;
- combinar esparsidad y estabilidad.

12.31. Caminos de regularización

Al variar λ , se obtiene una trayectoria

$$\hat{\beta}(\lambda).$$

Cuando $\lambda \rightarrow 0$, la solución se aproxima al modelo no regularizado.

Cuando $\lambda \rightarrow \infty$, los coeficientes tienden a cero.

12.32. Valor máximo del parámetro de regularización

En LASSO existe un valor suficientemente grande

$$\lambda_{\max}$$

para el cual todos los coeficientes penalizados son cero.

Los algoritmos suelen construir una secuencia decreciente desde $\lambda_{\max}$.

12.33. Selección del parámetro de regularización

La práctica habitual es seleccionar λ mediante validación cruzada:

$$\hat{\lambda} = \arg \min_{\lambda} CV(\lambda).$$

También puede utilizarse la regla de un error estándar para elegir una solución más regularizada y parsimoniosa.

12.34. Ridge como estimación bayesiana

Supóngase el modelo gaussiano

$$\mathbf{y} \mid \beta \sim N(\mathbf{X}\beta, \sigma^2 \mathbf{I}).$$

Considérese la previa

$$\beta \sim N(\mathbf{0}, \tau^2 \mathbf{I}).$$

El estimador MAP minimiza

$$\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \frac{1}{2\tau^2} \|\beta\|_2^2.$$

Por tanto, ridge corresponde a una previa normal.

12.35. LASSO como estimación bayesiana

Si la previa de cada coeficiente es Laplace,

$$p(\beta_j) \propto \exp\left(-\frac{|\beta_j|}{b}\right),$$

el estimador MAP conduce a una penalización L_1 .

12.36. Regularización en regresión logística

La pérdida logística penalizada es

$$J(\beta) = -\sum_{i=1}^n [y_i \log \pi_i + (1 - y_i) \log(1 - \pi_i)] + \lambda \Omega(\beta).$$

Puede utilizarse:

- ridge;
- LASSO;
- elastic net.

12.37. Regularización en redes neuronales

12.37.1. Weight decay

Se añade

$$\lambda \sum_l \|\mathbf{W}^{(l)}\|_F^2.$$

12.37.2. Dropout

Durante el entrenamiento, algunas activaciones se eliminan aleatoriamente.

12.37.3. Early stopping

Se detiene el entrenamiento cuando el error de validación deja de mejorar.

12.37.4. Data augmentation

Se generan transformaciones de los datos para reducir sobreajuste.

12.38. Regularización en árboles

En árboles, el control de complejidad se realiza mediante:

- profundidad máxima;
- número mínimo de observaciones por nodo;
- poda;
- penalización por número de hojas.

La regularización no siempre adopta la forma de una norma.

12.39. Regularización explícita e implícita

La regularización explícita aparece directamente en la función objetivo.

La regularización implícita puede provenir de:

- optimización;
- arquitectura;
- inicialización;
- detención temprana;
- ruido en el entrenamiento.

12.40. Grados de libertad efectivos

En ridge, los valores ajustados son

$$\hat{\mathbf{y}} = \mathbf{H}_\lambda \mathbf{y},$$

donde

$$\mathbf{H}_\lambda = \mathbf{X} (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top.$$

Los grados de libertad efectivos son

$$df(\lambda) = \text{tr}(\mathbf{H}_\lambda).$$

Al aumentar λ , disminuyen los grados de libertad efectivos.

12.41. Relación con la estabilidad

Un algoritmo es estable si pequeñas modificaciones de la muestra producen cambios pequeños en el modelo.

Ridge suele aumentar estabilidad al evitar coeficientes extremos.

La estabilidad contribuye a reducir la brecha de generalización.

12.42. Variables categóricas

Cuando una variable categórica se codifica con varias variables indicadoras, penalizar cada coeficiente por separado puede ser inadecuado.

Pueden utilizarse extensiones como:

- group LASSO;
- sparse group LASSO.

12.43. Group LASSO

Si los parámetros se agrupan en G bloques,

$$\beta_1, \dots, \beta_G,$$

la penalización es

$$\sum_{g=1}^G w_g \|\beta_g\|_2.$$

Puede eliminar grupos completos de variables.

12.44. Regularización adaptativa

Adaptive LASSO utiliza pesos:

$$\sum_{j=1}^p w_j |\beta_j|.$$

Los pesos pueden depender de estimaciones iniciales.

Esto permite penalizar menos los coeficientes aparentemente importantes.

12.45. Regularización y causalidad

La selección de variables predictivas no equivale a identificar variables causales.

Un coeficiente cero puede deberse a:

- correlación con otras variables;
- penalización;
- falta de potencia;
- estructura de la muestra.

La regularización mejora predicción, pero no resuelve por sí sola problemas causales.

12.46. Conexión con R

```
# Requiere glmnet
library(glmnet)

set.seed(123)

n <- 100
p <- 10

X <- matrix(rnorm(n * p), nrow = n, ncol = p)

beta_real <- c(3, -2, 1.5, rep(0, p - 3))

y <- as.vector(X %*% beta_real + rnorm(n))

# Ridge: alpha = 0
```

```

ajuste_ridge <- cv.glmnet(
  X,
  y,
  alpha = 0
)

ajuste_ridge$lambda.min

# LASSO: alpha = 1
ajuste_lasso <- cv.glmnet(
  X,
  y,
  alpha = 1
)

ajuste_lasso$lambda.min

coef(ajuste_lasso, s = "lambda.min")

# Elastic net
ajuste_en <- cv.glmnet(
  X,
  y,
  alpha = 0.5
)

coef(ajuste_en, s = "lambda.1se")

```

12.47. Ejemplo numérico ridge

Considere

$$\mathbf{X}^T \mathbf{X} = \begin{pmatrix} 4 & 3 \\ 3 & 2.5 \end{pmatrix},$$

y

$$\mathbf{X}^T \mathbf{y} = \begin{pmatrix} 10 \\ 8 \end{pmatrix}.$$

Con

$$\lambda = 1,$$

se obtiene

$$\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I} = \begin{pmatrix} 5 & 3 \\ 3 & 3.5 \end{pmatrix}.$$

La solución ridge es

$$\hat{\beta}_{ridge} = \begin{pmatrix} 5 & 3 \\ 3 & 3.5 \end{pmatrix}^{-1} \begin{pmatrix} 10 \\ 8 \end{pmatrix}.$$

Este sistema es más estable que el sistema sin penalización.

12.48. Comparación conceptual

Método	Penalización	Selección de variables	Estabilidad
Ridge	L_2	No exacta	Alta
LASSO	L_1	Sí	Puede ser inestable con correlación
Elastic net	$L_1 + L_2$	Sí	Mayor con variables correlacionadas

12.49. Errores frecuentes

1. Penalizar variables sin estandarizarlas.
2. Penalizar el intercepto sin intención.
3. Seleccionar λ usando el conjunto de prueba.
4. Interpretar coeficientes LASSO como evidencia causal.
5. Suponer que LASSO siempre selecciona la variable correcta.
6. Confundir coeficiente pequeño con irrelevancia absoluta.
7. Ignorar la inestabilidad entre variables correlacionadas.
8. Comparar soluciones obtenidas con escalas distintas.
9. Utilizar regularización sin recalibrar el modelo cuando sea necesario.
10. Reportar únicamente λ_{min} sin considerar parsimonia.

12.50. Ejercicios conceptuales

1. Explique por qué ridge introduce sesgo.
2. ¿Cómo puede un estimador sesgado tener menor error cuadrático medio?
3. ¿Por qué ridge ayuda con multicolinealidad?
4. ¿Por qué LASSO produce coeficientes cero?
5. Explique la diferencia geométrica entre L_1 y L_2 .
6. ¿Qué ventaja ofrece elastic net?
7. ¿Por qué es necesaria la estandarización?
8. ¿Qué relación existe entre ridge y una previa normal?
9. ¿Qué relación existe entre LASSO y una previa Laplace?
10. Explique la diferencia entre regularización explícita e implícita.

12.51. Ejercicio de derivación ridge

Considere

$$J(\beta) = (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta) + \lambda \beta^\top \beta.$$

1. Expanda la expresión.
2. Calcule el gradiente.
3. Iguale a cero.
4. Obtenga la solución ridge.
5. Explique por qué la matriz resultante es invertible para $\lambda > 0$.

12.52. Ejercicio de soft-thresholding

Calcule

$$S(z, \gamma)$$

para:

1. $z = 5, \gamma = 2$;
2. $z = -4, \gamma = 1.5$;
3. $z = 1, \gamma = 2$;
4. $z = -0.5, \gamma = 0.5$.

Interprete cuándo el resultado es cero.

12.53. Ejercicio de validación

Se obtienen los siguientes errores:

λ	Error CV
0.001	4.80
0.01	4.20
0.10	3.95
1.00	4.05
10.00	5.30

1. Seleccione λ .
2. Explique qué ocurre en valores muy pequeños.
3. Explique qué ocurre en valores muy grandes.
4. Relacione el patrón con sesgo y varianza.

12.54. Ejercicio comparativo

Supóngase que existen 50 variables altamente correlacionadas y solo 80 observaciones.

Compare:

1. mínimos cuadrados;
2. ridge;
3. LASSO;
4. elastic net.

Indique ventajas y limitaciones de cada uno.

12.55. Ejercicio aplicado

Se desea predecir PM10 utilizando 40 variables meteorológicas y derivadas.

1. Explique por qué puede existir multicolinealidad.
2. Proponga un esquema de estandarización.
3. Defina un modelo ridge.
4. Defina un modelo LASSO.
5. Defina un modelo elastic net.
6. Diseñe la selección de λ y α .
7. Explique qué métricas usaría.
8. Indique cómo evitaría fuga de información.

9. Explique cómo interpretaría los coeficientes.
10. Señale por qué la selección no implica causalidad.

12.56. Resumen

En este capítulo se estudió la regularización como mecanismo para controlar complejidad, reducir varianza y mejorar estabilidad.

Se derivó el estimador ridge y se analizó su efecto espectral. También se formuló LASSO mediante penalización L_1 , se introdujeron subgradientes y soft-thresholding, y se explicó su capacidad de selección de variables.

Finalmente, se desarrolló elastic net, la interpretación bayesiana, los caminos de regularización, la selección de λ y extensiones como group LASSO. Estos conceptos serán fundamentales en regresión, clasificación y redes neuronales.

Parte III

III. Modelos de regresión

13 Regresión lineal simple

13.1. Introducción

La regresión lineal simple estudia la relación entre una variable explicativa X y una variable respuesta Y . Su propósito es modelar cómo cambia, en promedio, la respuesta cuando cambia la variable explicativa.

Aunque se trata de uno de los modelos más sencillos, constituye la base conceptual de métodos más avanzados. En este capítulo se desarrollan la formulación probabilística, la estimación por mínimos cuadrados, las propiedades de los estimadores, la inferencia sobre los parámetros, los intervalos de confianza y predicción, el coeficiente de determinación y el análisis de residuos.

13.2. Objetivos

Al finalizar el capítulo, el lector podrá:

1. formular el modelo de regresión lineal simple;
2. interpretar los parámetros β_0 y β_1 ;
3. derivar los estimadores de mínimos cuadrados;
4. interpretar geoméricamente el ajuste;
5. demostrar propiedades de insesgadez;
6. calcular varianzas de los estimadores;
7. formular pruebas de hipótesis para la pendiente;
8. construir intervalos de confianza;
9. construir intervalos de predicción;
10. interpretar R^2 ;
11. analizar residuos;
12. reconocer violaciones de supuestos;
13. relacionar la regresión lineal con el aprendizaje supervisado.

13.3. Formulación del modelo

Sean observaciones

$$(x_i, y_i), \quad i = 1, \dots, n.$$

El modelo de regresión lineal simple es

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i.$$

Aquí:

- β_0 es el intercepto;
- β_1 es la pendiente;
- ε_i es el error aleatorio.

13.4. Interpretación de los parámetros

13.4.1. Intercepto

$$\beta_0$$

representa el valor esperado de Y cuando

$$X = 0.$$

Esta interpretación solo es útil si $X = 0$ tiene sentido dentro del contexto del problema.

13.4.2. Pendiente

$$\beta_1$$

representa el cambio promedio esperado en Y por cada unidad adicional de X .

Formalmente,

$$\mathbb{E}(Y \mid X = x) = \beta_0 + \beta_1 x.$$

Por tanto,

$$\frac{d}{dx} \mathbb{E}(Y \mid X = x) = \beta_1.$$

13.5. Supuestos clásicos

Se supone:

13.5.1. Linealidad

$$\mathbb{E}(Y_i \mid x_i) = \beta_0 + \beta_1 x_i.$$

13.5.2. Media cero de los errores

$$\mathbb{E}(\varepsilon_i \mid x_i) = 0.$$

13.5.3. Varianza constante

$$\text{Var}(\varepsilon_i \mid x_i) = \sigma^2.$$

13.5.4. Independencia

$$\text{Cov}(\varepsilon_i, \varepsilon_j) = 0, \quad i \neq j.$$

13.5.5. Normalidad

Para inferencia exacta,

$$\varepsilon_i \sim N(0, \sigma^2).$$

La normalidad no es necesaria para obtener los estimadores de mínimos cuadrados, pero sí para ciertas pruebas e intervalos exactos en muestras pequeñas.

13.6. Función de regresión

La función de regresión poblacional es

$$m(x) = \mathbb{E}(Y \mid X = x) = \beta_0 + \beta_1 x.$$

La recta ajustada es

$$\widehat{m}(x) = \hat{\beta}_0 + \hat{\beta}_1 x.$$

13.7. Criterio de mínimos cuadrados

Los residuos son

$$e_i = y_i - \hat{y}_i,$$

donde

$$\hat{y}_i = \beta_0 + \beta_1 x_i.$$

La suma de cuadrados residual es

$$S(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2.$$

Los estimadores de mínimos cuadrados son

$$(\hat{\beta}_0, \hat{\beta}_1) = \arg \min_{\beta_0, \beta_1} S(\beta_0, \beta_1).$$

13.8. Derivación de las ecuaciones normales

Derivando respecto de β_0 ,

$$\frac{\partial S}{\partial \beta_0} = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i).$$

Igualando a cero,

$$\sum_{i=1}^n y_i = n\beta_0 + \beta_1 \sum_{i=1}^n x_i.$$

Derivando respecto de β_1 ,

$$\frac{\partial S}{\partial \beta_1} = -2 \sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i).$$

Igualando a cero,

$$\sum_{i=1}^n x_i y_i = \beta_0 \sum_{i=1}^n x_i + \beta_1 \sum_{i=1}^n x_i^2.$$

Estas son las ecuaciones normales.

13.9. Estimador de la pendiente

Defina

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2,$$

$$S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}).$$

Entonces,

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}.$$

13.10. Estimador del intercepto

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

Por tanto, la recta ajustada pasa por el punto

$$(\bar{x}, \bar{y}).$$

13.11. Relación con covarianza y varianza

La pendiente puede escribirse como

$$\hat{\beta}_1 = \frac{\widehat{\text{Cov}}(X, Y)}{\widehat{\text{Var}}(X)}.$$

También,

$$\hat{\beta}_1 = r_{XY} \frac{s_Y}{s_X},$$

donde r_{XY} es la correlación muestral.

13.12. Interpretación geométrica

El vector de respuestas es

$$\mathbf{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}.$$

El espacio generado por

$$\mathbf{1} = \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}$$

y

$$\mathbf{x} = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$$

es un subespacio de $\mathbb{R}^n$.

El vector ajustado

$$\hat{\mathbf{y}}$$

es la proyección ortogonal de $\mathbf{y}$ sobre ese subespacio.

Por tanto,

$$\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}$$

es ortogonal a $\mathbf{1}$ y a $\mathbf{x}$.

13.13. Propiedades de los residuos

De las ecuaciones normales se obtiene:

$$\sum_{i=1}^n e_i = 0,$$

$$\sum_{i=1}^n x_i e_i = 0,$$

y

$$\sum_{i=1}^n \hat{y}_i e_i = 0.$$

Además,

$$\bar{\hat{y}} = \bar{y}.$$

13.14. Inssegadez de la pendiente

Como

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x}) Y_i}{S_{xx}},$$

y

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i,$$

se obtiene

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x}) \varepsilon_i}{S_{xx}}.$$

Tomando esperanza,

$$\mathbb{E}(\hat{\beta}_1) = \beta_1.$$

Por tanto, $\hat{\beta}_1$ es insesgado.

13.15. Insesgadez del intercepto

Como

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x},$$

entonces

$$\mathbb{E}(\hat{\beta}_0) = \beta_0.$$

13.16. Varianza de la pendiente

Bajo homocedasticidad e independencia,

$$\text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}}.$$

La varianza disminuye cuando:

- aumenta n ;
- aumenta la dispersión de X ;
- disminuye σ^2 .

13.17. Varianza del intercepto

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right].$$

13.18. Covarianza entre estimadores

$$\text{Cov}(\hat{\beta}_0, \hat{\beta}_1) = -\frac{\bar{x}\sigma^2}{S_{xx}}.$$

Si X se centra, es decir,

$$z_i = x_i - \bar{x},$$

entonces la covarianza entre intercepto y pendiente se reduce a cero.

13.19. Teorema de Gauss-Markov

Teorema 13.1. *Bajo linealidad, media cero, homocedasticidad e independencia, los estimadores de mínimos cuadrados son los mejores estimadores lineales insesgados.*

La palabra “mejores” significa que tienen mínima varianza dentro de la clase de estimadores lineales insesgados.

La normalidad no es necesaria para este resultado.

13.20. Estimación de la varianza del error

La suma de cuadrados residual es

$$SSE = \sum_{i=1}^n e_i^2.$$

El estimador insesgado de σ^2 es

$$s^2 = MSE = \frac{SSE}{n-2}.$$

Se utilizan $n-2$ grados de libertad porque se estimaron dos parámetros.

13.21. Error estándar residual

$$s = \sqrt{\frac{SSE}{n-2}}.$$

Este valor estima la desviación estándar de los errores.

13.22. Distribución de los estimadores

Si los errores son normales,

$$\hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{S_{xx}}\right).$$

Además,

$$\frac{\hat{\beta}_1 - \beta_1}{s/\sqrt{S_{xx}}} \sim t_{n-2}.$$

13.23. Error estándar de la pendiente

$$SE(\hat{\beta}_1) = \frac{s}{\sqrt{S_{xx}}}.$$

13.24. Error estándar del intercepto

$$SE(\hat{\beta}_0) = s\sqrt{\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}}.$$

13.25. Prueba de hipótesis para la pendiente

Se desea contrastar

$$H_0 : \beta_1 = 0$$

contra

$$H_1 : \beta_1 \neq 0.$$

El estadístico es

$$t = \frac{\hat{\beta}_1}{SE(\hat{\beta}_1)}.$$

Bajo H_0 ,

$$t \sim t_{n-2}.$$

Si el valor p es pequeño, existe evidencia de asociación lineal.

13.26. Interpretación correcta

Rechazar

$$H_0 : \beta_1 = 0$$

indica evidencia de relación lineal, no necesariamente causalidad.

Una pendiente no significativa no demuestra ausencia total de relación; puede existir:

- relación no lineal;
- poca potencia;
- medición deficiente;
- rango limitado de X .

13.27. Intervalo de confianza para la pendiente

Un intervalo de nivel $1 - \alpha$ es

$$\hat{\beta}_1 \pm t_{\alpha/2, n-2} SE(\hat{\beta}_1).$$

13.28. Intervalo de confianza para el intercepto

$$\hat{\beta}_0 \pm t_{\alpha/2, n-2} SE(\hat{\beta}_0).$$

13.29. Estimación de la respuesta media

En un valor x_0 ,

$$\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0.$$

Su error estándar es

$$SE(\hat{y}_0^{mean}) = s \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}.$$

13.30. Intervalo de confianza para la media

$$\hat{y}_0 \pm t_{\alpha/2, n-2} s \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}.$$

13.31. Intervalo de predicción

Para una nueva observación,

$$Y_{new} = \beta_0 + \beta_1 x_0 + \varepsilon_{new}.$$

El error estándar es

$$SE(\hat{y}_0^{pred}) = s \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}.$$

El intervalo de predicción es

$$\hat{y}_0 \pm t_{\alpha/2, n-2} s \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}.$$

Es más ancho que el intervalo para la media.

13.32. Descomposición de la variabilidad

La suma total de cuadrados es

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2.$$

La suma explicada es

$$SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2.$$

La suma residual es

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

Se cumple

$$SST = SSR + SSE.$$

13.33. Coeficiente de determinación

Definición 13.1. El coeficiente de determinación es

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}.$$

En regresión lineal simple con intercepto,

$$R^2 = r_{XY}^2.$$

13.34. Interpretación del coeficiente de determinación

R^2 representa la proporción de variabilidad de Y explicada por el modelo lineal.

No indica:

- causalidad;
- ausencia de sesgo;
- validez de supuestos;

- capacidad predictiva futura;
- calidad absoluta del modelo.

13.35. Tabla ANOVA

La descomposición puede organizarse como:

Fuente	Suma de cuadrados	gl	Cuadrado medio
Regresión	SSR	1	$MSR = SSR$
Error	SSE	$n - 2$	$MSE = SSE/(n - 2)$
Total	SST	$n - 1$	

El estadístico es

$$F = \frac{MSR}{MSE}.$$

En regresión simple,

$$F = t^2$$

para la prueba de la pendiente.

13.36. Residuos

Los residuos son

$$e_i = y_i - \hat{y}_i.$$

Se utilizan para evaluar los supuestos.

13.37. Residuos estandarizados

Una versión básica es

$$r_i = \frac{e_i}{s}.$$

Sin embargo, las varianzas de los residuos no son iguales porque dependen del apalancamiento.

13.38. Matriz sombrero

En forma matricial,

$$\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}.$$

La matriz

$$\mathbf{H} = \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T$$

se denomina matriz sombrero.

13.39. Apalancamiento

Los elementos diagonales

$$h_{ii}$$

miden apalancamiento.

En regresión simple,

$$h_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}}.$$

Observaciones alejadas de $\bar{x}$ tienen mayor apalancamiento.

13.40. Varianza de los residuos

$$\text{Var}(e_i) = \sigma^2(1 - h_{ii}).$$

Por ello, los residuos estandarizados internamente son

$$r_i = \frac{e_i}{s\sqrt{1 - h_{ii}}}.$$

13.41. Residuos studentizados

Los residuos studentizados externamente utilizan una estimación de σ obtenida sin la observación i .

Son útiles para detectar valores atípicos.

13.42. Distancia de Cook

La distancia de Cook mide la influencia de una observación sobre el ajuste:

$$D_i = \frac{e_i^2}{ps^2} \frac{h_{ii}}{(1 - h_{ii})^2},$$

donde $p = 2$ en regresión simple con intercepto.

Una observación puede ser influyente si combina:

- residuo grande;
- apalancamiento alto.

13.43. Diagnóstico de linealidad

Se examina la gráfica:

$$e_i \text{ contra } \hat{y}_i.$$

Un patrón curvo sugiere relación no lineal.

13.44. Diagnóstico de homocedasticidad

Si la dispersión de residuos aumenta o disminuye con $\hat{y}$, puede existir heterocedasticidad.

13.45. Diagnóstico de normalidad

Puede utilizarse:

- histograma;
- gráfico Q-Q;
- pruebas formales.

En muestras grandes, pequeñas desviaciones pueden resultar significativas sin ser importantes en la práctica.

13.46. Diagnóstico de independencia

En datos ordenados temporalmente se analizan:

- residuos contra tiempo;
- autocorrelaciones;
- prueba de Durbin-Watson.

13.47. Heterocedasticidad

Si

$$\text{Var}(\varepsilon_i \mid x_i) = \sigma_i^2,$$

la varianza no es constante.

Los estimadores de mínimos cuadrados pueden seguir siendo insesgados, pero los errores estándar clásicos pueden ser incorrectos.

13.48. Errores estándar robustos

Los errores estándar robustos corrigen la estimación de varianza sin modificar los coeficientes.

Son útiles cuando existe heterocedasticidad.

13.49. Transformaciones

Una transformación puede ayudar a:

- linealizar;
- estabilizar varianza;
- reducir asimetría.

Ejemplos:

$$\log(Y), \quad \sqrt{Y}, \quad \log(X).$$

La interpretación de los coeficientes cambia.

13.50. Extrapolación

Predecir fuera del rango observado de X puede ser peligroso.

Aunque la recta se extienda matemáticamente, la relación real puede cambiar.

13.51. Correlación y regresión

En regresión simple,

$$\hat{\beta}_1 = r \frac{s_Y}{s_X}.$$

Sin embargo:

- la correlación es simétrica;
- la regresión distingue respuesta y predictor;
- cambiar unidades afecta la pendiente;
- la correlación no cambia ante cambios lineales de escala positiva.

13.52. Regresión y causalidad

Una asociación lineal no implica causalidad.

Pueden existir:

- variables omitidas;
- causalidad inversa;
- confusión;
- selección de muestra;
- coincidencia.

13.53. Relación con máxima verosimilitud

Si

$$\varepsilon_i \sim N(0, \sigma^2),$$

la verosimilitud es

$$L(\beta_0, \beta_1, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(y_i - \beta_0 - \beta_1 x_i)^2}{2\sigma^2} \right].$$

Maximizar esta verosimilitud respecto de β_0 y β_1 equivale a minimizar

$$\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2.$$

Por tanto, mínimos cuadrados y máxima verosimilitud coinciden bajo normalidad.

13.54. Relación con aprendizaje supervisado

El espacio de hipótesis es

$$\mathcal{F} = \{f(x) = \beta_0 + \beta_1 x\}.$$

La pérdida es

$$L(y, f(x)) = (y - f(x))^2.$$

El riesgo empírico es

$$\widehat{R}_n(f) = \frac{1}{n} \sum_{i=1}^n (y_i - f(x_i))^2.$$

La regresión lineal simple es, por tanto, un problema de minimización del riesgo empírico.

13.55. Conexión con R

```
datos <- data.frame(  
  temperatura = c(18, 20, 22, 24, 26, 28),  
  pm10 = c(35, 39, 44, 50, 57, 63)  
)  
  
modelo <- lm(  
  pm10 ~ temperatura,  
  data = datos  
)  
  
summary(modelo)  
  
coef(modelo)  
  
confint(modelo)  
  
predict(  
  modelo,  
  newdata = data.frame(temperatura = 25),  
  interval = "confidence"  
)  
  
predict(  
  modelo,  
  newdata = data.frame(temperatura = 25),  
  interval = "prediction"  
)  
  
par(mfrow = c(2, 2))  
plot(modelo)
```

13.56. Ejemplo numérico

Considere:

x_i	y_i
1	2
2	3
3	5
4	6

Se tiene

$$\bar{x} = 2.5, \quad \bar{y} = 4.$$

Además,

$$S_{xx} = (1 - 2.5)^2 + (2 - 2.5)^2 + (3 - 2.5)^2 + (4 - 2.5)^2 = 5.$$

Y

$$S_{xy} = (1 - 2.5)(2 - 4) + (2 - 2.5)(3 - 4) + (3 - 2.5)(5 - 4) + (4 - 2.5)(6 - 4).$$

Por tanto,

$$S_{xy} = 6.$$

Entonces,

$$\hat{\beta}_1 = \frac{6}{5} = 1.2.$$

Y

$$\hat{\beta}_0 = 4 - 1.2(2.5) = 1.$$

La recta ajustada es

$$\hat{y} = 1 + 1.2x.$$

13.57. Errores frecuentes

1. Interpretar el intercepto fuera del rango observado.
2. Concluir causalidad a partir de una pendiente significativa.
3. Utilizar R^2 como único criterio de calidad.
4. Ignorar patrones en los residuos.
5. Extrapolar lejos del rango de los datos.
6. Confundir intervalo de confianza con intervalo de predicción.
7. Ignorar heterocedasticidad.
8. Eliminar observaciones influyentes sin justificación.
9. Suponer que normalidad de Y es requerida; el supuesto se refiere a los errores.
10. Interpretar una pendiente no significativa como prueba de ausencia de relación.

13.58. Ejercicios conceptuales

1. Explique la diferencia entre función de regresión y recta ajustada.
2. ¿Qué representa β_1 ?
3. ¿Por qué la recta ajustada pasa por $(\bar{x}, \bar{y})$?
4. ¿Qué significa el teorema de Gauss-Markov?
5. ¿Por qué se utilizan $n - 2$ grados de libertad?
6. ¿Qué diferencia existe entre intervalo de confianza y predicción?
7. ¿Qué mide R^2 ?
8. ¿Qué representa el apalancamiento?
9. ¿Qué diferencia existe entre valor atípico e influencia?
10. ¿Por qué la extrapolación puede ser peligrosa?

13.59. Ejercicio de estimación

Considere los datos:

x	2	4	6	8	10
y	5	8	9	13	15

Calcule:

1. $\bar{x}$;
2. $\bar{y}$;
3. S_{xx} ;
4. S_{xy} ;

5. $\hat{\beta}_1$;
6. $\hat{\beta}_0$;
7. los valores ajustados;
8. los residuos.

13.60. Ejercicio de inferencia

Supóngase:

$$\hat{\beta}_1 = 2.4,$$

$$SE(\hat{\beta}_1) = 0.6,$$

$$n = 20.$$

1. Calcule el estadístico t .
2. Evalúe $H_0 : \beta_1 = 0$.
3. Construya un intervalo de confianza del 95 %.
4. Interprete el resultado.

13.61. Ejercicio de ANOVA

Sean:

$$SST = 200, \quad SSE = 80, \quad n = 12.$$

Calcule:

1. SSR ;
2. R^2 ;
3. MSR ;
4. MSE ;
5. el estadístico F .

13.62. Ejercicio de predicción

Supóngase:

$$\hat{y} = 4 + 1.5x,$$

$$s = 2,$$

$$n = 25,$$

$$\bar{x} = 10,$$

$$S_{xx} = 200.$$

Para $x_0 = 12$:

1. calcule la predicción;
2. calcule el error estándar de la media;
3. calcule el error estándar de predicción;
4. compare ambos intervalos.

13.63. Ejercicio de diagnóstico

Para cada patrón, explique qué posible problema sugiere:

1. residuos con forma de U;
2. residuos con forma de embudo;
3. un punto con gran apalancamiento y residuo pequeño;
4. un punto con gran apalancamiento y residuo grande;
5. residuos autocorrelacionados.

13.64. Ejercicio aplicado

Se desea estudiar la relación entre temperatura y concentración de PM10.

1. Defina el modelo.
2. Interprete β_0 y β_1 .

3. Indique los supuestos.
4. Describa la estimación por mínimos cuadrados.
5. Explique cómo probaría la pendiente.
6. Explique cómo construiría un intervalo para la media.
7. Explique cómo construiría un intervalo para una nueva observación.
8. Proponga gráficos de diagnóstico.
9. Explique por qué la asociación no implica causalidad.
10. Indique cuándo sería necesaria una transformación.

13.65. Resumen

En este capítulo se desarrolló la regresión lineal simple desde su formulación probabilística hasta la inferencia y el diagnóstico.

Se derivaron los estimadores de mínimos cuadrados, se estudiaron sus propiedades de insesgadez y varianza, y se presentó el teorema de Gauss-Markov.

También se desarrollaron pruebas para la pendiente, intervalos de confianza y predicción, descomposición ANOVA, coeficiente de determinación, análisis de residuos, apalancamiento e influencia.

La regresión lineal simple constituye la base para la regresión múltiple, la regularización y numerosos modelos de aprendizaje supervisado.

14 Regresión lineal múltiple

Capítulo en desarrollo.

15 Regresión logística

Capítulo en desarrollo.

Parte IV

IV. Métodos de clasificación

16 Vecinos más cercanos

Capítulo en desarrollo.

17 Árboles de decisión

Capítulo en desarrollo.

18 Bosques aleatorios

Capítulo en desarrollo.

19 Máquinas de vectores de soporte

Capítulo en desarrollo.

20 Redes neuronales artificiales

Capítulo en desarrollo.

Parte V

V. Aprendizaje no supervisado

21 Análisis de componentes principales

Capítulo en desarrollo.

22 Agrupamiento k-means

Capítulo en desarrollo.

23 Agrupamiento jerárquico

Capítulo en desarrollo.

24 Reglas de asociación

Capítulo en desarrollo.

Parte VI

VI. Temas avanzados

25 Teoría de generalización

Capítulo en desarrollo.

26 Series de tiempo y aprendizaje automático

Capítulo en desarrollo.

Referencias